

Essaims de particules quantiques et apprentissage par complément pour la segmentation d'images médicales : une approche basée seuillage

Lamis Ghoualmi, Amina Bouzid

Encadré par : Dr. Amer Draâ

Remerciements

A priori nous tenons à exprimer notre entière gratitude et nos vifs remerciements à l'endroit de notre encadreur en la personne du *Dr.Amer Draa* qui par ses encouragements, son soutien et sa disponibilité, a été tout au long de notre travail d'un précieux apport dans la réalisation de notre projet. Son concours et ses conseils nous ont d'ailleurs permis l'acquisition et le développement de l'esprit scientifique, ses orientations nous ont été également très utiles pour le couronnement de notre travail dans ses différentes phases d'élaboration.

Pour cela nous tenons à le remercier pour tout l'effort qu'il nous a consenti surtout que nous avons découvert en lui un encadreur exemplaire, sérieux, persévérant et très généreux dans la transmission de son savoir.

Nous remercions également les membres de jury pour l'intérêt qu'ils ont bien voulu accorder à l'évaluation de notre travail et nous espérons avec ce mémoire être à la hauteur de leurs attentes.

Sans oublier nos parents qui nous ont encouragé, soutenu moralement et matériellement durant notre cursus universitaire pour la réalisation de nos objectifs intellectuels.

Nous adressons nos remerciements au personnel du laboratoire *MISC* plus particulièrement notre Professeur responsable de formation *Salim Chikhi* ainsi que tout le département d'informatique de l'université *Constantine 2*, pour les moyens matériels mis à notre disposition, et toutes les personnes qui nous ont apporté leur aide et sympathie.

Résumé

Les algorithmes d'optimisation basés population sont des algorithmes puissants capable de résoudre plusieurs type de problème dans différents domaine. Ils sont souvent recommandés dans le domaine d'imagerie médicale. Parmi les métaheuritiques basés population on trouve l'algorithme d'optimisation par essaim de particules PSO qui est l'un des meilleurs algorithmes d'optimisation. Il est simple à comprendre et à programmer. Cependant comme toute autre métaheuristique, PSO a des inconvénients. Le problème de la convergence prématuée est l'un des principaux problèmes du PSO.

Afin de pallier à cette limite, nous proposons dans notre projet une nouvelle variante de l'algorithme PSO qui est le PSO quantique (QPSO) pour résoudre le problème de la segmentation d'images médicales par seuillage. Cet algorithme se base sur la mécanique quantique au lieu des règles newtoniennes utilisées dans le PSO classique. Cette variante est beaucoup plus performante que le PSO classique. Il s'est avéré que l'algorithme QPSO souffre aussi du problème de la convergence prématuée. Afin de surmonter cette limite et d'améliorer les performances de l'algorithme QPSO nous proposons comme deuxième approche une variante de l'algorithme QPSO qui introduit le concept d'apprentissage par complément (OBL) dans le QPSO. Les résultats expérimentaux ont montré que cette variante OQPSO est plus performante que le QPSO classique.

Afin de valider nos contributions, un ensemble de tests a été effectué pour résoudre le problème de la segmentation d'images médicales par seuillage en utilisant deux fonctions objectif. La première permet de segmenter les images en se basant sur l'entropie de Kapur et la deuxième sur la variance inter-classes d'Otsu. Les résultats obtenus ont prouvé que l'algorithme OQPSO a surpassé l'algorithme QPSO de base ainsi que l'algorithme de colonie d'abeilles artificielles et sa variante guidée par le meilleur global, qui ont été implémentés par nous même ; pour but de comparaison.

Mots-clés Optimisation par essaim de particules, PSO Quantique , Apprentissage par complément, Segmentation d'images médicales, Seuillage multi-niveaux

Abstract

Population based optimization algorithms are powerful algorithms that can solve several types of problems in different domains. They are often recommended in medical imaging domain. Among population based meta-heuristics we find particles swarm optimization (PSO), which is one of the best optimization algorithms. It is simple to understand, to use and to implement. However, as other optimization algorithms, PSO has a big disadvantage. The problem of premature convergence is one of the major problems.

To overcome this limitation we use in our project a new variant of the PSO algorithm which is the quantum PSO (QPSO) to solve the segmentation in medical imaging by using the thresholding. This variant is based on quantum mechanics rather than the Newtonian rules assumed in all previous versions of PSO. The QPSO algorithm is much more efficient than conventional PSO, but it is proved that this algorithm also suffers from the problem of premature convergence. To overcome this limitation and improve the performance of the QPSO algorithm, we proposed a second variant named OQPSO algoithm which introduces the concept of opposition-based learning (OBL) in the QPSO. The results showed that this new variant is more efficient than the basic QPSO.

In order to validate our contribution, a set of tests was carried out to segment medical images by using thresholding whith two objective functions the first is called Kapur entropy and the second one is called the inter-class variance of Otsu. The results showed that the OQPSO algorithm outperformed the basic QPSO as well as the ABC and the GABC which were also implemented in order to carry out a comparative study.

Keywords Particules swarm optimisation, Quantum PSO, Opposition-based learning, Medical image segmentation, Multi-level thresholding

ملخص

تعتبر تجزئة الصور بشكل عام خطوة مهمة في مراحل معالجة الصور الرقمية فهي عبارة عن عملية تجزئة للصورة إلى مناطق متراكبة ومتجانسة وفقاً لمعايير محدد مثل اللون. أما العتبة فهي واحدة من تقنيات التجزئة . في هذا السياق نقدم نوعين من العتبة الأكثر استعمالاً طريقة "أوتسو" لتعظيم درجة التعادل وطريقة "كابور الإنتروريه" .

الهدف الرئيس من هذه الدراسة هو استخدام خوارزمية استمثال عناصر السرب في مجال الميكانيك الكمية، في تقسيم الصور الطيبة كأول إسهام. كثاني إسهام قمنا بإدخال مفهوم التعلم بالمرافق في خوارزمية استمثال عناصر السرب في مجال الميكانيك الكمية. لقد أظهرت النتائج المتحصل عليها بالمقارنة مع خوارزمية مستعمرة النحل الاصطناعي واحد أنواعها الموجه بأحسن حل والتي فمنا ببرمجتها كذلك، أن خوارزمية استمثال عناصر السرب في مجال الميكانيك الكمية مع إدخال مفهوم التعلم هي أحسن خوارزمية. إن خوارزمية مستعمرة النحل الاصطناعي الموجه بأحسن حل لم تستعمل من قبل في تقسيم الصور بالعتبة لذا فهي تعتبر إسهاماً ثالثاً منا.

الكلمات المفتاحية: استمثال عناصر السرب، تجزئة الصور الطيبة، التعلم بالمرافق،
تجزئة
الصور بالعتبة

Introduction générale

L'imagerie médicale est un domaine qui s'intéresse à visualiser une partie du corps humain ou d'un organe et d'en conserver une image. Elle a pour objectif d'aider dans le diagnostic. Le traitement d'images médicales est né de l'idée de la nécessité de remplacer l'observateur humain par la machine. Le but du traitement des images médicales est d'extraire à partir des images acquises, les informations utiles au diagnostic et de révéler des détails difficiles à percevoir à l'œil nu, tout en évitant la création d'artefacts, faussement informatifs. Pour cela le traitement fait appel à des outils, des algorithmes, qui permettent d'agir sur l'image numérisée ; L'un des processus fondamentaux dans la chaîne de traitement d'images médicales est la segmentation.

La segmentation d'images est l'opération la plus importante dans un système de traitement des images, car elle est située à l'articulation entre le traitement et l'analyse des images. L'intérêt de la segmentation est de partitionner une image en plusieurs régions homogènes, au sens d'un critère fixé a priori. L'intérêt de disposer de régions homogènes est de fournir des données simplifiées, qui facilitent la tâche d'un système de reconnaissance de formes, ou autre système d'extraction des objets contenus dans l'image.

Problématique

Parmi les techniques de la segmentation d'images, on trouve le seuillage qui permet d'extraire des objets de leurs fonds en fonction d'un seuil. De par sa simplicité, il occupe une place prépondérante dans plusieurs applications telles que : l'analyse de documents, analyse d'images médicales etc. La plupart des méthodes de seuillage déterminent le seuil en optimisant une fonction objectif. Cependant, le temps de calcul croît exponentiellement avec le nombre de seuils. Dans ce cas, le problème de seuillage multi-niveau devient un problème d'optimisation. Plusieurs métaheuristiques basé population ont été proposées pour résoudre ce problème. Parmi ces métaheuristiques on trouve l'algorithme d'optimisation par essaim de particules, l'algorithme génétique et algorithme de colonie d'abeilles artificielles.

L'algorithme d'optimisation par essaim de particules (PSO) est l'un des meilleurs algorithmes d'optimisation. Il est simple à comprendre et à implémenter, Cependant comme toutes autre

métaheuristique l'algorithme PSO possède quelque inconvénients. Le problème de la convergence prématuée est l'un des principaux problèmes du PSO [Van den Bergh, 2001].

Contributions

Motivés par les limites du PSO de base, on a proposé deux variantes de l'algorithme PSO qu'on va adapter pour le problème de segmentation d'images médicales par seuillage multi-niveaux, la première contribution consiste en la proposition de l'approche PSO dans le domaine quantique, cet algorithme est plus performant que le PSO classique mais ce dernier souffre aussi du problème de la convergence prématuée. Pour pallier à cette limite on propose comme deuxième contribution une approche qui est la notre qui consiste en l'introduction du concept d'apprentissage par complément dans QPSO. L'algorithme de colonie d'abeilles artificielles ABC et sa variante guidée par le meilleur global GABC ont étaient implémenté pour but de comparaison. Notant que l'algorithme GABC n'a jamais été utilisée pour la segmentation d'images médicales et cela sera notre troisième contribution.

Plan du document

Par conséquence, notre mémoire se divise en cinq chapitres qui sont les suivant :

Le premier chapitre comporte les notions de base de l'imagerie médicale ainsi que la chaîne de traitement d'images médicales. Le second chapitre décrit les différentes approches de segmentation d'images. Le troisième chapitre présente les systèmes complexes et leurs caractéristiques ainsi que des modèles artificiels pour ces systèmes complexes.

La quatrième chapitre présente nos contributions pour résoudre le problème de la segmentation d'images médicales par seuillage multi-niveaux, on retrouve les motivations qui nous ont poussé à proposer de nouvelles approches, les concepts d'exploration et exploitation dans l'algorithme d'optimisation par essaim de particule, le principe de notre première approche qui est le PSO dans le domaine quantique et son comportement, puis la principales limites du PSO quantique qui vont servir de motivations pour proposer la seconde approche qui est l'introduction du concept d'apprentissage par complément dans le PSO quantique.

Le cinquième chapitre présente les résultats expérimentaux de l'application des algorithmes PSO quantique et le PSO quantique avec l'apprentissage par complément ainsi que deux autres algorithmes qui sont l'algorithme ABC et sa variante guidée par le meilleur global pour résoudre le problème de la segmentation d'images médicales par seuillage multi-niveaux.

Table des matières

Remerciements	i
Résumé	ii
Abstract	iii
Introduction générale	v
1 Imagerie Médicale	8
1.1 Introduction	10
1.2 Imagerie médicale	10
1.2.1 Intérêt de l'imagerie médical	11
1.2.2 Traitement d'images Médicales	11
1.3 Chaine de traitement d'images médicale	11
1.3.1 Acquisition des données images	11
1.3.2 Numérisation	14
1.3.3 Prétraitement	14
1.3.4 Traitement numérique d'image	15
1.4 Conclusion	17
2 Segmentation d'images	18
2.1 Introduction	20
2.2 Segmentation d'images	20
2.3 Techniques de segmentation d'images	21
2.3.1 Approches basées contour	21
2.3.2 Approches basées région	23
2.3.3 Approche coopérative	26
2.4 Segmentation par seuillage	26
2.4.1 Définition du seuillage	27
2.4.2 Méthodes de seuillage globales	27
2.4.3 Méthodes de seuillage local ou adaptatives	29
2.5 Conclusion	30

3 Systèmes Complexes Adaptatifs	31
3.1 Introduction	33
3.2 Historique	33
3.3 Système complexe adaptatif : définition	34
3.3.1 Systèmes complexes	34
3.3.2 Systèmes complexes adaptatifs	34
3.4 Propriétés des systèmes complexes adaptatifs	35
3.4.1 Complexité	35
3.4.2 Émergence	35
3.4.3 Auto-organisation et systèmes auto-organisés	36
3.4.4 Adaptation	36
3.4.5 Apprentissage	37
3.5 Optimisation	37
3.5.1 Définitions	37
3.6 Modèles artificiels pour les systèmes complexes adaptatifs (SACs)	38
3.6.1 Classification des modèles artificiels pour les SACs	38
3.6.2 Algorithmes évolutionnaires	39
3.6.3 Algorithmes d'intelligence par essaim	43
3.7 Conclusion	48
4 Contributions (QPSO et l'OBL pour la segmentation d'images médicales)	49
4.1 Introduction	51
4.2 Motivation	51
4.2.1 Métaheuristiques Pour la segmentation d'images	52
4.3 Éléments des contributions	52
4.3.1 Optimisation par essaim de particules quantiques	53
4.3.2 Apprentissage par complément	54
4.4 Contributions	55
4.4.1 Formulation du problème	55
4.4.2 Contribution(1) : PSO Quantique pour la segmentation d'images médicales	58
4.4.3 Contribution(2) : PSO quantique avec apprentissage par complément pour la segmentation d'images médicales	62
4.5 Conclusion	64
5 Étude expérimentale	65
5.1 Introduction	67
5.2 Images de tests	67
5.3 Choix des paramètres	68
5.4 Résultats expérimentaux et discussion	69

5.4.1	Résultats visuels	69
5.4.2	Résultats numériques	71
5.5	Conclusion	78
Appendices		78
A	Résultats des images segmentées	80
Conclusion général		96
Bibliographie		104

Table des figures

1.1	Chaine de traitement d'images médicales	11
1.2	Image radiologique	12
1.3	Image issue d'un scanner	13
1.4	Image IRM	13
1.5	Image avant filtrage et image après filtrage	15
1.6	Modification de l'histogramme	16
1.7	L'opération de segmentation	16
1.8	Recalage d'images	17
2.1	Techniques de la segmentation d'images	20
2.2	Dérivées première et seconde d'un contour de type "saut d'amplitude"	22
2.3	Évolution du contour actif $T(\tau)$ avec la vitesse v vers l'objet d'intérêt	23
2.4	Principe de la segmentation par division des régions (Structure quaternaire)	24
2.5	Principe de la segmentation par division-fusion.	25
2.6	Allures idéales d'un histogramme. (a) : unimodal, (b) : bimodal et (c) multimodal .	28
3.1	Types d'émergence	36
3.2	Classification des metaheuristiques	39
3.3	Croisement génétique	40
3.4	Déplacement d'une particule.	44
4.1	Population P et OP	55
4.2	Schématisation de nos contributions	58
4.3	Organigramme de la segmentation d'images médicales par l'algorithme QPSO .	59
4.4	Population P et population OP dans le cas de l'OBL	60
4.5	Particule P_i	60
4.6	Image subdiviser en 3 classes	61
4.7	Exemple d'une image segmentée	61
4.8	Organigramme de la segmentation d'images médicales par l'algorithme OQPSO .	63
4.9	Population P et population OP	64
5.1	Base d'images utilisées	68

5.2	<i>Image 1</i> segmentée par les différentes approches - fonction objectif Kapur	70
5.3	<i>Image 1</i> segmentée par les différentes approches - fonction objectif Otsu	70
5.4	Évolution de la fitness dans l'algorithme ABC	75
5.5	Évolution de la fitness dans l'algorithme GABC	75
5.6	Évolution de la fitness dans l'algorithme QPSO	76
5.7	Évolution de la fitness dans l'algorithme OQPSO	76
5.8	Comparaison de l'algorithme QPSO, OQPSO	77
5.9	Comparaison des 4 approches	77
A.1	Images médicales utilisées pour les tests	81
A.2	Autre type d'images utilisées pour les tests	81

Liste des tableaux

1.1	Propriétés de l'image radiologique	12
1.2	Propriétés de l'image scanner	13
1.3	Propriétés de l'image IRM	14
5.1	Paramètres des algorithmes QPSO et OQPSO	68
5.2	Paramètres nécessaire à l'algorithme ABC GABC	69
5.3	Résultats de la méthode Kapur pour 2 seuils	71
5.4	Résultats de la méthode Kapur pour 3 seuils	72
5.5	Résultats de la méthode Kapur pour 4 seuils	72
5.6	Résultats de la méthode Otsu pour 2 seuils	73
5.7	Résultats de la méthode Otsu pour 3 seuils	73
5.8	Résultats de la méthode Otsu pour 4 seuils	74
A.1	Image1 segmentée par les 4 approches avec la fonction objectif Kapur	82
A.2	Image2 segmentée par les 4 approches avec la fonction objectif Kapur	83
A.3	Image3 segmentée par les 4 approches avec la fonction objectif Kapur	84
A.4	Image4 segmentée par les 4 approches avec la fonction objectif Kapur	85
A.5	Image5 segmentée par les 4 approches avec la fonction objectif Kapur	86
A.6	Lena segmentée par les 4 approches avec la fonction objectif Kapur	87
A.7	Peppers segmentée par les 4 approches avec la fonction objectif Kapur	88
A.8	Image1 segmentée par les 4 approches avec la fonction objectif Otsu	89
A.9	Image2 segmentée par les 4 approches avec la fonction objectif Otsu	90
A.10	Image3 segmentée par les 4 approches avec la fonction objectif Otsu	91
A.11	Image4 segmentée par les 4 approches avec la fonction objectif Otsu	92
A.12	Image5 segmentée par les 4 approches avec la fonction objectif Otsu	93
A.13	Lena segmenté par les 4 approches avec la fonction objectif Otsu	94
A.14	Peppers segmenté par les 4 approches avec la fonction objectif Otsu	95

Liste d'algorithmes

3.1	Algorithme génétique	41
3.2	Algorithme de l'évolution différentielle	42
3.3	Algorithme d'optimisation par essaim de particules	45
3.4	Algorithme de colonie d'abeilles artificielles	47
4.1	Algorithme d'optimisation par essaim de particules quantiques	54
4.2	Algorithme OQPSO	62

Chapitre 1

Imagerie Médicale

“Les certitudes de la science médicale ne sont jamais que des certitudes.” -

Norbert Bensaïd

Sommaire

1.1	Introduction	10
1.2	Imagerie médicale	10
1.2.1	Intérêt de l'imagerie médical	11
1.2.2	Traitement d'images Médicales	11
1.3	Chaine de traitement d'images médicale	11
1.3.1	Acquisition des données images	11
1.3.2	Numérisation	14
1.3.3	Prétraitement	14
1.3.4	Traitemen numérique d'image	15
1.4	Conclusion	17

1.1 Introduction

A l'évolution des nouvelles techniques occupées à l'interprétation des images par ordinateur, le traitement d'image joue un rôle très important dans plusieurs domaines tels que l'imagerie satellitaire, médicale, industrielle, etc. L'imagerie médicale a connu des techniques efficaces qui permettent d'acquérir et de traiter des images internes du corps humain et d'établir un diagnostic ou même la mise en œuvre d'une thérapeutique en temps réel comme échographie, IRM, et scanner . Selon la technique utilisée, on peut distinguer deux types d'images médicales. Les images anatomiques médicales permettant d'obtenir des informations géométriques sur la structure des organes (taille, volume, localisation, etc.). Et les images fonctionnelles permettant d'obtenir une vision sur la fonctionnalité des organes, par exemple le IRM

Le but du traitement des images médicales est d'extraire à partir des images acquises, les informations utiles au diagnostic, de révéler des détails difficiles à percevoir à l'œil nu, tout en évitant la création d'artefacts, faussement informatifs. Pour cela le traitement fait appel à des outils, des algorithmes, qui permettent d'agir sur l'image numérisée ; dans la chaîne de traitement d'image Berrichi et Benyettou [2009].

Ce chapitre présente le domaine de l'imagerie médicale. On passera en revue par les différents processus utilisés dans la chaîne de traitement d'images médicales .

1.2 Imagerie médicale

Définition 1.1 (Imagerie médicale) *L'imagerie médicale est une méthode unique permettant de visualiser des processus biologiques au sein même des organismes vivants de manière non invasive. Elle est essentielle à la compréhension de leur physiologie et de leurs pathologies afin de mieux les diagnostiquer, les pronostiquer et les soigner [Bihan, 2008].*

L'imagerie médicale est le procédé permettant d'examiner le patient sans opération pour obtenir une représentation visuelle d'informations médicales : signal 1D, image 2D,image 3D [Cho et al., 1993].

L'importance que révèle l'imagerie médicale tient d'abord au fait qu'une image est un concentré d'information bien plus efficace qu'un texte ou qu'une explication verbale. L'interprétation des images médicales est l'un des domaines de recherche les plus encourageants, étant donné qu'il offre des facilités pour le diagnostic et les décisions thérapeutiques d'un grand nombre de maladies [Berrichi et Benyettou, 2009].

1.2.1 Intérêt de l'imagerie médical

L'imagerie médicale rassemble l'ensemble des techniques utilisées pour le diagnostic ainsi que pour le traitement de nombreuses maladies. Elle a permis à la médecine d'obtenir un accès immédiat et fiable à des informations invisibles lors du diagnostic clinique (fonctionnement des tissus et organes, etc.). Elle permet d'identifier précisément les éventuelles lésions et anomalies du corps et des organes et de poser un diagnostic plus fiable. Elle offre un suivi très précis de l'évolution d'une maladie. Elle permet la localisation avec précision d'un organe par rapport à un autre [Bonniol, 2009].

1.2.2 Traitement d'images Médicales

Définition 1.2 (Traitement d'images Médicales) *Le traitement d'images désigne une discipline de l'informatique et des mathématiques appliquée qui étudie les images numériques et leurs transformations, dans le but d'améliorer leur qualité ou d'en extraire de l'information.[Rafael et Woods, 2008]*

1.3 Chaine de traitement d'images médicale

Un système de traitement d'image est composé des phases suivantes :
acquisition, numérisation, prétraitement, traitement et visualisation.
voici un schéma illustrant la chaîne de traitement d'images médicales 1.1.

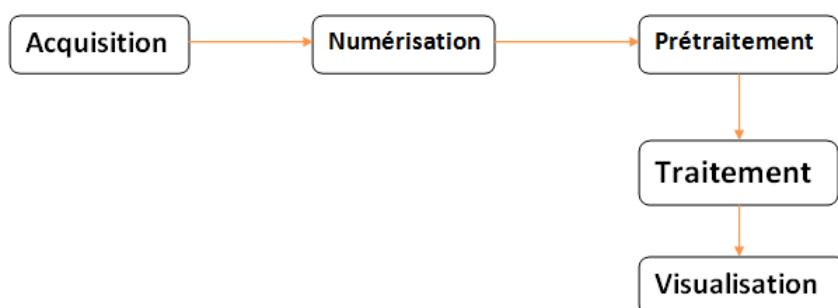


FIGURE 1.1 – Chaîne de traitement d'images médicales

1.3.1 Acquisition des données images

L'acquisition d'images constitue un des maillons essentiels de toute chaîne de conception et de production d'images. Pour pouvoir manipuler une image sur un système informatique, il est avant tout nécessaire de lui faire subir une transformation qui la rendra lisible et manipulable par ce système. Le passage de cet objet externe (l'image d'origine) à sa représentation interne (dans l'unité de traitement) par le biais d'un capteur [Bendiab, 2010].

Principaux capteurs de l'imagerie médicale

Définition 1.3 (capteur) *Le capteur est le dispositif qui enregistre l'onde électromagnétique amenant de la scène sous une certaine représentation en vue de son exploitation. Parmi les types de capteur on trouve : camera, capteur infrarouge, IRM, scanner et microscope [Bendiab, 2010].*

Radiologie La radiologie est une technique d'imagerie de transmission, par rayons X dans le cadre de la radiographie X, ou par rayons gamma en gamma-graphie. Elle permet d'obtenir un cliché dont le contraste dépend à la fois de l'épaisseur et du coefficient d'atténuation des structures traversées [Montagne et Heitz, 2009]. La figure 1.2 illustre une image radiologique.



FIGURE 1.2 – Image radiologique

les propriétés de base de l'image radiologique sont décrites dans la (Table 1.1).

TABLE 1.1 – Propriétés de l'image radiologique

Principe :	les rayons X permettent d'obtenir des clichés en deux dimensions des structures osseuses et articulaires
Dispositif d'acquisition :	Impression photographique d'un film par le faisceau de rayons X
Formation de l'image :	Obtention par projection, numérisation des images
Type d'images :	Image en Niveau de gris.
Domaine d'application :	L'orthopédie, la rhumatologie et l'orthodontie
Avantage :	Examen rapide.

Scanner Le scanner est une technique d'imagerie médicale qui consiste à mesurer l'absorption des rayons X par les tissus puis, par traitement informatique, à numériser et enfin reconstruire des images 2D ou 3D des structures anatomiques. La figure 1.3 illustre une image médicale issu d'un scanner.



FIGURE 1.3 – Image issue d'un scanner

Les propriétés de base de l'image scanner sont décrites dans la (Table 1.2).

TABLE 1.2 – Propriétés de l'image scanner

Principe :	Le scanner explore un volume du corps qui permet d'établir des images tridimensionnelles des organes ou des tissus
Dispositif d'acquisition :	Rayons X envoyés par un tube et reçus par un détecteur.
Type d'image :	Imagerie en coupes.
Domaine d'application :	Lésions osseuses, pathologies vasculaires.
Avantage :	Le scanner permet de visualiser une modification de volume ou une anomalie de structure(tumeur) il a révolutionné la neurologie en offrant la possibilité de voir le cerveau humain
Limite ;	Il ne permet pas d'en préciser la nature (inflammation, cancer).

IRM L'imagerie par Résonance Magnétique (IRM) est une technique d'imagerie médicale permettant d'obtenir des vues 2D ou 3D de l'intérieur du corps de façon non-invasive avec une résolution relativement élevée. La figure 1.4 illustre une image IRM. Les propriétés de base de l'image IRM sont décrites dans la (Table 1.3).

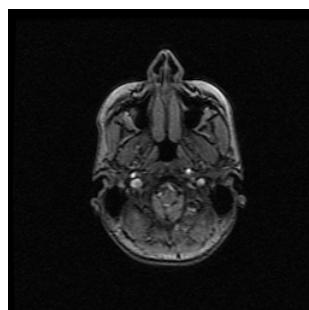


FIGURE 1.4 – Image IRM

TABLE 1.3 – Propriétés de l'image IRM

Principe :	Permet de trouver la structure anatomique de tout volume du corps, en particulier des "tissus mous" tels que le cerveau, la moelle épinière, les muscles ou les tendons.
Dispositif d'acquisition :	Ondes permettent de créer des champs magnétiques.
Type d'image :	Image en couleur Image en coupe ou 3D.
Caractéristiques :	Temps d'acquisition : 1 à 20 ms .
Domaine d'application :	Tous les domaines.
Avantage :	l'IRM permet de mieux définir la nature des lésions observées Comme elle permet aussi de suivre l'activité d'un organe tel le cerveau ,bon contraste pour les tissus mous

1.3.2 Numérisation

La numérisation est le procédé permettant la construction d'une représentation discrète d'un objet du monde réel. Cela signifie que l'objet sera représenté par un nombre fini de nombres entiers et bornés. Dans son sens le plus répandu, la numérisation est la conversion d'un signal (vidéo, image, audio, caractère d'imprimerie, impulsion, etc.) en une suite de nombres représentant cet objet sous forme de données pouvant être traitées par un dispositif informatique ou d'électronique numérique [Répter, 2000].

L'échantillonnage

L'échantillonnage consiste à transmettre un signal en capturant des valeurs à intervalles réguliers. Il produit une suite de valeurs discrètes.[Electropedia, 2004]

Quantification

En sciences, la quantification consiste à attribuer une valeur à une grandeur physique, prise dans un ensemble fini de valeurs, souvent dans le but de numériser une information analogique pour la traiter par ordinateur.

1.3.3 Prétraitement

Le prétraitement concerne les images acquises. Ces images ne peuvent échapper aux effets de dégradations due essentiellement aux phénomènes physiques tels que : la diffraction (dérivation) du système optique. Et le flou du mouvement de l'image durant son acquisition [Bendiab, 2010].

Filtrage numérique

Pour améliorer la qualité de l'image, on doit éliminer les effets des bruits en lui faisant subir un traitement appelé filtrage. Le principe du filtrage consiste à modifier la distribution fréquentielle des composants d'un signal selon des spécifications données [Bendiab, 2011]. La figure 1.5 à gauche illustrant une image avant filtrage et à droite une image après filtrage.



FIGURE 1.5 – Image avant filtrage et image après filtrage

Modification d'histogramme

En traitement d'images, l'égalisation d'histogramme est une méthode d'ajustement du contraste d'une image numérique qui utilise l'histogramme. La l'égalisation d'histogramme permet de mieux répartir les intensités sur l'ensemble de la plage de valeurs possibles, en « étalant » l'histogramme. L'égalisation est intéressante pour les images dont la totalité, ou seulement une partie, est de faible contraste (l'ensemble des pixels sont d'intensité proches) [Gonzalez, 2008]. La figure 1.6 une image avant et après linéarisation.

1.3.4 Traitement numérique d'image

Les grands bouleversement de l'imagerie médicale moderne proviennent certe d'une part de l'acquisition des données mais aussi de leurs exploitation. Les principaux outils d'exploitation d'images sont la segmentation d'images, le recalage d'image et l'indexation d'image.

Segmentation d'images

La segmentation d'image est le processus qui découpe en éléments (ensembles de pixels). Le but de ce processus est de simplifier la représentation de l'image pour la rendre plus facile à analyser et à interpréter [Talbi, 2009].

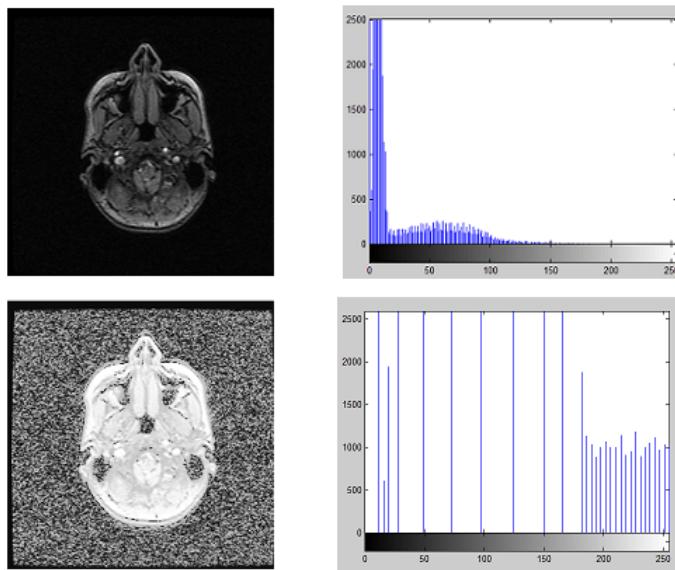


FIGURE 1.6 – Modification de l'histogramme

La segmentation est une étape primordiale en traitement d'image. A ce jour il existe de nombreuses méthodes de segmentation que l'on peut regrouper en trois principales classes.

1. Segmentation basée sur les régions
2. Segmentation basée sur les contour
3. Segmentation basée sur la coopération entre les deux premières méthodes

La figure 1.7 illustre l'opération de segmentation d'images. Nous détaillerons dans le chapitre suivant l'opération de segmentation d'images médiales.

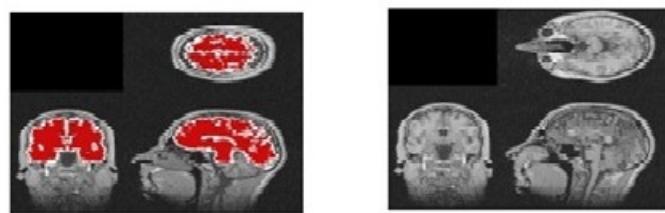


FIGURE 1.7 – L'opération de segmentation

Recalage

Le recalage est une tâche fondamentale pour l'analyse des images , Le recalage d'images fait référence à la référence à la procédure ayant pour but de trouver une transformation spatial reliant deux ou plusieurs images [Brown, 1992].

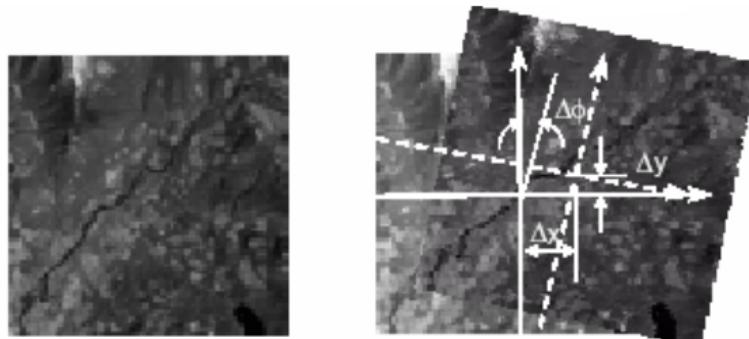


FIGURE 1.8 – Recalage d'images

Visualisation

Tout système de traitement d'image est doté d'un dispositif de visualisation qui permet l'affichage des images [Bendiab, 2010].

1.4 Conclusion

Au cours de ce chapitre on a présenté le concept de l'imagerie médicale et ces principales modalités. Les différents techniques d'imagerie médicales sont complémentaires et leurs progrès doivent énormément au domaine de traitement de l'image. En effet l'imagerie médicale a révolutionné la médecine et ses progrès permettent d'aller plus loin dans le diagnostic des pathologies. Dans le prochain chapitre on va voir l'opération de la segmentation d'images en détail.

Chapitre 2

Segmentation d'images

“Les machines un jour pourront résoudre tous les problèmes, mais jamais aucune d'entre elles ne pourra en poser un !” - Albert Einstein

Sommaire

2.1	Introduction	20
2.2	Segmentation d'images	20
2.3	Techniques de segmentation d'images	21
2.3.1	Approches basées contour	21
2.3.2	Approches basées région	23
2.3.3	Approche coopérative	26
2.4	Segmentation par seuillage	26
2.4.1	Définition du seuillage	27
2.4.2	Méthodes de seuillage globales	27
2.4.3	Méthodes de seuillage local ou adaptatives	29
2.5	Conclusion	30

2.1 Introduction

L'analyse et l'interprétation des images sont actuellement très utilisées dans différents domaines allant de l'aide au diagnostic, en médecine, à la navigation autonome des véhicules en passant par la reconnaissance des visages, des empreintes, de l'iris ; le contrôle de qualité des produits manufacturables (bois, tissus, verre, pièces mécaniques), etc.

Dans un système d'analyse d'images, la segmentation apparaît comme l'étape la plus importante car toutes les tâches ultérieures comme l'extraction de primitives, la détection d'une position d'un objet, ou la reconnaissance d'un objet dépendent fortement de la qualité de la segmentation. Le but de la segmentation d'image est de faciliter l'extraction des éléments qui la composent. Pour cela, plusieurs approches ont été proposées.

Voici un schéma illustrant les différentes approches de la segmentation d'images.

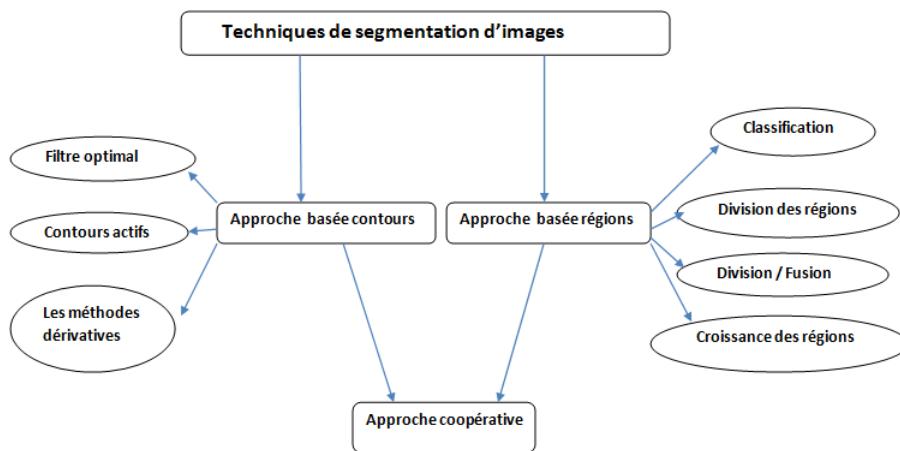


FIGURE 2.1 – Techniques de la segmentation d'images

Nous présenterons dans ce chapitre une brève revue de ces approches de segmentation d'images puis nous détaillerons quelques méthodes de seuillage d'histogrammes qu'on va utiliser dans notre travail .

2.2 Segmentation d'images

Définition 2.1 (Segmentation d'image) *La segmentation permet d'isoler dans l'image les objets sur lesquels doit porter l'analyse ou de séparer les régions d'intérêt de son fond. Autrement dit, elle permet de partitionner l'image en zones homogènes ayant des caractéristiques (niveau de gris, couleur, texture) identiques où une zone peut correspondre à un objet ou une partie d'un objet.*

Mathématiquement, la segmentation est définie par Zucker [1976] de la manière suivante :

Segmenter une image I en n régions, revient à la partitionner en n sous ensembles $R_1, R_2, \dots; R_n$ tels que :

1. $I = \bigcup R_i$
2. R_i est constituée de pixels connexes pour tout i .
3. $p(R_i) = \text{Vrai}$ pour tout i .
4. $p(R_i \cup R_j) = \text{faux}$ pour tous i, j , R_i, R_j étant adjacentes dans I .

La première condition indique que chaque pixel de l'image doit appartenir à une région R_i et l'union de toutes les régions forme l'image entière. La deuxième condition est relative à la structure des régions, elle définit une région comme un ensemble de pixels qui doivent être connexes. La troisième condition exprime que chaque région doit respecter un prédictat d'uniformité. La dernière condition implique la non réalisation de ce même prédictat pour la réunion de deux régions adjacentes.

L'opération de segmentation est souvent confrontée aux problèmes d'ambiguïtés et du bruit qui affectent certains pixels de l'image. C'est la raison pour laquelle, plusieurs techniques de segmentation ont été proposées. Dans ce qui suit on va découvrir les principales techniques de la segmentation d'images. Dans ce qui suit on va voir les différentes techniques de segmentation d'images. [Abdelli, 2011]

2.3 Techniques de segmentation d'images

On peut distinguer trois grandes approches de segmentation d'images : segmentation à base de contours, segmentation à base de régions et segmentation hybride.

2.3.1 Approches basées contour

Il s'agit dans cette approche de rechercher les contours qui délimitent les régions homogènes de l'image. Un contour est un ensemble de pixels formant une frontière entre deux ou plusieurs régions voisines, il est défini par une variation "rapide" du caractère niveau de gris, couleur ou texture. La recherche des contours dans une image a été étudiée depuis l'origine des travaux sur l'imagerie numérique.

Il existe plusieurs méthodes de segmentation basées sur l'approche contour qu'on peut regrouper en trois sous catégories : les méthodes dérivatives par filtrage optimal et les contours actifs.

Les méthodes dérivatives sont les plus utilisées dans la détection des transitions d'intensités. Elles consistent à calculer la dérivée en chaque point de l'image afin de mettre en évidence les variations de niveau de gris. On peut classer les méthodes dérivatives en deux groupes selon qu'on utilise la dérivée première (approche gradient) ou la dérivée seconde (approche Laplacien). L'allure

de la dérivée première et de la dérivée seconde d'un signal de type « saut d'amplitude », qui peut correspondre à une variation locale et dans une seule direction du niveau de gris, est donnée par la figure suivante.

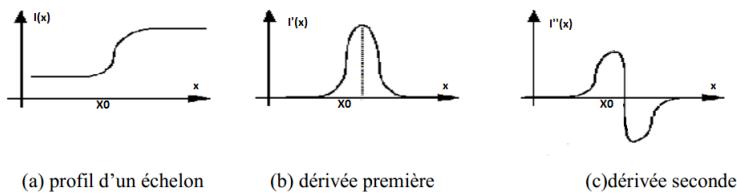


FIGURE 2.2 – Dérivées première et seconde d'un contour de type “saut d'amplitude”

Une zone de transition dans le signal correspond à un maximum (ou un minimum) local de la dérivée première et un passage par zéro de la dérivée seconde. L'identification d'une zone de transition dans l'image peut être ainsi faite par seuillage de la norme de sa dérivée première ou du passage par zéro de sa dérivée seconde. Parmi les opérateurs gradient les plus connus, on trouve les masques de Roberts [1965], de Prewitt [1970], de Sobel [1978] , de Kirsch [1971].

Les méthodes dérivatives sont faciles à implémenter, rapides en termes de temps de calcul et donnent généralement de bons résultats sur des images non bruitées. Elles restent cependant sensibles aux petites variations non significatives des niveaux de gris (bruit) et produisent des contours discontinus qu'il faut ensuite fermer. Pour améliorer la qualité des méthodes dérivatives et pallier aux problèmes de précision et de localisation des contours, des opérateurs de dérivation avec filtrages optimaux ont été introduits.

Un filtre optimal est un filtre déivateur qui permet de détecter des contours en respectant les 3 critères suivants [Cocquerez, 1995] :

- **Une bonne détection** : l'opérateur donne une réponse au voisinage d'un contour.
- **Une bonne localisation** : optimisation de la précision avec laquelle le contour est détecté.
- **Unicité de la réponse** : le contour doit provoquer une réponse unique de l'opérateur.

Plusieurs filtres optimaux sont apparus dans la littérature. Parmi eux, on trouve les filtres de Canny [1986], de Deriche [1987] et Deriche [1990] et celui de Shen et Castan [1986], Castan *et al.* [1989], Shen et Castan [1992].

Quant aux contours actifs (Snakes en anglais), ils sont plus récents, ils ont été introduits par Kass *et al.* [1988] et sont définis comme des courbes capable de se déformer et de se déplacer pour épouser la forme des objets constituant l'image [Azerradj et Kessoum, 2007]. L'idée de cette méthode est de déplacer les points de la courbe pour les rapprocher des zones de fort gradient tout en conservant des caractéristiques comme la courbure du contour ou la répartition des points sur le contour ou d'autres contraintes liées à la disposition des points [Chilali, 2006].

Les contours actifs permettent de détecter des contours fermés mais restent sensibles, à l'instant des méthodes dérivatives, aux variations locales des niveaux de gris. La figure 2.3.2 illustre l'évolution de contour actif avec : $T(\tau)$ est le contour initial qui peut être défini manuellement et v la vitesse d'évolution de la courbe.

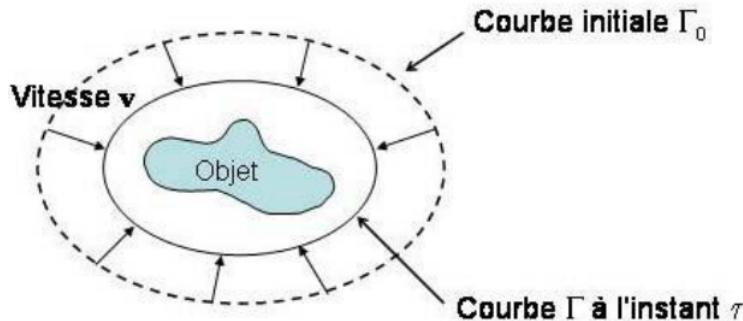


FIGURE 2.3 – Évolution du contour actif $T(\tau)$ avec la vitesse v vers l'objet d'intérêt

2.3.2 Approches basées région

Contrairement à la segmentation d'images par l'approche contour, la segmentation par régions consiste à décomposer l'image en régions homogènes [Gonzalez et Woods, 1992]. Ces régions sont composées d'ensembles des pixels connexes possédant des propriétés au sens d'un prédictat d'homogénéité donné. On distingue les méthodes qui tiennent compte de la connexité des pixels et celles qui n'utilisent pas cette information.

Dans le premier cas, en plus de l'information niveau de gris, l'information spatiale est automatiquement intégrée dans le processus de segmentation [Pavlidis et Liow, 1990], le contrôle géométrique peut être aussi utilisé pour contrôler ce processus. Le problème fondamental associé à cette approche est lié à la définition du critère d'homogénéité utilisé dans le processus de segmentation de l'image. On distingue quatre types de méthodes : croissance des régions, division des régions, division/fusion et segmentation d'images par classification.

1. Croissance des régions :

Cette approche consiste à choisir initialement un ensemble de pixels pour les considérer comme des germes ou noyaux des régions à partir desquels la croissance des régions s'effectuera. Chaque région doit respecter un critère d'uniformité ou d'homogénéité défini par exemple par la variance des niveaux de gris.

La croissance des régions s'effectue par agrégation de nouveaux pixels aux germes initiaux. Elle consiste à fusionner successivement aux régions les pixels voisins qui sont similaires à condition que les régions fusionnées continuent à vérifier le critère d'uniformité. Notant que des régions adjacentes peuvent être fusionnées si leur fusion vérifie le critère

d'uniformité et que de nouveaux germes peuvent être créés dans les régions qu'elles ne pouvant pas être fusionnées avec les régions existantes [Boucher et Garbay, 1998].

2. Division des régions :

Les modèles de division de régions consistent à diviser l'image d'une manière récursive tant qu'un critère d'homogénéité sur les régions n'est pas vérifié. Initialement, l'image est divisée en zones. Chaque zone ainsi créée est elle-même divisée si elle ne vérifie pas le critère d'homogénéité. Ce processus de division se poursuit pour toutes les zones nouvellement créées et s'arrête lorsque toutes les zones sont homogènes ou bien leurs tailles sont en dessous d'un seuil fixé préalablement. La division de l'image est généralement représentée par une structure géométrique bien particulière telle que la structure en arbre quaternaire « quadtree » ou la structure de Voronoï. La figure 2.4 montre le principe de la segmentation par division suivant la structure d'arbre quaternaire.

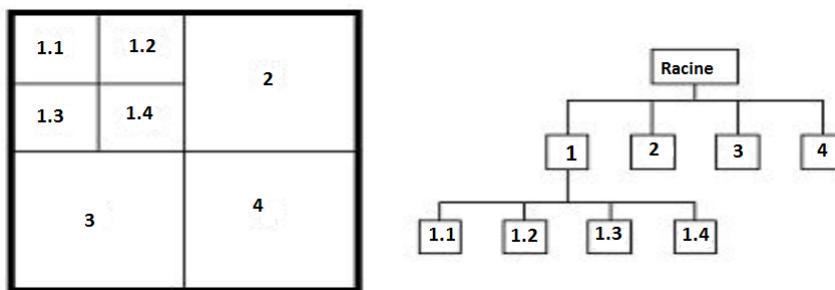


FIGURE 2.4 – Principe de la segmentation par division des régions (Structure quaternaire)

Le critère d'homogénéité peut être évalué par la variance des niveaux de gris ou peut être défini à partir de l'allure de l'histogramme de niveau de gris. Par exemple, dans [Ohlander *et al.*, 1979], l'histogramme de chaque région est analysé, s'il est unimodal (région homogène), la région reste inchangée, sinon elle est divisée. La division prend fin quand toutes les régions ont un histogramme unimodal.

3. Division/fusion :

Ces méthodes combinent successivement une méthode de division de l'image en des petites régions homogènes comme celle décrite précédemment et une méthode de fusion des régions connexes et similaires au sens d'un prédictat de regroupement. Le processus de segmentation utilise la structure pyramidale telle que les arbres quaternaires. Au cours de la phase de fusion, on progresse de manière récursive vers le haut de l'arbre en fusionnant les régions qui forment au niveau supérieur une région homogène.

Horowitz et Pavlidis [1976], sont les premiers à avoir proposé une telle approche de segmentation à partir de laquelle de nouvelles variantes sont apparues dans la littérature [Beveridge *et al.*, 1989; Strasters et Gerbrands, 1991; Gonzalez et Woods, 1992].

La figure 2.5 illustre le principe de la division/fusion. Les résultats dépendent de l'ordre dans lequel les régions sont examinées pour être éventuellement regroupées.

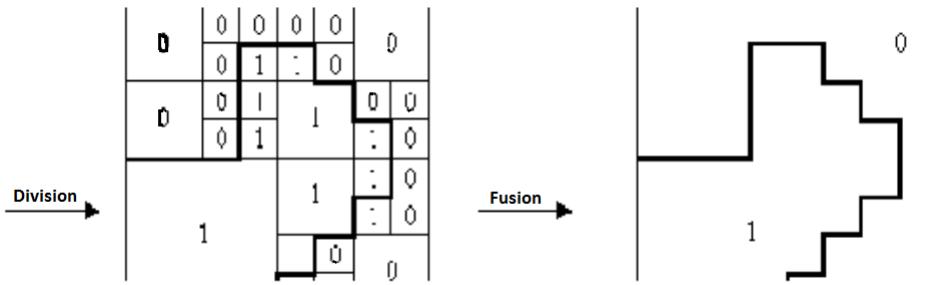


FIGURE 2.5 – Principe de la segmentation par division-fusion.

4. Segmentation d'images par classification :

La classification est l'une des procédures les plus utilisées en analyse des données, elle permet de partitionner un ensemble de données multidimensionnelles en un ensemble de K classes disjointes. En segmentation d'images, les données multidimensionnelles correspondent aux pixels de l'image où chaque pixel est caractérisé par un vecteur d'attributs tels que les attributs de texture ou les composantes couleurs. Chaque classe regroupe des pixels ayant des vecteurs de caractéristiques aussi similaires que possible. Sachant que les pixels de deux classes distinctes ont des attributs très différents [Jain *et al.*, 1999].

Contrairement aux méthodes précédentes, les techniques de segmentation par classification ne prennent pas en compte la disposition spatiale des pixels et ne considèrent que le vecteur de caractéristiques. Elles identifient les classes de pixels présentes dans l'image et affectent à chaque pixel une étiquette indiquant la classe à laquelle il appartient. Ainsi les pixels appartenant à une classe peuvent former plusieurs régions non adjacentes dans l'image mais partageant les mêmes propriétés. Une segmentation en régions n'est obtenue qu'après analyse de la connexité des pixels dans l'image étiquetée [Abdelli, 2011].

On trouve dans la littérature une multitude de méthodes de classification parmi lesquelles on peut citer, l'algorithme K-means et sa version floue fuzzy-C-means, l'algorithme d'estimation-maximisation (EM), l'algorithme mean-shift, etc.

Lorsqu'on considère le niveau de gris comme la seule caractéristique pour représenter un pixel, la segmentation par classification peut être abordée par des techniques de seuillage qui seront présentées en détail dans les sections suivantes et dans le prochain chapitre.

2.3.3 Approche coopérative

L'approche contour et l'approche région sont en fait des approches duales, on peut alors les combiner afin d'aboutir à une segmentation plus efficace. Comme, il est possible de combiner plusieurs techniques d'une même approche. L'intérêt de faire coopérer plusieurs approches permet de définir automatiquement des ensembles de contraintes pour mieux guider le processus de segmentation.

Dans une approche coopérative, la stratégie de résolution peut être séquentielle, c'est-à-dire les résultats d'une approche sont exploités successivement pour en guider une autre, ou bien itérative. De plus, des principes de fusion d'information peuvent être exploités pour renforcer des critères de décision et influencer les choix de segmentation [Laurence, 1999]. Dans le cadre de la classification, par exemple, la nécessité de définir une région d'intérêt est fondamentale pour réduire le nombre de classes à classifier. De même, le choix d'une stratégie de résolution, lorsqu'elle n'est pas guidée par un ensemble de connaissance à priori n'est pas évident.

Il existe de multiples façons d'envisager la coopération contour-région [Pavlidis et Liow, 1990]. Le terme de «coopération contour-région» signifie l'utilisation des informations des contours pour autoriser ou non la fusion de deux régions ou la division d'une région ; réciproquement, il peut signifier l'utilisation d'informations sur les régions pour autoriser ou non la fusion de deux contours ou la croissance d'un contour. Il existe aussi une coopération région-région quand deux régions coopèrent pour fusionner ou une coopération contour-contour quand deux contours coopèrent pour se connecter. Dans tous les cas, il existe de multiples critères possibles (par exemple, écart des niveaux de gris entre deux régions, pourcentage de points de contours à la frontière de deux régions, etc.) pour autoriser la coopération ainsi que de multiples manières permettant de les combiner [Laurence, 1999].

2.4 Segmentation par seuillage

La segmentation par seuillage d'histogramme constitue un cas particulier de la segmentation par classification. Elle permet de répartir les pixels en classes en fonction de leurs niveaux de gris. Les classes sont alors délimitées par des seuils.

2.4.1 Définition du seuillage

soit $\{0, 1, 2, \dots, L-1\}$ l'ensemble des niveaux de gris d'une image, $i(x,y)$ a luminance (niveau de gris) d'un pixel de coordonnées (x,y) , $L - 1$ étant le niveau de gris maximal. (Souvent $L = 256$). La segmentation par seuillage est une opération qui consiste à répartir les pixels en K classes (C_1, C_2, \dots, C_n) à partir d'un ensemble de seuils $T = \{t_1, t_2, \dots, t_{k-1}\}$. Par convenance, on utilise deux autres seuils, $t_0=0$ et $t_k = L - 1$. Un pixel de niveau de gris $i(x,y)$ est affecté à la classe C_K si $t_k \leq i(x,y) \leq t_{k+1}$ avec $k=0,1,2,\dots,K-1$.

Pour une image comportant des objets clairs sur un fond sombre, le seuillage se résume à choisir un niveau de gris t (un seul seuil) et à affecter à chaque pixel de l'image le label *objet* ou *fond* selon le test suivant :

- Si $i(x,y) < t$, alors le pixel est étiqueté «fond», sinon le pixel est étiqueté «objet». Dans ce cas, on parle du seuillage tout court (*bilevel thresholding*) et l'image segmentée ainsi obtenue est appelée image binaire.
- Si par contre, le nombre de seuils recherchés est supérieur à 1, on parle de *multiseuillage* ou *multi-level thresholding*.

Plusieurs techniques ont été proposées pour le calcul d'un seul seuil puis étendues au problème du multiseuillage. Cependant, en pratique cette extension peut engendrer des temps de calculs prohibitifs. En effet, la recherche rapide d'un seul seuil d'une manière exhaustive est tout à fait possible. Cependant cette recherche exhaustive devient prohibitive lorsque le nombre de seuils augmente. Chang *et al.* [1995] notent que la complexité des calculs augmente exponentiellement lorsque le nombre de seuils augmente. Pour K classes, L étant le niveau de gris maximal, le nombre d'opérations nécessaires pour le calcul de $K-1$ seuils est donné par :

$$NO = \frac{(L+K)!}{L!K!} \quad (2.1)$$

Les méthodes de seuillage peuvent être reparties en deux catégories selon qu'on définit un même seuil pour tous les pixels de l'image (seuillage globale) ou un seuil pour chaque pixel (seuillage local ou adaptatif).

2.4.2 Méthodes de seuillage globales

Les méthodes de seuillage globales reposent sur l'exploitation de l'histogramme de toute l'image. L'histogramme est une courbe monodimensionnelle qui caractérise la distribution des niveaux de gris, il est décrit par une fonction monovariable discrète $h(i)$ ou $p(i)$ qui représente respectivement

la fréquence ou la probabilité d'apparition du niveau de gris i , tel que :

$$p(i) = \frac{h(i)}{N} \quad (2.2)$$

$h(i)$ étant le nombre de pixels ayant le niveau de gris i et N est le nombre total de pixels dans l'image.

A partir de l'allure de l'histogramme, on peut déduire le nombre de classes ainsi que la position relative des seuils figure 2.6. L'histogramme est unimodal, s'il est formé d'un seul pic représentant les pixels de l'objet ou ceux du fond. Il est bimodal s'il est caractérisé par deux modes séparés par une vallée, il indique l'existence d'un objet sur un fond.

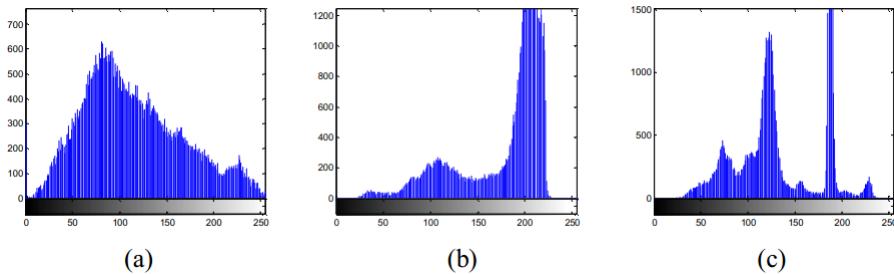


FIGURE 2.6 – Allures idéales d'un histogramme. (a) : unimodal, (b) : bimodal et (c) multimodal

L'histogramme multimodal comporte plus de deux modes séparés par des vallées, il indique la présence de plusieurs classes dans image (chaque mode correspond à une classe).

Les seuils doivent être localisés dans les vallées. En pratique, il est rare de trouver un histogramme qui présente des modes bien distincts. En effet, la plupart des images présentent des histogrammes bruités caractérisés par des modes non discernables.

Il existe toute une panoplie de méthodes de seuillages globales qu'on peut repartir en deux catégories : méthodes paramétriques et méthodes non paramétriques.

Méthodes paramétriques

Les méthodes paramétriques de segmentation d'image supposent que les différents classes de l'image suivent une certaine fonction de densité de probabilité. Généralement, ces fonctions de densités de probabilité (f_{dp}) sont supposées suivre un modèle gaussien. Partant d'une approximation de l'histogramme de l'image par une combinaison linéaire gaussienne, les seuils optimaux sont à l'intersection de ces dernières [Hafnia, 2012].

Méthodes non paramétriques

Les méthodes non paramétriques de seuillage permettent de trouver les seuils optimaux sans tenir compte d'aucune hypothèse sur la forme de l'histogramme. Ces méthodes sont très nombreuses,

elles constituent la grande majorité des méthodes de seuillage et sont généralement basées sur l'optimisation d'une fonction objectif. Nous présenterons dans ce qui suit deux d'entre elles qui sont la méthode Kapur et la méthode Otsu.

- **Méthode d'Otsu :**

Cette méthodes est considérée comme la méthode de référence dans le domaine de seuillage d'histogrammes. Dans cette méthode, l'opération de seuillage est vue comme une séparation (un partitionnement) des pixels d'une image en deux classes C_1 (fond) et C_2 (objet) à partir d'un seuil t . La classe *fond* regroupe tous les pixels ayant un niveau de gris inférieur au seuil t alors que la classe *objet* contient tous les pixels de niveau de gris supérieur à t [Otsu, 1979].

- **Méthode de Kapur :** La méthode de Kapur [Kapur *et al.*, 1985] est basée sur le principe de maximisation de l'entropie de Shannon. Elle suppose que les classes « objet » et « fond » possèdent deux densités de probabilité indépendantes.

On va découvrir le fonctionnement de ces méthodes en détail dans le chapitre de la contribution.

2.4.3 Méthodes de seuillage local ou adaptatives

Il existe des images pour lesquelles il est difficile d'effectuer une bonne binarisation au moyen d'un seul seuil, si celui-ci est le même pour chaque point de l'image. Ceci peut être dû à une non uniformité de l'éclairage de l'image ou au fait que les différents objets qui composent l'image ont des dynamiques de luminances différentes. Pour cela, les méthodes de binarisation locales sont mieux adaptées Abdelli [2011].

A l'inverse des méthodes globales qui ne considèrent que la valeur du pixel, les méthodes locales prennent en considération la valeur des pixels voisins pour le calcul des seuils. Deux stratégies sont souvent employées. La première consiste à diviser, en premier lieu, l'image en fenêtres non chevauchantes [Chehdi et Coquin, 1991]. Dans un deuxième temps, un seuil est déterminé dans chaque fenêtre selon la nature de l'histogramme local. Un seuil égal à zéro est affecté à la fenêtre possédant un histogramme unimodal tandis qu'une procédure de seuillage est appliquée pour déterminer un seul seuil dans le cas d'un histogramme bimodal ou multimodal. Les seuils nuls sont finalement remplacés par les autres seuils non nuls par interpolation ou par moyennage [Nakib, 2007].

2.5 Conclusion

Nous avons présenté dans ce chapitre les notions de base sur la segmentation d'images. Il ressort que le domaine de la segmentation est tellement riche et diversifié qu'il est difficile de donner une étude exhaustive. Celles ci se déclinent en trois grandes approches. Nous nous sommes particulièrement intéressés à l'approche région dans laquelle les méthodes basées sur la classification et plus précisément de seuillage ont attiré notre attention. Les méthodes de seuillage d'histogramme sont nombreuses, nous avons détaillé que quelques une d'entres elles, celles que nous allons appliqué dans notre travail. Dans le prochain chapitre les systèmes complexes et leurs caractéristiques ainsi que les modèles artificiels pour ces systèmes seront présentés.

Chapitre 3

Systèmes Complexes Adaptatifs

*“The study of complex systems is the study of the world as it is,
not as we want it to be.”* - Brenda Zimmerman, Edgeware

Sommaire

3.1	Introduction	33
3.2	Historique	33
3.3	Système complexe adaptatif : définition	34
3.3.1	Systèmes complexes	34
3.3.2	Systèmes complexes adaptatifs	34
3.4	Propriétés des systèmes complexes adaptatifs	35
3.4.1	Complexité	35
3.4.2	Émergence	35
3.4.3	Auto-organisation et systèmes auto-organisés	36
3.4.4	Adaptation	36
3.4.5	Apprentissage	37
3.5	Optimisation	37
3.5.1	Définitions	37
3.6	Modèles artificiels pour les systèmes complexes adaptatifs (SACs)	38
3.6.1	Classification des modèles artificiels pour les SACs	38
3.6.2	Algorithmes évolutionnaires	39
3.6.3	Algorithmes d'intelligence par essaim	43
3.7	Conclusion	48

3.1 Introduction

De nombreux systèmes sont constitués d'un grand nombre d'entités en interaction. On les qualifie de systèmes complexes lorsque même si les interactions entre ces entités sont bien comprises, il émerge un comportement global qui n'était pas évident à partir des règles d'interaction.

Donc, un système est informellement dit complexe si le résultat final de son comportement n'est pas prédictable directement en connaissant les règles. Ce n'est pas une limite due à la longueur des calculs (ce point est le champ d'étude de la théorie de la complexité algorithmique), ni d'un comportement aléatoire, ou de la sensibilité aux conditions initiales (qui est étudié par la théorie du chaos), même si l'étude de ces propriétés sur un système complexe est intéressante. Cette limitation vient de l'impossibilité de modéliser le système par des équations solvables et prédictives. Ce qui est primordial est le nombre de paramètres, et le fait que chacun d'entre eux peut avoir une influence essentielle sur le comportement du modèle.

Dans ce chapitre on va définir ces systèmes, leurs concepts de base tel que l'adaptation, la complexité, l'émergence, l'apprentissage et l'auto-organisation, et on termine par aborder les modèles artificiels pour les systèmes complexes adaptatifs.

3.2 Historique

Historiquement, le domaine des systèmes complexes a évolué selon les trois périodes suivantes :

- **Durant les années 40 et 60 :** l'apparition de la science de la complexité due à l'insatisfaction de plusieurs chercheurs des outils offerts par la science réductionniste pour la modélisation des phénomènes rencontrés dans leurs domaines de recherche [Draa, 2011].
- **Durant les années 70 et 80 :** les mathématiciens et les physiciens du non-linéaire et de la mécanique statistique se sont intéressés aux phénomènes d'auto-organisation en généralisant aux systèmes biologiques l'idée que les propriétés globales émergentes de ce type de systèmes ne pouvaient être obtenues en effectuant un moyennage des propriétés des éléments en interaction, comme le font les méthodes classiques de la physique [Draa, 2011] [Henon et Weisbuch, 2003]
- **Durant les années 80 et 90 :** l'apparition des approches inspirées de la nature a très bien contribué à la compréhension et la mise en œuvre des systèmes complexes. Parmi ces approches, on citep : les systèmes multi agents, les approches basées essaims et les systèmes immunitaires artificiels [Henon et Weisbuch, 2003] [Ianik, 1995] [Langton, 1990] .

3.3 Système complexe adaptatif : définition

La définition des systèmes complexes adaptatifs se diversifie selon le contexte d'utilisation, cela est dû à la nature multidisciplinaire du domaine des systèmes complexes. Dans cette section, nous allons introduire quelques définitions des systèmes complexes adaptatifs en se concentrant sur le domaine informatique.

3.3.1 Systèmes complexes

Définition 3.1 (Système complexe) *Un système complexe peut être vu comme un système dynamique composé de plusieurs systèmes simples et de parties interagissant d'une manière non linéaire [Ilachinski, 2004].*

Définition 3.2 (Système complexe) *Un système complexe est un système composé d'un ensemble homogènes ou hétérogènes, interagissant entre eux de façon non linéaire (interactions rétroactives), mettant ainsi en œuvre une dynamique permettant à l'ensemble du système d'exister comme un tout, différent de la simple somme de ses composants [Hassas, 2003].*

Dans un système complexe on distingue deux niveaux : niveau microscopique et le niveau macroscopique.

1. Un niveau microscopique : représentant le niveau des composants, avec des propriétés locales à chacun d'eux.
2. Un niveau macroscopique : représentant l'ensemble du système, avec des propriétés nouvelles, que l'on ne trouve dans aucun des composants pris individuellement. On parle alors d'émergence de nouvelles propriétés.

3.3.2 Systèmes complexes adaptatifs

Un système complexe adaptatif est un système complexe dont les parties peuvent évoluer et s'adapter à un environnement variable [Draa, 2011; Ilachinski, 2004].

Définition 3.3 (Système complexe adaptatif) *Selon Anderson, un système complexe adaptatif est une collection d'agents hétérogènes et indépendants agissant d'une manière adaptative chacun avec l'autre et chacun avec son environnement dans le but de créer une entité distincte de haut niveau [Anderson, 1999].*

Définition 3.4 (Système complexe adaptatif) *Les systèmes complexes adaptatifs sont des systèmes composés d'agents interagissant les uns avec les autres qui répondent au stimulus [de leur environnement] sous forme d'un comportement pouvant être défini par des règles. Les agents s'adaptent par le changement de leurs règles de comportement résultant du cumul d'expérience. Ils peuvent être agrégés en méta-agents dont le comportement peut être émergent, i.e. un comportement ne pouvant pas être déterminé par l'analyse d'agents de bas niveau [Holland, 1996; Draa, 2011].*

3.4 Propriétés des systèmes complexes adaptatifs

Dans cette section ,on va introduire les propriétés les plus pertinentes des systèmes complexes adaptatifs qui sont la complexité, l'émergence, l'auto-organisation, l'adaptation, l'apprentissage.

3.4.1 Complexité

Définition 3.5 (Complexité) *La complexité est la propriété d'un modèle qui rend difficile la formulation de son comportement global même s'il y a assez d'information pour décrire ses parties et les relations entre elles [Draa, 2011]; [Edmonds, 2000].*

La complexité dans un CAS, comme dans une système complexe, est due aux interactions locales. Elle résulte principalement de la diversité des agents du système et du grand nombre de connexions entre ces agents. Selon Morin (Sociologue français, qui a développé un esprit interdisciplinaire dans le cadre de la théorie de la complexité) : “Penser en termes de complexité signifie reconnaître le *Principe Holistique* selon lequel l'unité de l'organisme n'est pas réductible à la somme de ses parties constitutives. Morin [2008] propose la formulation suivante pour la description d'un système complexe :

$$\text{Système} = \sum \text{parties} + \sum \text{relations} - \text{entre-parties}$$

3.4.2 Émergence

Définition 3.6 (Émergence) *La propriété d'émergence réfère à l'apparition inattendue de patterns spatiaux et temporels dans la structure et la dynamique du système. Ceci est équivalent au fait que le comportement du système n'est pas déduit des comportements de ses parties[Parrott, 2002].*

Selon Fromm il existe quatre types de base de l'émergence. Dans le premier type, aucun ‘feedback’ existe au niveau du système, il y en a que des ‘feedforwards’. La propriété majeur de l'émergence de type 2 est l'existence de feedbacks simples, soit positifs ou négatifs. Les feedbacks

multiples, l'apprentissage et l'adaptation sont des points clé dans le troisième type de l'émergence. On trouve ce type d'émergence dans les CASs intelligents ayant une interaction intensive avec leurs environnements externes. Finalement, le quatrième type d'émergence est caractérisé par le multi-niveau et la diversité des patterns créés 3.1 [Draa, 2011].

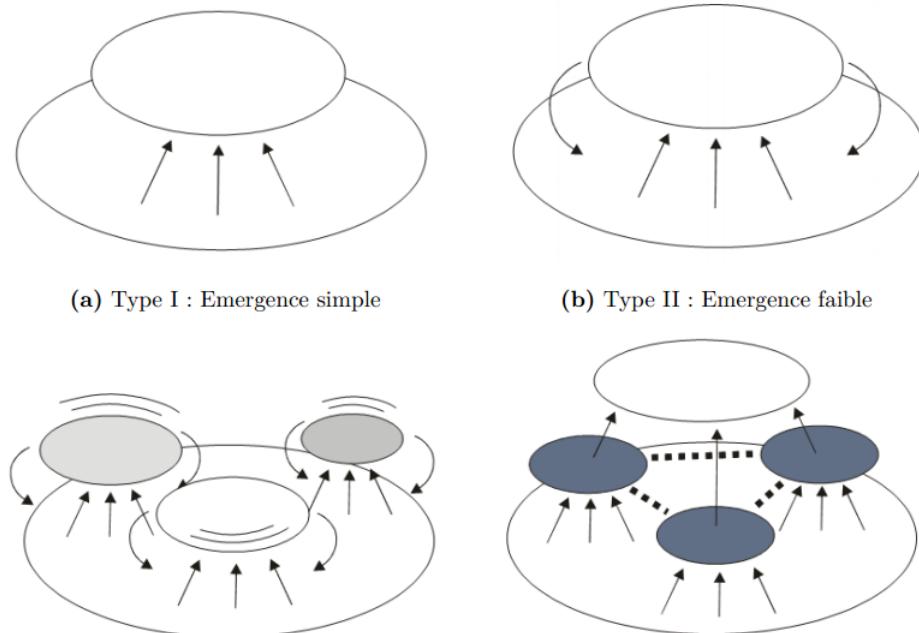


FIGURE 3.1 – Types d'émergence

3.4.3 Auto-organisation et systèmes auto-organisés

Selon Fromm [2005], les termes 'émergence' et 'auto-organisation' sont utilisés des fois d'une façon interchangeable, mais la différence entre les deux concepts derrière peut être cernée comme suit. Le terme auto-organisation réfère plus à un processus de dynamique résidant au frontières entre le système et son environnement. Tandis que le terme 'émergence' est concerné par les frontières entre le niveau micro et le niveau macro du système. En pratique, les deux phénomène se trouvent ensemble comme caractéristiques de plusieurs systèmes complexes naturels.

3.4.4 Adaptation

Définition 3.7 (Adaptation) *L'adaptation dans les systèmes naturels réfère au développement des caractéristiques génétiques et comportementales qui permettent aux organismes ou systèmes de faire face aux changements de l'environnement afin de survivre et se reproduire [Draa, 2011; Smit et Wandel, 2006].*

Type d'adaptation

On distingue deux types d'adaptation :

1. **l'adaptation spontanée** : Dans ce type on trouve que le système s'adapte d'une manière immédiate et non réfléchie, c'est-à-dire sans planification.
2. **l'adaptation planifiée** : elle résulte de décisions stratégiques intentionnelles fondées sur une perception claire aux conditions.

3.4.5 Apprentissage

Définition 3.8 (Apprentissage) *L'apprentissage est le processus continu de transformation de l'information et de l'expérience en connaissances, compétences, comportements et attitudes [Draa, 2011; Cobb, 2011].*

Type d'apprentissage

Selon Cornuéjols et Miclet [2002] On distingue principalement 3 types d'apprentissage.

1. **Apprentissage supervisé** : un superviseur externe est présent c'est lui qui va fournir des réponses désirées au système
2. **Apprentissage non supervisé** : l'apprentissage se fait sans guide l'apprenant fait des hypothèses , puis les tests , et ensuite il les évalue selon certains critères
3. **Apprentissage par renforcement** : il est réalisé à travers une séquence de perceptions de l'environnement ,d'actions du système et de récompenses comme feedback de l'environnement dans lequel le système évolue

3.5 Optimisation

L'optimisation est l'une des branches les plus importantes des mathématiques appliquées modernes, et de nombreuses recherches. La résolution de problèmes d'optimisation est devenue un sujet central en recherches opérationnelle.

3.5.1 Définitions

Définition 3.9 (Problème d'optimisation) *Un problème d'optimisation se définit comme un problème de minimisation ou de maximisation, c'est à dire on cherche une solution de valeur optimale, minimale, si on minimise la fonction objectif, ou maximal si on la maximise [Troudi, 2006].*

Définition 3.10 (Fonction objectif) *$F : U \rightarrow R$ une mesure quantitative de qualité d'un candidat à l'optimum.*

Définition 3.11 (Minimum global) Soit V l'ensemble des solutions réalisables, $f : V \rightarrow R$ est la fonction de fitness. Le point $(\vec{u}^*) \in V$ s'appelle l'optimum global, quand la formule 1.1 est vérifiée.

$$f(\vec{u}^*) \leq (\vec{u}) \forall \vec{u} \in V \quad (3.1)$$

Définition 3.12 (Minimum local) Le point $\vec{u}^* \in V$ s'appelle l'optimum local, quand il existe un voisinage N de \vec{u}^* tel que la formule 1.2 est vérifiée.

$$f(\vec{u}^*) \leq (\vec{u}) \forall \vec{u} \in N \quad (3.2)$$

Définition 3.13 (Heuristique) Une heuristique (du grec, *heuristo* = je trouve) est une technique visant à accélérer la recherche d'une solution à un problème, en faisant un compromis entre la rapidité de la recherche et la qualité de la solution trouvée ; c'est à dire trouver une bonne solution en un minimum de temps. Cette technique est très dépendante du domaine de recherche, ce qui rend difficile la recherche d'une heuristique appropriée [Dreo, 2003].

Définition 3.14 (Meta-heuristique) On appelle meta-heuristique (du grec, *meta* = qui englobe) une méthode de recherche générique conçue dépendante aussi peu que possible du domaine d'application. Le terme *meta* s'explique aussi par le fait que ces méthodes sont des structures générales dont il faut instancier les composants en fonction du problème ; par exemple, le voisinage, les solutions de départ ou les critères d'arrêt [Dreo, 2003].

3.6 Modèles artificiels pour les systèmes complexes adaptatifs (SACs)

3.6.1 Classification des modèles artificiels pour les SACs

Il existe plusieurs classifications des métaheuristiques dans la littérature, la figure 3.2 illustre une classification qui divise les métaheuristiques en deux partie métaheuristiques à solutions unique et métaheuristique à base de populations de solutions . Voici un schéma illustrant la classification des métaheuristiques 3.2.

Métaheuristiques à solution unique

Les méthodes itératives à solution unique sont toutes basées sur un algorithme de recherche de voisinage qui commence avec une solution initiale, puis l'améliore pas à pas en choisissant une nouvelle solution dans son voisinage [Bachelet., 1999]. De manière générale, les opérateurs de recherche locale s'arrêtent quand une solution localement optimale est trouvée, c'est-à-dire quand il n'existe pas de meilleure solution dans le voisinage. Mais accepter uniquement ce type de solution n'est bien sûr pas satisfaisant. Parmi les méthodes métaheuristiques à solution unique, on trouve, le recuit simulé et la recherche tabou.

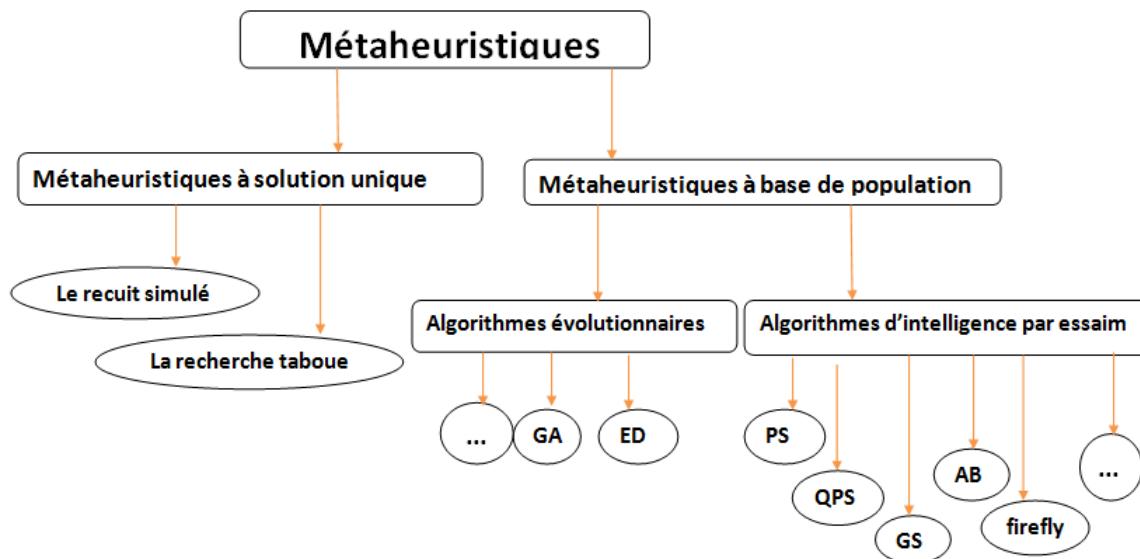


FIGURE 3.2 – Classification des metaheuristiques

Métaheuristiques à base de population

Ces méthodes d'optimisation sont basées sur une population de solutions qu'il faut améliorer au fur et à mesure des itérations. L'intérêt de ces méthodes est d'utiliser la population comme facteur de diversité. Ces méthodes sont : évolutives et sont basées sur le principe du processus d'évolution naturelle analogue au mécanisme d'évolution des espèces vivantes [Jong et Spears, 1993; Back et Schwefel, 1993; Schoenauer et Michalewicz, 1997].

Les métaheuristiques à base de population se divisent elles-mêmes en deux branches : les algorithmes évolutionnaires et les algorithmes d'intelligence par essaims.

3.6.2 Algorithmes évolutionnaires

Les Algorithmes Evolutionnaires (AE) font partie du champ de l'intelligence artificielle. Ils sont apparus à la fin des années 1950 [Fraser, 1957]. Il s'agit d'une Intelligence de bas niveau inspirée de l'intelligence naturelle. Ces algorithmes sont basés sur la théorie de l'évolution et de la sélection naturelle élaborée par Charles Darwin, qui annonce que dans un environnement quelconque, seules les espèces les mieux adaptées survivent, les autres étant condamnées à disparaître. Au sein de chaque espèce, le renouvellement des populations est essentiellement dû aux meilleurs individus de l'espèce.

Parmi les types d'algorithmes évolutionnaires on trouve : l'algorithme génétique et l'algorithme d'évolution différentielle .

• Algorithme génétique

Ces algorithmes qui ont été introduit par les travaux de Holland et Goldberg sont s'inspirent du principe de l'évolution darwinienne des populations biologiques. Une population de taille NP est initialisée au début de l'algorithme, ou chaque individu est codé sur une chaîne de gènes $X_i : i = [1..D]$ et D est la taille d'un individu (la chaîne des gènes). La population évolue au cours de l'algorithme en appliquant à chaque génération un processus analogue à la sélection naturelle.

Les individus les plus adaptés gagnent la compétition de la reproduction tandis que les moins adaptés meurent avant la reproduction [Belkacem, 2006]. Cette évolution est représentée par une suite d'opérations génétiques appliquées à la population pour chaque itération.

Les opérations de l'algorithme génétique sont les suivantes :

Croisement génétique

L'opérateur de croisement combine les gènes de deux individus pour avoir un enfant qui a les mêmes caractéristiques que les deux parents, il existe trois types de croisement : croisement à un point , consiste à générer une position aléatoire et remplacer les gènes d'un parent par ceux de l'autre ; croisement à deux points , son principe est la génération aléatoire de deux positions une position de départ et une autre position d'arrêt et remplacer les gènes qui appartiennent à cette partie par ceux de l'autre parent et le croisement uniforme qui consiste à remplacer les gènes avec une probabilité.

fixée à 0.5. La figure 3.3 montre ces trois types de croisement.

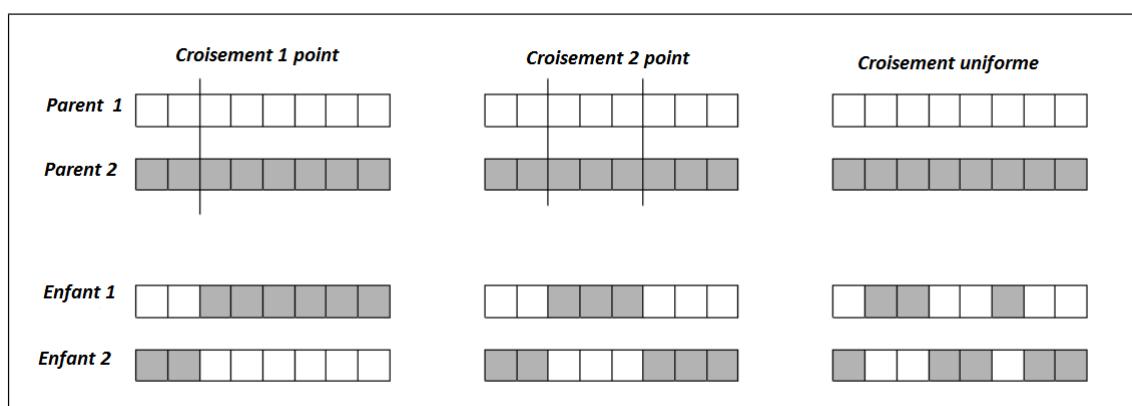


FIGURE 3.3 – Croisement génétique

[Jourdan, 2003]

Mutation génétique

Le rôle de la mutation est de faire apparaître de nouveaux gênes. Cet opérateur introduit une diversité nécessaire à l'exploitation de l'espace de recherche en permettant de générer des points voisins des parents [Jourdan, 2003]. Un gène a une probabilité de mutation p aléatoire qui est comparée avec le taux de mutation Pc comme le décrit la paire d'équations suivante 3.3

$$x_i = \begin{cases} x_{X,G}(j) & \text{si } p(0,1) \leq Pc \\ x_{U,G}(j) & \text{sinon} \end{cases} \quad (3.3)$$

Sélection génétique

La sélection génétique permet de choisir aléatoirement des parents pour leur appliquer les opérateurs génétiques. Il existe plusieurs types de sélection : *la roulette, par probabilité, par tournoi et par rang*. Certains individus peuvent être choisis plusieurs fois tandis que d'autres ne le seront jamais. Le but de la sélection est d'augmenter la qualité des solutions en gardant celles qui ont les meilleures Fitness [Belkacem, 2006].

Évaluation génétique

Pour pouvoir décider de la qualité d'un individu et ainsi le comparer aux autres, il faut établir une mesure commune d'évaluation. L'évaluation génétique est représentée par la Fitness, elle est généralement caractérisée par une fonction F et est l'étape dans laquelle on mesure la qualité de chaque individu [Jourdan, 2003].

La version basique des algorithmes génétiques fonctionne comme le montre l'algorithme : 3.1. Parmi les applications d'algorithme génétique on trouve Beaumont et Bradshaw qui ont d'utiliser

Algorithme 3.1 Algorithme génétique

Choisir NP,Pc.

$t \leftarrow 0$

Génération de la population initiale.

Tant que (le critère d'arrêt n'est pas atteint) **Faire**

$t \leftarrow t + 1$

pour chaque individu $X_{i,G}$ de la population **faire**

- Évaluer la fonction d'adaptation.

- Choisir les parents $X_{r1,G}$ et $X_{r2,G}$.

- Créer l'individu qui a la meilleure valeur de fitness entre $X_{i,G}$ et $U_{i,G}$.

- Ajouter l'individu choisi à la population.

l'algorithme génétique pour de résoudre des problèmes non-linéaires tels que les travaux des modèles de croissance optimale [Beaumont et Bradshaw, 1995]

• Évolution différentielle

Proposé par Price et Storn [1997], l'algorithme d'Évolution Différentielle (ED) est une version améliorée de l'AG. Il dispose d'opérateurs de mutation, croisement et sélection. Cependant l'ED marque la différence avec l'AG en donnant plus d'importance à la mutation. Cette mutation a pour but de créer une solution « mutant » à partir des différences entre deux solutions ou plusieurs de la population.

Plusieurs variantes ont été alors proposées [Price et Storn, 1997], elles diffèrent par le choix de la solution à muter, le nombre de différences et le type de croisement. La variante la plus classique dite DE/rand/1/exp consiste à ajouter à une solution X_m , choisie aléatoirement dans la population, une différence pondérée de deux autres solutions X_n et X_l prises aléatoirement dans la population avec $m \neq n \neq l$:

F étant le facteur de mutation, ceci peut être formulé aussi suivant l'équation (3.4).

$$y = X_m + F(X_n - X_l) \quad (3.4)$$

Le croisement consiste à changer chaque gène de la solution x_{ij} par celui du mutant avec une probabilité p_r . La nouvelle solution x_C ainsi créée est sélectionnée pour remplacer une solution de la population si sa fitness est meilleure.

Ce mécanisme de mutation, croisement et sélection est répété pour chaque solution de la population algorithme 3.2.

Algorithme 3.2 Algorithme de l'évolution différentielle

Debut

$G \leftarrow 1$

Choisir NP, F et CR

$PG \leftarrow$ Initialiser la population aléatoirement.

Tant que le critère d'arrêt n'est pas atteint **Faire**

Pour chaque individu $X_{i,G}$ de PG **Faire**

Choisir les parents auxiliaires $X_{r1,G}$, $X_{r2,G}$ et $X_{r3,G}$

Créer l'individu enfant $U_{I,G}$ en utilisant la mutation et le Croisement différentiels

Appliquer la sélection $P_{G+1} \leftarrow P_{G+1} \cup \text{Meilleur}(X_{I,G}, X_{I,G})$

Fin pour

$G \leftarrow G + 1$

Fin tant que

Fin

Parmi les applications de l'algorithme d'évolution différentielle on trouve le problème de recalage des images médicales [Neggaz et Benyettou, 2009].

3.6.3 Algorithmes d'intelligence par essaim

L'intelligence par essaim a été introduite dans les années 1990 comme une nouvelle approche, souvent bio-inspirée, pour la résolution de problèmes . La source d'inspiration de cette approche vient de l'observation du comportement des insectes sociaux : une population d'agents extrêmement simples , interagissant et communiquant indirectement à travers leur environnement, constitue un algorithme massivement parallèle pour résoudre une tache donnée

Il existe plusieurs algorithme d'intelligence par essaim parmi eux on trouve :

- **Optimisation par essaim de particules (PSO)**

La métaheuristique basée sur la méthode des essaims particulaires en anglais (Particle Swarm Optimization, PSO) a été développée par Kennedy et al. en 1995 [Kennedy et Eberhart, 1995].

Cette méthode est inspiré du comportement collectif d'animaux comme le déplacement des bancs de poissons ou le vol des oiseaux.

En effet, on peut observer chez ces animaux des dynamiques de déplacement relativement complexes, alors qu'individuellement chaque individu a une intelligence limitée et une connaissance seulement locale à sa situation dans l'essaim.

Principe de l'optimisation par essaim de particules

Le principe de cette approche est comme suit. Un essaim est composé d'un ensemble de particules qui représentent chacune une solution du problème traité. Ces particules se déplacent selon leurs propres perceptions de l'environnement avec des règles simples .

Chaque particule est définie par sa position $x(t)$ qui représente une solution et sa vitesse $v(t)$. Une particule est caractérisée par le P_{best_i} qui représente sa meilleure position et le G_{best} qui est la meilleure position globale pour tout l'essaim.

A chaque itération la particule va se déplacer en fonction de sa vitesse et des deux meilleures positions qu'elle connaît (la sienne et celle de l'essaim) comme l'illustre la figure 3.4.

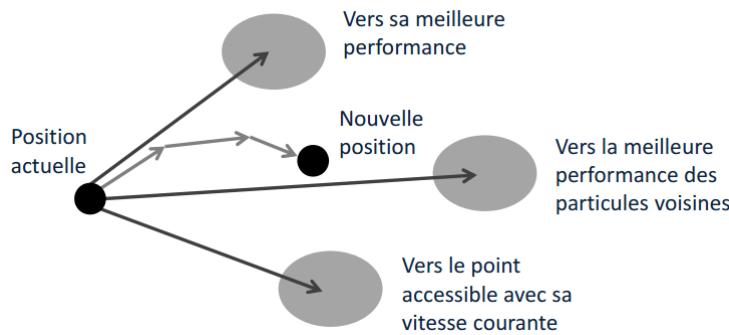


FIGURE 3.4 – Déplacement d'une particule.

La particule se déplace en fonction de sa vitesse et sa position suivant les deux équations de la formule (3.5) de [Hashemi et Meybodi, 2011].

$$\begin{cases} v_i(t+1) = w_i t + c_1 * r_1(pbest_i - p_i(t)) + c_2 * r_2(gbest - p_i(t)) \\ p_i(t+1) = p_i(t) + v_i(t+1) \end{cases} \quad (3.5)$$

Où w est l'inertie qui permet de contrôler l'influence de la vitesse obtenue au pas précédent. c_1 et c_2 sont des facteurs d'attractions, vers sa meilleure position (mémoire de la particule) et vers la meilleure position de ses voisines (mémoire partagée) et r_1 , r_2 sont des nombres aléatoires dans l'intervalle $[0,1]$.

Les performances du PSO sont très sensibles aux valeurs données aux paramètres. Le processus d'optimisation par essaims de particules se déroule comme le montre l'algorithme 3.3.

Avantages et limites du PSO

L'algorithme du PSO possède plusieurs avantages :

- C'est un algorithme simple à implémenter
- Il est très efficace dans la recherche global
- Il est facile à paralléliser pour le traitement concurrent
- Il possède peu de paramètres à régler

Le PSO a été utilisé pour le clustering des données [van der Merwe et Engelbrecht, 2003].

Cependant, le PSO se montre faible dans la convergence globale comme Van den Bergh [2001] l'a démontré. C'est pour cela que d'autre variante du PSO sont apparues parmi elle ont trouvé le PSO quantique inspirée de la mécanique quantique. Cette variante appelée optimisation par essaim de particules quantiques qui a été proposé par Sun [2004]. On va découvrir cette approche avec plus de détail dans le chapitre des contributions.

Algorithme 3.3 Algorithme d'optimisation par essaim de particules

Pour chaque particule **Faire**

Initialiser sa position et sa vitesse :

Initialiser $p_i(t)$ **Fin pour****Répéter**Choisir la particule g_{best} ayant la meilleure fitness dans L'itération courante**Pour** chaque particule p **Faire**Calculer la vitesse $v(t + 1)$ utilisant l'équation (1.5)Mettre à jour le vecteur position $x(t + 1)$ selon l'équation (1.5)Calculer la valeur de la fitness $f(x(t))$ **Si** $f(x(t)) > f(P_{best})$ Mettre à jour le p_{best} **Si** $f(P_{best}) > G_{best}$ Mettre à jour le G_{best} **Fin pour.** $t \leftarrow t + 1$ **Tant que** le critère d'arrêt n'est pas atteint.

• Abeilles artificielles

La colonie d'abeilles artificielles en anglais (Artificial Bee Colony, ABC), inventée par Karaboga en 2005 est un algorithme d'optimisation inspiré du comportement alimentaire collectif des abeilles [Karaboga, 2007]. La colonie d'abeilles artificielles s'était inspirée du comportement alimentaire intelligent des abeilles recherchant une source de nourriture pour l'optimisation de problèmes numériques [Birattari, 2002].

Dans l'algorithme ABC, la colonie se compose de trois types d'abeilles : les abeilles butineuses actives (employeds), inactives (scouts) et les éclaireuses (Onlookers).

Dans la première étape, l'algorithme génère une population initiale de SN solutions distribuées de façon aléatoire. Chaque solution $x_i (i = 1, 2, \dots, SN)$ est initialisée par les éclaireuses, et représente un vecteur de solution au problème d'optimisation. Les variables que contient chaque vecteur doivent être optimisées.

Après l'initialisation, la population des solutions est soumise à des cycles répétés $C = 1, 2, \dots, C_{max}$. Ces cycles représentent des processus de recherches faits par les butineuses actives, inactives et les éclaireuses.

Les butineuses actives recherchent dans le voisinage de la source précédente x_i de nouvelles sources v_i ayant plus de nectar. Elles calculent ensuite leur fitness. Afin de produire une nouvelle source de nourriture à partir de l'ancienne, on utilise la formule (3.6) :

$$v_{ij} = x_{ij} + \phi_{ij}(x_{ij} - x_{kj}) \quad (3.6)$$

Où $j \in (1, 2, \dots, SN)$, $k \in 1, 2, \dots, D$, D est la dimension du problème, j et k sont des indices choisis au hasard. Bien que k est déterminé aléatoirement, il doit être différent de i . ϕ_{ij} est un nombre aléatoire appartenant à l'intervalle $[-1, 1]$. Il contrôle la production d'une source de nourriture dans le voisinage de x_{ij} .

Après la découverte de chaque nouvelle source de nourriture v_i , un mécanisme de sélection gourmande est adopté, c'est-à-dire que cette source est évaluée par les abeilles artificielles, sa performance est comparée à celle de x_i . Si le nectar de cette source est égale ou meilleur que celui de la source précédente, celle-ci est remplacée par la nouvelle. Dans le cas contraire l'ancienne est conservée.

Pour un problème de minimisation, La fitness est calculée suivant la formule (3.7) :

$$\begin{cases} f_i = \frac{1}{1+f_i}, f_i \geq 0 \\ f_i = 1 + \text{abs}(f_i), f_i < 0 \end{cases} \quad (3.7)$$

Tel que f_i est la valeur de la fonction objectif de la solution x_i .

A ce stade, les butineuses inactives et les éclaireuses sont entrain d'attendre au sein de la ruche.

A la fin du processus de recherche, les butineuses actives partagent les informations sur le nectar des sources de nourriture ainsi que leurs localisations avec les autre abeilles via la danse frétillante. Ces dernières évaluent ces informations tirées de toutes les butineuses actives, et choisissent les sources de nourriture en fonction de la valeur de probabilité P_i associée a cette source, et calculée par la formule (3.8).

$$P_i = \frac{fit_i}{\sum_{i=1}^n fit_i} \quad (3.8)$$

Où fit_i est la fitness de la solution i , qui est proportionnelle à la quantité du nectar de la source de nourriture à la position i .

La source de nourriture dont le nectar est abandonné par les abeilles, les éclaireuses la remplacent par une nouvelle source. Si durant un nombre de cycle prédéterminé appelé *Limite* une position ne peut être améliorée, alors cette source de nourriture est supposée être abandonnée.

L'algorithme 3.4 illustre les étapes de l'algorithme de colonie d'abeilles artificielles.

Parmi les applications de l'algorithme de colonie d'abeilles artificielles ont trouve Karaboga et Akay [2007] qui ont appliquée l'algorithme ABC à la formation de réseaux de neurones.

Algorithme 3.4 Algorithme de colonie d'abeilles artificielles

La phase d'initialisation.

Répéter

- La phase des abeilles butineuses actives (employed).
- La phase des abeilles les éclaireuses (onlookers).
- La phase des abeilles butineuses inactives (scouts).
- Enregistrer la meilleure solution jusqu'à maintenant.

jusqu'à ce que la condition d'arrêt est atteinte.

• **Algorithme des lucioles**

L'algorithme des lucioles est une métaheuristique développée par le Shi-Yang [2009]. Cet algorithme est basé sur le comportement naturel des lucioles. Les lucioles produisent des éclairs de lumières à l'aide de ce phénomène. Cette lumière aide à faire communiquer les uns avec les autres et attirer des proies ou d'autres lucioles.

Dans cet algorithme le concept principal est qu'une luciole est attirée vers d'autres si celui-ci émet une intensité lumineuse plus élevée.

Les trois règles de base suivantes sont respectées tout en mouvement d'une luciole à autre :

1. Toutes les lucioles sont unisexes et donc une luciole sera attirée par d'autres lucioles indépendamment de leurs sexes.
2. L'attractivité est proportionnelle à la luminosité, et donc pour deux lucioles clignotantes se déplacera vers le plus lumineuse. De plus comme l'attrait est proportionnelle à la luminosité, ils diminuent tous les deux en tant que la distance augmente. Si elle n'est pas plus lumineuse qu'une luciole particulière, elle se déplace de façon aléatoire ;
3. La brillance d'une luciole est déterminée en fonction de la nature de la fonction objectif.

L'algorithme de firelies a été appliqué sur le recalage d'images par Hassanzadeh *et al.* [2011], plus de détail sur l'algorithme des lucioles peut être trouver dans Dekhici et Belkadi [2012]

• **Algorithme de recherche gravitationnelle**

Récemment, un nouvel algorithme d'intelligence par essaim a été introduit en se basant sur le principe des forces de gravité entre les masses. Cette méthode est appelée algorithme de recherche gravitationnelle (en anglais Gravitational Search Algorithm GSA). Le GSA pourrait être considéré comme un système isolé des masses. C'est comme un petit monde artificiel des masses obéissant aux lois de la gravitation newtonienne et aux mouvements. La position de la masse correspond à

une solution du problème, et ses masses gravitationnelles et inertielles sont déterminées en utilisant une fonction de remise en forme.

Ainsi, les agents sont considérés comme des objets et leur performance est mesurée par leurs masses. Tous ces objets s'attirent par la force de gravité, et cette force provoque un mouvement de tous les objets vers les objets plus lourds avec des masses. Par conséquent, les masses coopèrent en utilisant une forme de communication directe, par la force gravitationnelle [Rashedi et Nezamabadi, 2009].

3.7 Conclusion

Dans ce chapitre nous avons présenté des modèles artificiels pour les systèmes complexes utilisés pour la résolution de problèmes d'optimisation connues sous le titre de métaheuristiques. Les métaheuristiques sont des méthodes stochastiques qui visent à résoudre un large panel de problèmes, le but visé par ces méthodes est d'explorer l'espace de recherche efficacement afin de déterminer des solutions (presque) optimales. Ces méthodes ont rencontrées un vif succès grâce à leur simplicité leur forte modularité. Malgré les bons effets des métaheuristiques, elles restent limitées par certains problèmes

La performance d'une métaheuristique dépend de plusieurs facteurs. La limite majeure des métaheuristiques dépend du paramétrage. Il existe très peu de règles universelles permettant de connaître le paramétrage idéal ; généralement seules l'expertise et l'expérience de l'utilisateur permettront de faire un bon choix.

Dans le chapitre suivant, nous présentons une méthodes basée-population qui est une variante de l'algorithme d'optimisation par essaim de particules appelé algorithme d'optimisation par essaim de particules quantiques. C'est cette approche qu'on va étendre pour la résolution du problème de segmentation d'images médicales.

Chapitre 4

Contributions (QPSO et l'OBL pour la segmentation d'images médicales)

“Une personne qui n'a jamais commis d'erreurs n'a jamais tenté d'innover.” -

Albert Einstein

Sommaire

4.1	Introduction	51
4.2	Motivation	51
4.2.1	Métaheuristiques Pour la segmentation d'images	52
4.3	Éléments des contributions	52
4.3.1	Optimisation par essaim de particules quantiques	53
4.3.2	Apprentissage par complément	54
4.4	Contributions	55
4.4.1	Formulation du problème	55
4.4.2	Contribution(1) : PSO Quantique pour la segmentation d'images médicales	58
4.4.3	Contribution(2) : PSO quantique avec apprentissage par complément pour la segmentation d'images médicales	62
4.5	Conclusion	64

4.1 Introduction

La segmentation est une partie intégrante dans le système de reconnaissance, qui vise à subdiviser les pixels de l'image en différentes classes. Les pixels assez similaires que possible, sont rangés dans la même classes et les dissimilaires dans différentes classes. L'objectif de la segmentation est donc d'aboutir à une description du contenu de l'image par l'extraction des différents objets. Cette séparation des objets, ou la différenciation des pixels est faite dans ce travail par les techniques de seuillage multi-niveaux qui ont évolué ces dernières années et qui sont parmi les techniques les plus importantes pour la segmentation d'images.

Dans ce chapitre nous présenterons nos contributions pour résoudre le problème de la segmentation d'images médicales par seuillage multi-niveaux.

4.2 Motivation

L'imagerie médicale a rendu possible un énorme progrès en matière de diagnostic et fournit jour après jour un apport important aux soins des patients. L'évolution rapide des techniques d'imagerie aboutit aujourd'hui à une offre très étendue dans ce domaine.

La vision intervenant dans un grand nombre d'activités humaines, le champ des applications du traitement d'images est très vaste ; la médecine est un des domaines qui n'a pu échapper à ce souffle .

L'un des processus fondamentaux dans la chaîne de traitement d'images médicales est la segmentation. Le but de la segmentation d'images dans le domaine médical est d'extraire à partir des images acquises, les informations utiles au diagnostic, de révéler des détails difficiles à percevoir à l'œil nu, tout en évitant la création d'artefacts, faussement informatifs. Pour cela le traitement fait appel à des outils, des algorithmes, qui permettent d'agir sur l'image numérisée [Berrichi et Benyettou, 2009].

Parmi les techniques de la segmentation d'images on trouve le seuillage, la segmentation par seuillage d'histogramme constitue un cas particulier de la segmentation par classification. Elle permet de répartir les pixels en classes en fonction de leurs niveaux de gris. Les classes sont alors délimitées par des seuils. La segmentation par seuillage peut être séparer en deux catégories : seuillage à deux niveaux qui est la binarisation et seuillage multi-niveaux [Abdelli, 2011].

La complexité des calculs augmente exponentiellement avec l'augmentation du nombre de seuils à cause de la nature itérative et exhaustive de ces méthodes. Afin de résoudre ce problème, les chercheurs ont eu recours aux métaheuristiques comme une alternative aux méthodes exactes qui

sont couteuses en temps d'exécution. L'utilisation des métaheuristiques pour le seuillage multi-niveaux permet de trouver une solution optimale ou au moins une bonne approximation obtenue dans un temps de calcul raisonnable [Troudi, 2006].

4.2.1 Métaheuristiques Pour la segmentation d'images

Parmi les métaheuristiques déjà utilisées pour la segmentation d'images par seuillage on trouve l'algorithme génétique proposé par Hammouche *et al.* [2008], on peut citer également les méthodes basées sur la minimisation de l'entropie floue proposé par Yang [2003], l'entropie relative utilisé par Tao et Tian [2003], l'optimisation des fonctions d'Otsu et de Kapur utilisé par Hammouche *et al.* [2010], ainsi que celle utilisées pour le seuillage d'histogrammes bidimensionnels [Yang, 2003; Yu et Fan, 2008].

L'algorithme d'évolution différentielle a été appliqué dans le cadre du seuillage en optimisant la fonction d'Otsu par Hammouche *et al.* [2010] et pour approximer l'histogramme par mélange de distributions [cuevas, 2009].

Horng [2011] a proposé l'algorithme de colonie d'abeille artificielles pour la segmentation d'images par seuillage et enfin Feng *et al.* [2005] qui a adapté l'algorithme d'optimisation par essaim de particules(PSO) pour la segmentation d'images.

4.3 Éléments des contributions

L'intelligence par essaim de particules (PSO) a été introduite dans les années 1990 comme une approche, bio-inspirée, pour la résolution de problèmes. Comme tout autre algorithme d'optimisation, l'objectif du PSO est de réaliser une convergence vers l'optimum global. Pour cela, il faut chercher un compromis délicat entre l'exploitation des solutions déjà trouvées et l'exploration de l'espace de recherche tout au long de l'évolution du processus de recherche.

L'exploration et l'exploitation sont deux forces opposées [Feiben et Schippers, 1998]. Donc, une bonne balance entre les deux est nécessaire d'où le fait de favoriser un concept sur un autre donne lieu à un déséquilibre.

L'algorithme du PSO possède plusieurs avantages. En effet c'est un algorithme simple à implémenté très efficace dans la recherche globale, facile à paralléliser pour le traitement concurrent et possède peu de paramètres à régler. Cependant, cet algorithme souffre d'une limite majeure qui est le problème de la convergence prématuée, démontré par Van den Bergh [2001].

Dans le cadre de notre projet et pour surmonter la limite du PSO classique, nous nous proposons d'utiliser une variante de l'algorithme d'optimisation par essaim de particules, il s'agit du PSO quantique. Cette variante est utilisée, comme première contribution pour la segmentation d'images médicales par seuillage.

4.3.1 Optimisation par essaim de particules quantiques

L'optimisation par essaim de particules quantiques (En anglais Quantum Particle Swarm Optimization QPSO) est une variante du PSO qui est inspirée du comportement quantique. Proposé par Sun [2004].

- **Principe du QPSO**

Le PSO quantique est un d'algorithme probabiliste. L'équation du mouvement du QPSO est différente de celle du PSO classique, cet algorithme ne nécessite pas de vecteur de vitesse pour particules. De plus il y a moins de paramètres à ajuster, ce qui le rend plus facile à mettre en œuvre.

Dans le modèle quantique du PSO, l'état d'une particule est représenté par la fonction d'onde $\psi(x, t)$ où x est la position de la particule à un instant donnée nommé t . Le comportement dynamique de la particule est largement différent de celui de la particule dans le PSO classique. Les valeurs exactes de la position et la vitesse ne peuvent pas être déterminées simultanément, on peu seulement avoir la probabilité pour qu'une particule apparaisse à la position x de la fonction de densité de probabilité $\psi(x, t)^2$ [Farzi *et al.*, 2010].

Les particules se déplacent en fonction de l'ensemble de formules (4.1).

$$\left\{ \begin{array}{l} x_{id}(t+1) = \{g_{id} \pm \beta \mid mbest_d - x_{id}(t) \mid \ln(1/u)\} \\ g_{id} = \varphi \cdot pbest_{id} + (1 - \varphi)gbest_{d'} \\ mbest_d = \sum_{i=1}^M pbest_{id}/M \end{array} \right. \quad (4.1)$$

Où $mbest$ représente la moyenne de toutes les meilleures positions des particules, φ et u sont des nombres distribué aléatoirement sur l'intervalle $[0, 1]$, M représente le nombres de particules ($i = 1, 2, \dots, M$) ; et β représente le seul paramètre du QPSO appelé *coefficient de contraction expansion*.

- **Algorithme du QPSO**

L'algorithme de l'optimisation par essaim de particules quantiques se présente comme dans le pseudo-code de l'algorithme 4.1. Où $Pbest$ représente la meilleure position d'une particule P_i , $Gbest$ est la meilleure solution de toutes la population P et $Mbest$ est la fitness moyenne du $Pbests$.

Algorithme 4.1 Algorithme d'optimisation par essaim de particules quantiques

Début

Initialisation de la population P avec des positions aléatoires.

$P_{best} = P$ dans l'initialisation de l'algorithme.

Tant que la condition d'arrêt n'est pas vérifiée **Faire**.

Évaluer la fitness de chaque particule

Comparer la fitness de chaque particule avec son P_{best}

Mettre à jour les P_{best}

Comparer la fitness du nouveau P_{best} de chaque particule avec celle du G_{best}

Mettre à jour le G_{best}

Calculer le M_{best} en utilisant l'équation dédiée au calcul du M_{best}

Calculer les nouvelles positions des particules en utilisant l'ensemble de formules (4.1).

Fin

Le QPSO est plus performant que le PSO classique. Mais ce dernier souffre toujours du problème de la convergence prématuée [Yang *et al.*, 2009]. Afin de résoudre ce problème et améliorer les performances du QPSO, on propose notre deuxième contribution qui est l'introduction du concept d'apprentissage par complément dans le PSO quantique.

4.3.2 Apprentissage par complément

L'apprentissage par complément (en anglais Opposition Based Learning, OBL) a d'abord été proposé par Tizhoosh et Malisia [2007] et a été appliqué avec succès pour résoudre plusieurs problèmes [Rahnamayan *et al.*, 2008; Liu *et al.*, 2007]. L'idée de base de l'OBL est l'examen d'une estimation et son estimation opposée correspondante simultanément, rapprochant la solution candidate actuelle. La solution inverse x^* peut être calculée comme le montre la formule (4.2) [Rahnamayan *et al.*, 2008].

$$x^* = a + b - x \quad (4.2)$$

Où $x \in [a, b]$, a et b sont les bornes inférieure et supérieure de la variable x . Similairement cette définition peut être étendue pour des problèmes à plusieurs dimensions et qui sera formulée comme dans la formule (4.3).

$$x_j^* = a_j + b_j - x_j \quad (4.3)$$

En supposons que $f(X)$ est la fonction objectif d'un problème donné et que $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$ est la *ième* particule de la population P , $OX_i = (x_{i1}^*, x_{i2}^*, \dots, x_{in}^*)$ est l'opposé correspondant de l'individu X_i . Si $f(OX_i)$ est meilleure que $f(X_i)$ alors on met à jour X_i en la remplaçant par la particule OX_i .

La figure 4.1 illustre une population P et sa population opposée OP .

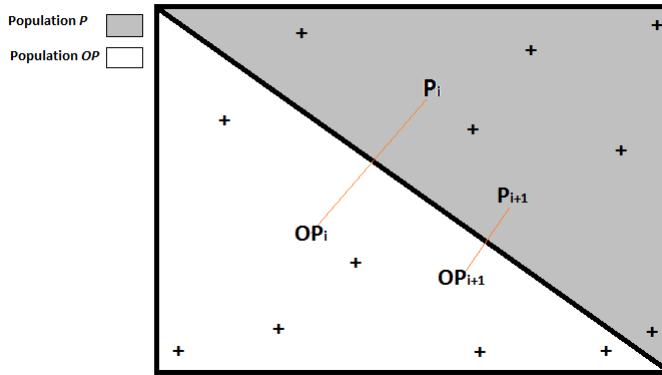


FIGURE 4.1 – Population P et OP

4.4 Contributions

4.4.1 Formulation du problème

Soit une image $I1$ représentée par 0 à $L - 1$ niveaux de gris. Le nombre total des pixels de l'image est égal à N et f_i est le nombre de pixels ayant le niveau de gris i comme l'illustre la formule (4.4).

$$N = \sum_{i=0}^{L-1} f_i \quad (4.4)$$

Une probabilité d'occurrence du niveau de gris i est donnée par la formule (4.5).

$$p_i = \frac{f_i}{N} \text{ où } \sum_{i=0}^{L-1} p_i = 1 \quad (4.5)$$

On suppose que l'image $I1$ est composée de $M+1$ régions M est le nombre de seuils $\{t_1, t_2, \dots, t_M\}$ nécessaires pour la segmentation de l'image en régions comme illustré dans la formule (4.6).

$$\left\{ \begin{array}{l} c_0 = \{0, \dots, t_1 - 1\}; \\ c_1 = \{t_1, \dots, t_2 - 1\}; \\ \dots \\ c_M = \{t_M, \dots, L - 1\}; \end{array} \right. \quad (4.6)$$

Tel que : $t_1 \leq t_2 \dots \leq t_{M-1} \leq t_M$

Le problème du seuillage consiste à chercher l'ensemble des seuils $(t_1^*, t_2^*, \dots, t_M^*)$ qui maximise la fonction objectif f formulée comme dans l'équation (4.7).

$$(t_1^*, t_2^*, \dots, t_M^*) = \text{Max}(f(t)) \quad (4.7)$$

Il existe plusieurs méthodes de segmentation d'images par seuillage. Parmi elles on trouve la méthode Otsu qui choisit le seuil optimal en maximisant la variance inter-classe et la méthode Kapur qui choisit le seuil optimal en maximisant l'entropie de Kapur.

Dans notre travail nous cherchons à optimiser deux fonctions objectif qui sont :

- **Fonction objectif (1)** : Maximiser l'entropie de Kapur.
- **Fonction objectif (2)** : Maximiser la variance interclasses de Otsu.

• Maximisation de l'entropie de Kapur

La notion d'entropie est utilisée dans de nombreux domaines tel que la reconstruction d'images, l'estimation spectrale et la restauration d'image. Dans notre travail nous allons utiliser l'entropie de Kapur pour la segmentation d'images médicales. Le principe de la maximisation d'entropie repose sur la détermination des seuils en maximisant cette dernière résultant du découpage de l'histogramme en M classes [Kapur *et al.*, 1985]. Notre première fonction objectif est défini par l'équation (4.8).

$$f([t_1, t_2, \dots, t_M]) = H_0 + H_1 + H_2 + \dots + H_M \quad (4.8)$$

$$\text{Où : } \begin{cases} H_0 = - \sum_{i=0}^{t_1-1} \frac{p_i}{w_0} \ln \frac{p_i}{w_0}, & w_0 = \sum_{i=0}^{t_1-1} p_i \\ H_1 = - \sum_{i=t_1}^{t_2-1} \frac{p_i}{w_1} \ln \frac{p_i}{w_1}, & w_1 = \sum_{i=t_1}^{t_2-1} p_i \\ H_2 = - \sum_{i=t_2}^{t_3-1} \frac{p_i}{w_2} \ln \frac{p_i}{w_2}, & w_2 = \sum_{i=t_2}^{t_3-1} p_i \\ \dots \\ H_M = - \sum_{i=t_M}^{L-1} \frac{p_i}{w_M} \ln \frac{p_i}{w_M}, & w_M = \sum_{i=t_M}^{L-1} p_i \end{cases}$$

Où L les niveaux de gris d'une image donnée, L est dans l'intervalle $0..L - 1$, N est le nombre totale de pixels de l'image, W_i est la probabilité d'apparition des pixels appartenant à une classe c_i , p_i est la probabilité d'apparition d'un niveau de gris et H_i est l'entropie d'une classe c_i .

• Maximisation de la variance inter-classes

Cette méthode est utilisée pour la réalisation d'un seuillage à plusieurs niveaux (multi-classes) à partir d'un histogramme d'image à niveaux de gris. Cette technique partitionne l'image en $M + 1$ régions en maximisant la variance inter-classes par la détermination de M seuils t_1, t_2, \dots, t_M [Otsu, 1979].

La variance inter-classes d'Otsu peut être formulé comme dans l'équation (4.9).

$$f(t) = \sigma_0 + \sigma_1 + \sigma_2 + \dots + \sigma_M \quad (4.9)$$

$$\text{Où } \begin{cases} \sigma_0 = w_0(\mu_0 - \mu_T)^2 \\ \sigma_1 = w_1(\mu_1 - \mu_T)^2 \\ \dots \\ \sigma_M = w_M(\mu_M - \mu_T)^2 \end{cases} \quad (4.10)$$

Où L les niveaux de gris d'une image donnée, L est dans l'intervalle $0..L - 1$, N est le nombre totale de pixels de l'image, W_i est la probabilité d'apparition des niveaux de gris d'une classe c_i , p_i est la probabilité d'apparition d'un niveau de gris et H_i est l'entropie d'une classe c_i .

Les probabilités w_i et les moyennes μ_i de chaque classe sont calculées comme indiqué dans la formule (4.11).

$$\begin{cases} w_0 = \sum_{i=0}^{t_1} P_i, \mu_0 = \sum_{i=0}^{t_1} \frac{iP_i}{w_1} \\ w_1 = \sum_{i=t_1+1}^{t_2} P_i, \mu_1 = \sum_{i=t_1+1}^{t_2} \frac{iP_i}{w_2} \\ \dots \\ w_M = \sum_{i=t_{M-1}+1}^{L-1} P_i, \mu_M = \sum_{i=t_{M-1}+1}^{L-1} \frac{iP_i}{w_M} \end{cases} \quad (4.11)$$

L'intensité moyenne de l'image entière μ_T est calculée par la formule (4.12) :

$$\mu_T = w_0\mu_0 + w_1\mu_1 + \dots + w_M\mu_M \quad (4.12)$$

La figure 4.2 schématisé nos contributions. Notre première contribution consiste à adapter le PSO quantique au problème de la segmentation d'images médicales par seuillage, cette contribution elle même sera diviser en deux sous contributions, l'une consiste à segmenter les images en se basant sur l'entropie de Kapur et la deuxième consiste à segmenter les images en se basant sur la variance inter-classes d'Otsu. Notre deuxième contribution introduit le concept d'apprentissage par complément dans le PSO quantique, cette contribution aussi sera divisé en deux sous contributions, la première consiste à segmenter les images médicales en se basant sur l'entropie de Kapur, et la deuxième consiste à segmenter les images en se basant sur la variance inter-classes d'Otsu. Dans ce qui suit on va détailler les différentes contributions.

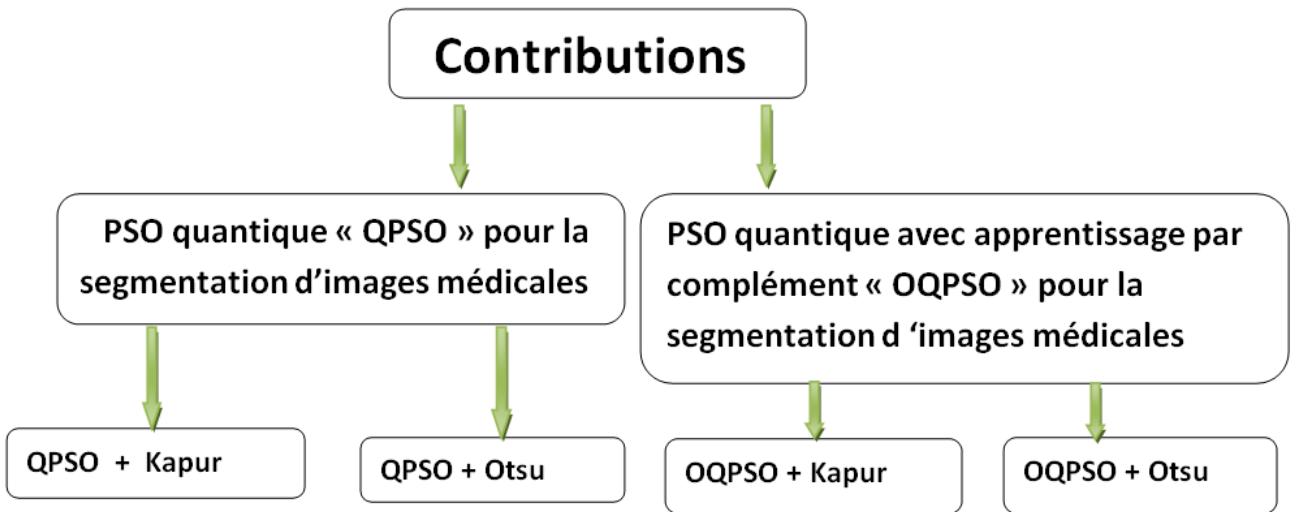


FIGURE 4.2 – Schématisation de nos contributions

4.4.2 Contribution(1) : PSO Quantique pour la segmentation d'images médicales

Étant donné une image I_1 qui possède L niveaux de gris et une population P de particules représentant des solutions de seuillage générées aléatoirement dont les valeurs des variables sont entre 0 et 255 .Chaque particule P_i de cette population représente un ensemble de seuils. Notre objectif est donc de trouver la particule P_i qui possède les seuils optimaux permettant de segmenter l'image I_1 en utilisant l'algorithme du PSO quantique vu dans la section précédente.

Cette Contribution possède deux sous contribution qui sont à la base de l'utilisation des deux fonctions objectif décrites dans la section précédente l'entropie de Kapur et la variance inter-classes d'Otsu. Donc la fonction objectif (fitness) est représentée par l'entropie de Kapur (fonction objectif 1) et la variance inter-classes de Otsu (fonction objectif 2).

Le schéma de la figure 4.3 décrit la démarche globale de la segmentation d'images en utilisant le PSO quantique qu'on nommera QPSO.

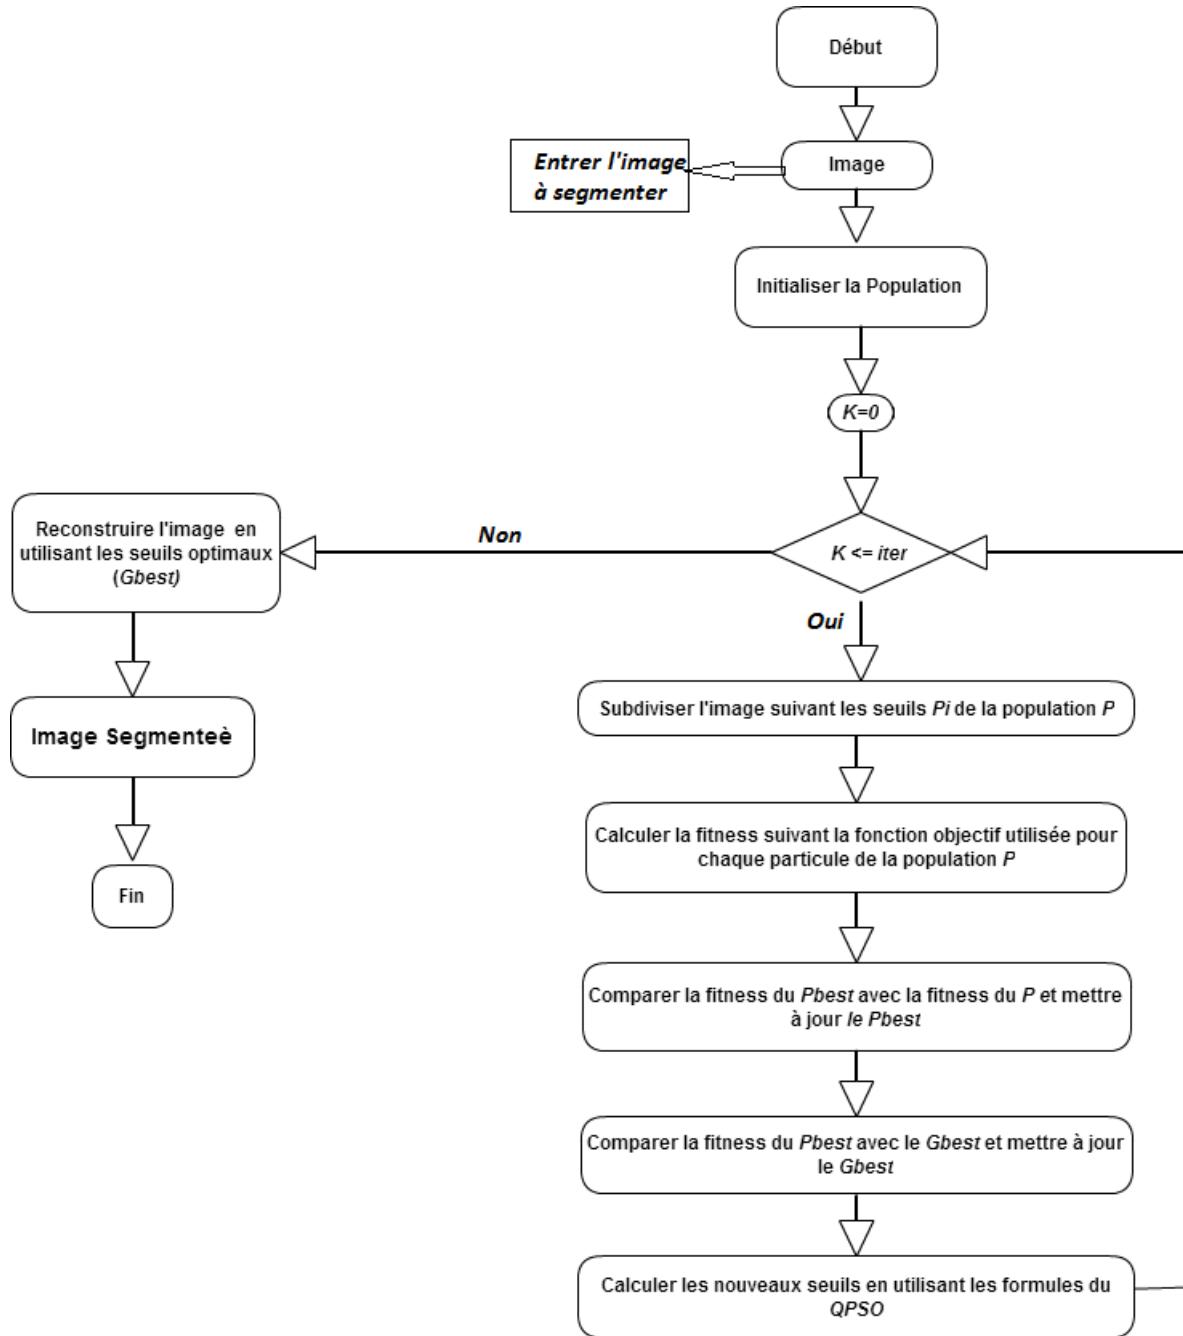


FIGURE 4.3 – Organigramme de la segmentation d'images médicales par l'algorithme QPSO

Les étapes de la segmentation d’images par seuillage en utilisant l’algorithme QPSO se présente comme suit :

1. Générer aléatoirement une population P d’individus représentant un seuillage dont les valeurs sont entre 0 et 255 comme illustré dans la figure 4.9 . Discréteriser les valeurs de la population P c’est à dire passé du domaine continu au domaine discret faire un trie ascendant pour chaque particule P_i .

<i>Particule1</i> =>	23.45	199.98	3.98	240.60
<i>Particule2</i> =>	30.45	10.56	50.68	300.67
	122.45	240.00	60.67	45.68
<i>Particule n</i> =>	254.98	190.45	45.76	80.65
	<i>Seuil 1</i>	<i>Seuil 2</i>		<i>Seuil n</i>

Population P

4	23	200	241
11	30	51	255
46	61	122	251
46	81	190	255

Population P après discréétisation

FIGURE 4.4 – Population P et population OP dans le cas de l’OBL

Pour chaque particule P_i de la population P faire :

2. Subdiviser l’image en classes suivant les seuils de la particule P_i . Quelque soit le nombre de seuils on concatène toujours la particule P_i avec le 0 et 255, comme l’illustre la figure 4.5.

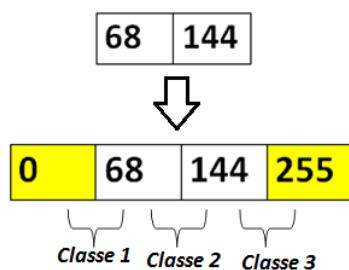


FIGURE 4.5 – Particule P_i

La figure 4.6 illustre l’image $I1$ après l’avoir classifier selon la particule P_i ce qui veut dire qu’on va subdiviser l’image $I1$ en 3 classes.

4	23	200	241
11	30	51	255
46	61	122	251
46	81	190	255

1	1	3	3
1	1	1	3
1	1	2	3
1	2	3	3

FIGURE 4.6 – Image subdiviser en 3 classes

3. Calculer la fitness pour chaque particule (Kapur ou Ostu).
4. Comparer la fitness de la particule en cours avec celle du P_{best} ; si la fitness courante est meilleure mettre à jour le P_{best} .
5. Comparer la fitness du P_{best} avec celle du G_{best} ; si la fitness du P_{best} est meilleure alors mettre à jour le G_{best} .
6. Calculer les nouveaux seuils en utilisant les formules du QPSO décrites dans l'équation (4.1).
7. Aller à 3 jusqu'à ce que la condition d'arrêt soit atteinte.

Le g_{best} représente la particule qui possède les meilleurs seuils pour segmenter l'image I_1 .

8. Reconstruire l'image segmentée en utilisant le g_{best} et en attribuant à chaque classe un seul niveau de gris qui représente la moyenne des niveaux de gris de cette classe voici un exemple d'une image segmenté par 2 seuils figure 4.7 où S_1 et S_2 représentent les seuils.

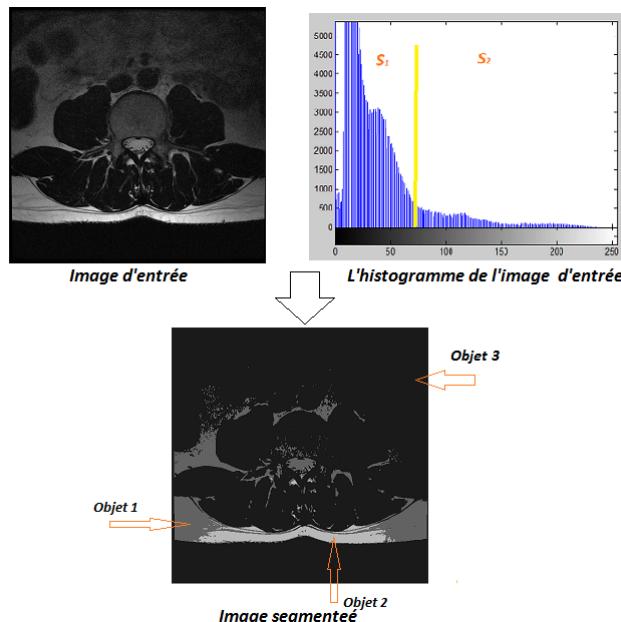


FIGURE 4.7 – Exemple d'une image segmentée

4.4.3 Contribution(2) : PSO quantique avec apprentissage par complément pour la segmentation d'images médicales

L'algorithme de QPSO n'a pas pallié à la limite majeure du PSO classique qui est le problème de convergence prématuée [Yang *et al.*, 2009]. Pour résoudre ce problème on va introduire une nouvelle approche qui sera notre deuxième contribution qui introduit du concept d'apprentissage par complément dans l'algorithme QPSO, on nommera cette approche (OQPSO). Cette deuxième contribution elle même sera partitionnée en deux sous-contributions qui sont OQPSO pour la segmentation d'image médicale en se basant sur l'entropie de Kapur et OQPSO pour la segmentation d'images médicales en se basant sur la variance inter-classes d'Otsu.

L'idée principale de l'approche proposée consiste à utiliser l'OBL pour générer l'estimation opposé des particules du QPSO pour un problème de segmentation d'images médicale par seuillage. On notera l'introduction de l'OBL dans le QPSO par OQPSO(de l'anglais opposition-based QPSO). Les principales étapes du OQPSO sont décrites dans l'algorithme 4.2.

Algorithme 4.2 Algorithme OQPSO

Début

Générer une population aléatoire P de solutions.

Tant que la condition d'arrêt n'est pas atteinte **Faire**

Calculer la population inverse OP .

Calculer la fitness de P et OP .

Comparer les fitness de P et OP ; mettre à jour les articules P dans le cas où les fitnesses du OP sont meilleures.

Calculer la nouvelle fitness de P après mise à jour.

Comparer les fitnesses des particules P et P_{best} ; et mettre à jour les P_{best} si les fitnesses du P sont meilleures.

Comparer P_{best} , G_{best} et mettre à jour le G_{best} si la fitness d'un P_{best} est meilleure.

Fin

L'organigramme de la figure 4.8 illustre les principales étapes du OQPSO.

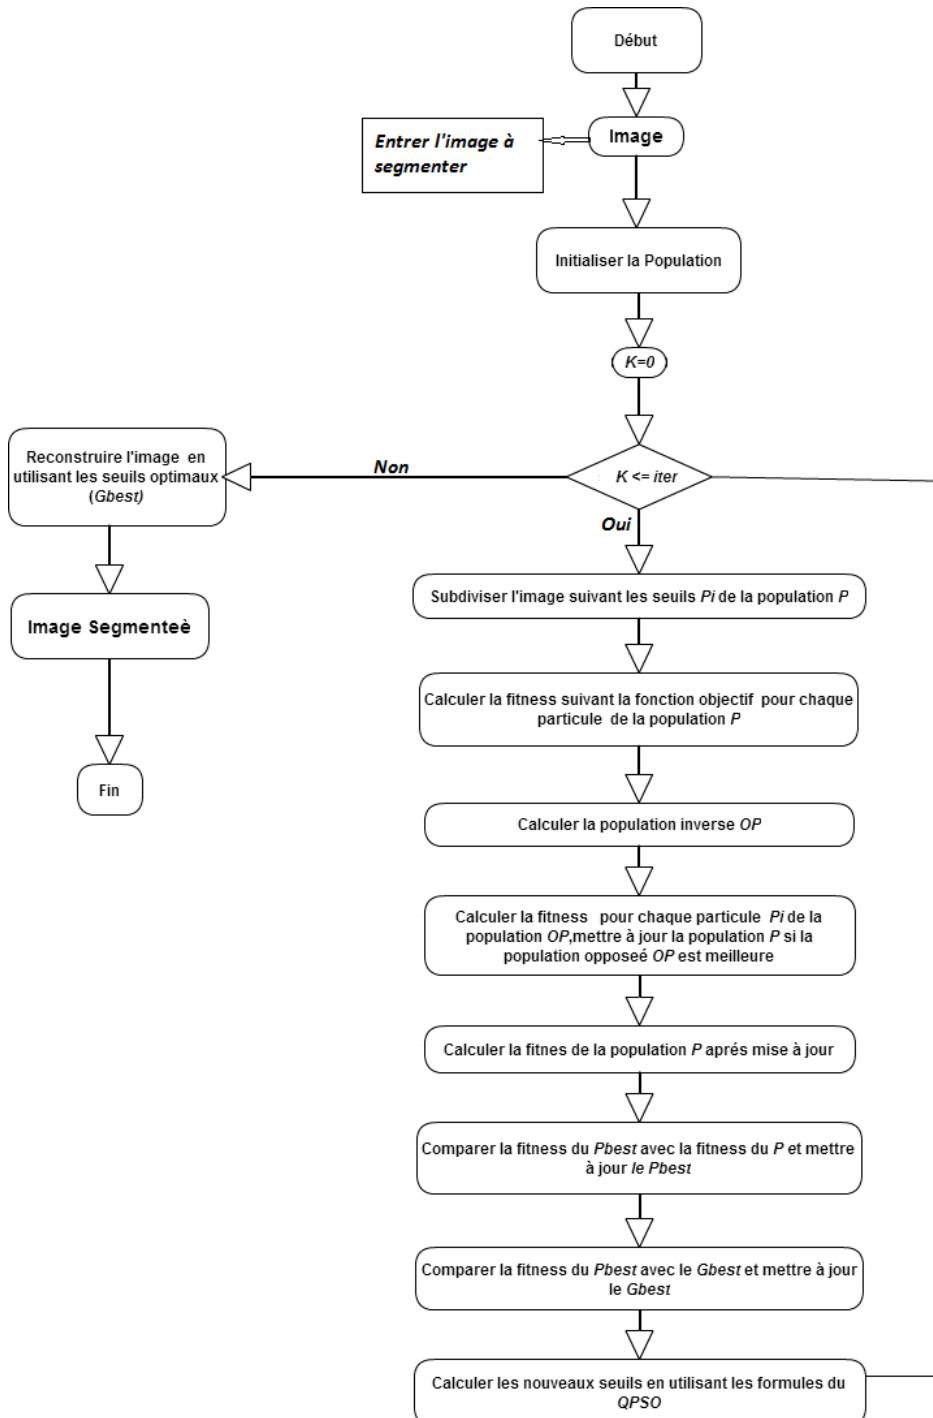


FIGURE 4.8 – Organigramme de la segmentation d'images médicales par l'algorithme OQPSO

Voici les étapes propre à l'approche OQPSO pour la segmentation d'images par seuillage :

Calculer la population opposée OP de la population P . Le calcule de la population opposée se fait en suivant la formule 4.13

$$op_i = a + b - p_i \quad (4.13)$$

Où $a = 0$ et $b = 255$ car les valeurs de notre domaine de recherche se situent entre 0 et 255. Après avoir calculé la population OP on doit encore trier chaque particule P_i de manière ascendante. Voici un exemple d'une population P et sa population opposée OP avant tri et après tri figure 4.9.

Population P	Population OP intermédiaire	Population OP																																																
<table border="1"> <tbody> <tr><td>4</td><td>23</td><td>200</td><td>241</td></tr> <tr><td>11</td><td>30</td><td>51</td><td>255</td></tr> <tr><td>46</td><td>61</td><td>122</td><td>251</td></tr> <tr><td>46</td><td>81</td><td>190</td><td>255</td></tr> </tbody> </table>	4	23	200	241	11	30	51	255	46	61	122	251	46	81	190	255	<table border="1"> <tbody> <tr><td>251</td><td>232</td><td>55</td><td>4</td></tr> <tr><td>244</td><td>225</td><td>204</td><td>0</td></tr> <tr><td>209</td><td>194</td><td>133</td><td>4</td></tr> <tr><td>209</td><td>174</td><td>65</td><td>0</td></tr> </tbody> </table>	251	232	55	4	244	225	204	0	209	194	133	4	209	174	65	0	<table border="1"> <tbody> <tr><td>4</td><td>55</td><td>232</td><td>251</td></tr> <tr><td>0</td><td>204</td><td>225</td><td>244</td></tr> <tr><td>4</td><td>133</td><td>194</td><td>209</td></tr> <tr><td>0</td><td>65</td><td>174</td><td>209</td></tr> </tbody> </table>	4	55	232	251	0	204	225	244	4	133	194	209	0	65	174	209
4	23	200	241																																															
11	30	51	255																																															
46	61	122	251																																															
46	81	190	255																																															
251	232	55	4																																															
244	225	204	0																																															
209	194	133	4																																															
209	174	65	0																																															
4	55	232	251																																															
0	204	225	244																																															
4	133	194	209																																															
0	65	174	209																																															

FIGURE 4.9 – Population P et population OP

Pour chaque particule P_i faire :

Calculer la fitness pour chacune des population P et OP .

Comparer la fitness de P et OP , mette à jour P si la fitness de OP est meilleur.

Calculer la nouvelle fitness de population P après mise à jour.

Le reste des étapes sont similaires au QPSO de base.

4.5 Conclusion

Dans ce chapitre, l'algorithme d'optimisation par essaim de particules quantiques (QPSO) a été présenté ainsi qu'une nouvelle variante proposé par nous même, qui introduit le concept d'apprentissage par complément. Les principes des approches QPSO et OQPSO ont été abordé ainsi que leurs adaptation pour résoudre le problème de la segmentation d'images médicales par seuillage. Dans le prochain chapitre on va voir les résultats expérimentaux issue de l'application de ces deux approches pour résoudre le problème de la segmentation d'images médicales.

Chapitre 5

Étude expérimentale

“L’expérience ne procure aucun plaisir, si ce n’est celui de la transmettre.”

-André Maurois

Sommaire

5.1	Introduction	67
5.2	Images de tests	67
5.3	Choix des paramètres	68
5.4	Résultats expérimentaux et discussion	69
5.4.1	Résultats visuels	69
5.4.2	Résultats numériques	71
5.5	Conclusion	78

5.1 Introduction

Après avoir présenté dans le chapitre précédent nos deux contributions, nous exposons dans ce chapitre les résultats expérimentaux obtenus de l'implémentation des approches QPSO et OQPSO pour la résolution du problème de la segmentation d'images médicales par seuillage.

Pour valider nos deux contributions, on a procédé par des études comparatives entre les résultats expérimentaux de nos deux approches QPSO et OQPSO et de deux autres approches puissantes qui sont l'algorithme des abeilles artificielles et sa variante contenant un terme guidé par le meilleur global (GABC). Ces deux approches ont été implémentées par nous même. L'algorithme de colonie d'abeilles artificielles a été appliqué pour la segmentation d'images par seuillage par Horng [2011], mais n'a pas été appliqué à la segmentations d'images médicales. Par contre l'algorithme GABC n'a jamais été utilisé pour la segmentation d'images par seuillage et cela sera notre troisième contribution.

5.2 Images de tests

L'imagerie médicale est en constante évolution. Les méthodes automatiques de traitement et d'analyse d'images se sont récemment multipliées pour assister l'expert dans l'analyse qualitative et quantitative de ces images, afin de faciliter leurs interprétation. La segmentation automatique des tissus du cerveau est devenue une étape fondamentale pour ces analyses dans de nombreuses pathologies cérébrales telles que la maladie d'*alzheimer* et la *schizophrénie*.

C'est pour cela qu'on a choisi d'utiliser des images médicales de type IRM. Ces images sont de type DICOM qui est une norme standard pour la gestion des images dans le domaine médical. On a converti ces images sous format *tif* pour pouvoir les manipuler dans l'environnement matlab, qu'on a utilisé pour l'implémentation des différentes approches en conservant les informations contenue dans ces images médicales.

La figure 5.1 présente les images utilisées pour les tests ainsi que leurs histogrammes respectives.

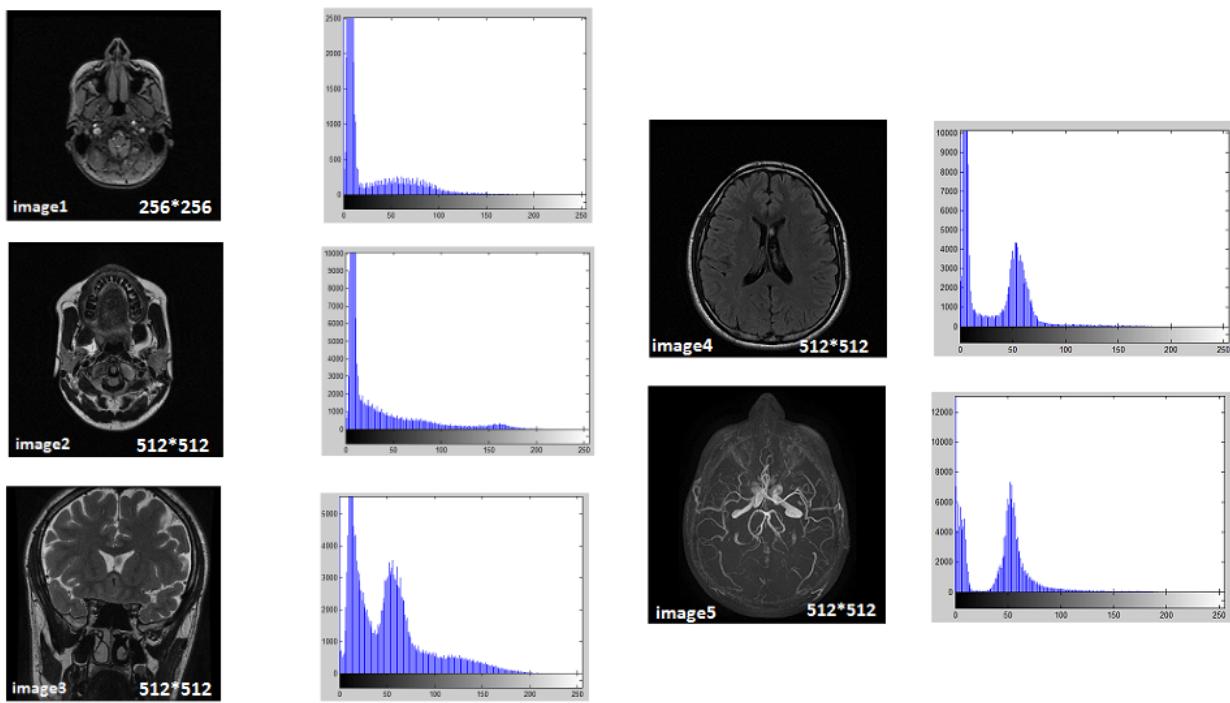


FIGURE 5.1 – Base d’images utilisées

5.3 Choix des paramètres

Le tableau 5.1 spécifie les paramètres dédiés aux algorithmes QPSO et OQPSO pour notre implémentation.

TABLE 5.1 – Paramètres des algorithmes QPSO et OQPSO

Nom du paramètre	Valeur numérique
Nombre d’exécutions : N_{exe}	30
Nombre d’itérations : $iter$	25
Nombre d’individus dans une population : N	50
Nombre de seuils dans un vecteur d’individus : M	[2,3,4]

L’algorithme QPSO possède un unique paramètre nommé β qui est *le coefficient de contraction expansion*. Le QPSO donne de meilleures performances en faisant varier la valeur du paramètre β . Après une série de tests, on a fixé la valeur de β comme suit : 1.0 au début de la recherche qui diminue jusqu’à 0.5 à la fin de la recherche. Cela donnera un bon équilibre entre l’exploration et de l’exploitation. Le calcul de la valeur de β se fera comme l’illustre la formule (5.1)

$$\beta = \beta_{Max} - ((\beta_{Max} - \beta_{Min}) * (k/iter)) \quad (5.1)$$

Où : $\beta_{Max} = 1.0$, $\beta_{Min} = 0.5$, $iter$ est le nombre maximum d’itérations et k est l’itération courante.

Le tableau 5.2 résume les paramètres dédiés aux algorithmes ABC et GABC.

La taille de la population dans l'algorithme ABC et GABC est la moitié de celle des algorithmes QPSO et OQPSO car ; dans les algorithmes ABC et GABC pour une seule itération le traitement et la mesure de la fitness des particules se font deux fois (dans la phase des abeilles employées et la phase des abeilles spectatrices).

TABLE 5.2 – Paramètres nécessaire à l'algorithme ABC GABC

Nom du paramètre	Valeur numérique
Nombre d'exécutions : N_{exe}	30
Nombre d'itérations : $iter$	25
Nombre d'individus dans une population : N	25
Nombre de seuils dans un vecteur d'individus : M	[2,3,4]

L'algorithme ABC et sa variante GABC possèdent un paramètre commun appelé *limite*. La valeur du paramètre *limite* sera fixée à 5. En plus du paramètre *limite*, l'algorithme GABC contient un terme guidé par le meilleur global comme vu dans la section (3.5.3) du chapitre 3, ce terme possède un paramètre appelé C qui est un nombre aléatoire entre 0 et 4. Le travail de Zhu et Kwong [2010] qui est l'application de l'algorithme GABC pour des fonctions benchmarks a déduit que la meilleure valeur du paramètre C est 1.5. Après avoir effectué une série de tests avec différentes valeurs du paramètre C pour l'adapter à notre problème qui est la segmentation d'images médicales par seuillage on a décidé de fixer la valeur de C à 0.25.

5.4 Résultats expérimentaux et discussion

Dans cette section on va analyser les différents résultats des tests sur les images médicales. On va commencer par les résultats visuels, ensuite les résultats numériques.

5.4.1 Résultats visuels

Voici quelques résultats de la segmentation de *l'image 1* issue de notre base de test par les différentes approche QPSO, ABC, GABC et OQPSO avec les fonctions objectif Kapur et Otsu (Figures 5.2 et 5.3). On a choisi d'afficher *l'image 1* segmenté par 4 seuils pour faire bien apparaître les différentes classes. Les résultats visuels pour tous les autres images avec tout les seuils sont détaillés dans l'annexe A.

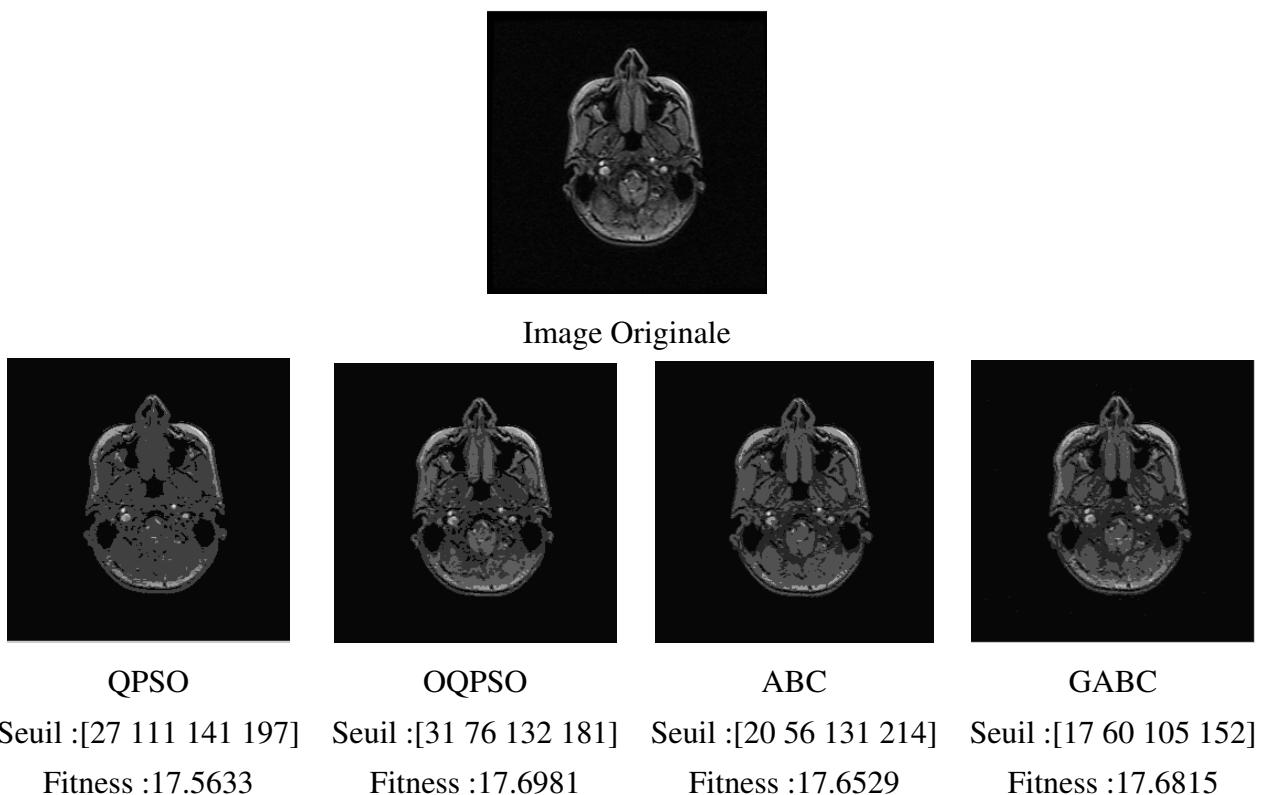


FIGURE 5.2 – *Image 1* segmentée par les différentes approches - fonction objectif **Kapur**

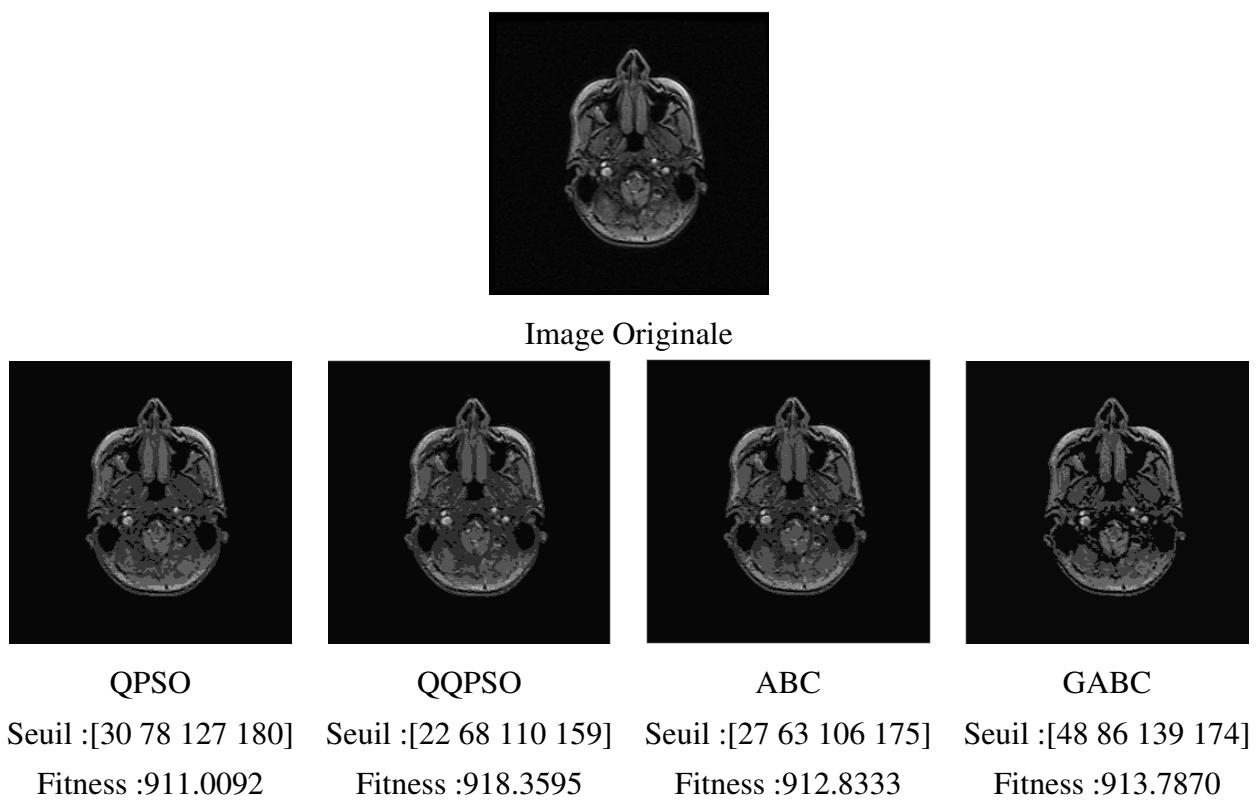


FIGURE 5.3 – *Image 1* segmentée par les différentes approches - fonction objectif **Otsu**

Toutes les approches ont donné une très bonne segmentation. La qualité visuelle de l'image segmentée ne peut pas déterminer qui est l'algorithme le plus performant, les 4 métaheuristiques sont performantes. Comme ces algorithmes se base sur la recherche stochastique, leur performance ne peut être jugée en une seule exécution. Donc, pour mesurer la stabilité et le comportement de ces algorithmes on a besoin de faire plusieurs exécutions. Dans la section suivante, on va analyser les résultats numériques de chaque approche pour différentes images avec différents nombres de seuils.

5.4.2 Résultats numériques

La moyenne et la variance entre les résultats obtenus par plusieurs exécutions donne une indication sur la stabilité de l'algorithme ; plus les résultats des différentes exécutions sont proches plus l'algorithme est stable.

Dans ce qui suit , on va présenter les tables des résultats des 30 exécutions des 4 approches en utilisant l'entropie de Kapur pour 2 seuils, 3 seuils et 4 seuils, Où *Mean* présente la moyenne de la meilleure fitness de chacune des 30 exécutions et *Var* présente l'écart type.

La table 5.3 présente les résultats de la segmentation d'images en se basant sur l'entropie de Kapur avec 2 seuils. On voit que l'algorithme OQPSO a donné la meilleures fitness dans la plupart des images. L'algorithme ABC a obtenu la meilleure fitness dans certaines images. On voit que la variance dans l'algorithme OQPSO et ABC est très petite voire inexiste ce qui veut dire que ces deux algorithmes sont relativement stables. Pour l'algorithme QPSO et GABC on voit qu'ils sont proches des algorithmes OQPSO et ABC mais ne les dépassent jamais.

TABLE 5.3 – Résultats de la méthode **Kapur** pour 2 seuils

Image \ Algorithme		QPSO	OQPSO	ABC	GABC
Image1	Mean	11.2321	11.2380	11.2374	11.2348
	Var	0.00628093	0.00226816	0.0033288	0.00481391
Image2	Mean	11.5481	11.5471	11.5511	11.5503
	Var	0.0039642	0.00361088	0.00144464	0.00256128
Image3	Mean	12.2066	12.2065	12.2067	12.2065
	Var	0.0003	0.000489148	0.000231527	0.000564848
Image4	Mean	11.5014	11.5024	11.5024	11.5019
	Var	0.00216294	0.000561455	0.00075307	0.00210546
Image5	Mean	11.4147	11.4157	11.4152	11.4149
	Var	0.00164564	0.000662514	0.00113541	0.00193581

Pour la segmentation d'images en 4 classes (Table 5.4), on voit que l'algorithme OQPSO a la meilleure fitness dans la plupart des images. L'algorithme GABC le suit. Par contre, les algorithmes ABC et QPSO sont juste derrières.

TABLE 5.4 – Résultats de la méthode **Kapur** pour 3 seuils

Algorithme \ Image		QPSO	OQPSO	ABC	GABC
Image1	Mean	14.5991	14.6054	14.6029	14.6034
	Var	0.00129842	0.00651686	0.000076721	0.0112002
Image2	Mean	14.9847	14.9868	14.9862	14.9856
	Var	0.00610417	0.00584293	0.00320917	0.00688693
Image3	Mean	15.3309	15.3287	15.3343	15.3357
	Var	0.0164367	0.02431	0.0098841	0.00961064
Image4	Mean	14.4820	14.4830	14.4818	14.4837
	Var	0.0165347	0.0164111	0.0190187	0.0111485
Image5	Mean	14.6011	14.6151	14.6082	14.6048
	Var	0.0228293	0.00760523	0.0122542	0.0176344

Pour la segmentation d'images en 5 classes (Table 5.5), on voit que l'algorithme GABC se montre performant dans la plupart des images. L'algorithme QPSO est très proche aussi, et des fois il dépasse l'algorithme GABC. Les algorithmes QPSO et ABC sont juste derrières.

TABLE 5.5 – Résultats de la méthode **Kapur** pour 4 seuils

Algorithme \ Image		QPSO	OQPSO	ABC	GABC
Image1	Mean	17.6435	17.6795	17.6769	17.6745
	Var	0.0525541	0.0350545	0.0397782	0.0374644
Image2	Mean	18.0042	18.0204	18.0090	18.0228
	Var	0.00467822	0.0190972	0.0226581	0.0114053
Image3	Mean	18.1051	18.1063	18.0976	18.1149
	Var	0.0237593	0.0276624	0.0335858	0.0267834
Image4	Mean	17.2355	17.2583	17.2417	17.2705
	Var	0.117457	0.097243	0.0657942	0.0744053
Image5	Mean	17.5058	17.5433	17.4856	17.5199
	Var	0.0834486	0.0187462	0.0675008	0.0314626

Les tables 5.6,5.7 et 5.8 présentent les résultats des 30 exécution des 4 approches en utilisant la variance inter-classes d'Otsu pour deux, trois et quatre seuils respectivement.

Pour la segmentation d'images en 3 classes en utilisant la variance inter-classes d'Otsu (Table 5.6), on voit que l'algorithme OQPSO donne la meilleure fitness dans la plupart des images. Dans l'*image 2*, les algorithmes QPSO, OQPSO et ABC ont la même fitness. Dans une des images aussi l'algorithme QPSO a donné une valeur de fitness meilleure que l'algorithme OQPSO, l'algorithme GABC est toujours en dernière position.

TABLE 5.6 – Résultats de la méthode **Otsu** pour 2 seuils

Image \ Algorithme		QPSO	OQPSO	ABC	GABC
Image1	Mean	848.7897	849.0058	848.9982	848.7520
	Var	0.1996	0.105951	0.0835582	0.60485
Image2	Mean	1.4125e+003	1.4125e+003	1.4125e+003	1.4120e+003
	Var	0.350947	0.207094	0.296106	0.690231
Image3	Mean	1.5023e+003	1.5024e+003	1.5023e+003	1.5022e+003
	Var	0.240081	0.164514	0.240266	0.43213
Image4	Mean	844.7442	844.7481	844.7623	844.6378
	Var	0.0504699	0.0456555	0.0171964	0.323469
Image5	Mean	1.1876e+003	1.1858e+003	1.1739e+003	1.1550e+003
	Var	0.0935507	0.140773	30.661	40.3177

Pour la segmentation d'images en 4 classes (Table 5.7), on voit que l'algorithme OQPSO a dans la plupart du temps la meilleure fitness, l'algorithme GABC le dépasse dans certaines images, les algorithmes QPSO, ABC sont derrières mais ils sont proches des algorithmes OQPSO et GABC.

TABLE 5.7 – Résultats de la méthode **Otsu** pour 3 seuils

Image \ Algorithme		QPSO	OQPSO	ABC	GABC
Image1	Mean	891.4997	892.7635	892.1297	890.8063
	Var	3.8924	1.19025	1.14182	3.53088
Image2	Mean	1.4761e+003	1.4785e+003	1.4777e+003	1.4768e+003
	Var	3.42024	1.51385	1.37163	3.34313
Image3	Mean	1.7057e+003	1.7173e+003	1.6993e+003	1.6818e+003
	Var	35.7831	8.73374	8.73374	56.761
Image4	Mean	893.2671	906.3505	898.2543	889.8084
	Var	15.4653	13.2608	13.2608	17.9694
Image5	Mean	1.4485e+003	1.4723e+003	1.4279e+003	1.3832e+003
	Var	41.4266	30.0323	38.0123	93.3301

Pour la segmentation d'images en 5 classes (Table 5.8). On remarque que l'OQPSO donne la meilleure fitness dans toutes les images à part *l'image2*. L'algorithme ABC est proche de l'algorithme OQPSO. Par contre l'algorithme QPSO ,GABC sont un peu loin derrières.

TABLE 5.8 – Résultats de la méthode **Otsu** pour 4 seuils

Image \ Algorithme		QPSO	OQPSO	ABC	GABC
Image1	Mean	915.8651	919.2577	918.5236	917.4748
	Var	6.43318	5.42684	4.54849	5.01823
Image2	Mean	1.5195e+003	1.5252e+003	1.5257e+003	1.5236e+003
	Var	10.1931	9.91207	9.77906	9.8234
Image3	Mean	1.8330e+003	1.9083e+003	1.870778e+003	1.8323e+003
	Var	73.6978	48.6302	70.2092	70.4626
Image4	Mean	928.9782	940.7538	928.8470	924.2740
	Var	23.3119	18.6389	24.3935	24.1684
Image5	Mean	1.64044e+003	1.6912e+003	1.6541e+003	1.512245e+003
	Var	130.857	97.1749	109.62	152.43

Pour une analyse plus fine du comportement de chaque algorithme, on va étudier l'évolution de la fitness de chacune des quatre approches.

Les Figures ci-dessous illustrent l'évolution de la fitness pour les quatre approches en utilisant les fonctions Kapur et Otsu pour la segmentation d'images avec 4 seuils. On a choisi d'afficher les graphes de 4 seuils pour bien voir l'évolution de la fitness et la différence d'évolution de la fitness entre les 4 algorithmes.

La meilleure fitness $fit(Gbest)$ est en rouge représentée dans le graphe par *Gbest*, la fitness moyenne $fit(Mbest)$ est en bleu représentée dans le graphe par *Mbest* et la mauvaise fitness $fit(Gworst)$ est en vert représentée dans le graphe par *Gworst*.

La figure 5.4 présente l'évolution de la fitness pour l'approche ABC. Dans le graphe de la fonction kapur, on voit que l'algorithme ABC évolue très vite dans les 5 premières itérations. Puis il stagne dans les itérations 5 à 12 et il reprend son évolution dans l'itération 13. Dans le graphe de la fonction Otsu l'évolution se fait petit à petit dans les 25 itérations. Donc, on peut dire que la fitness d'Otsu a permis une bonne flexibilité de l'algorithme ABC.

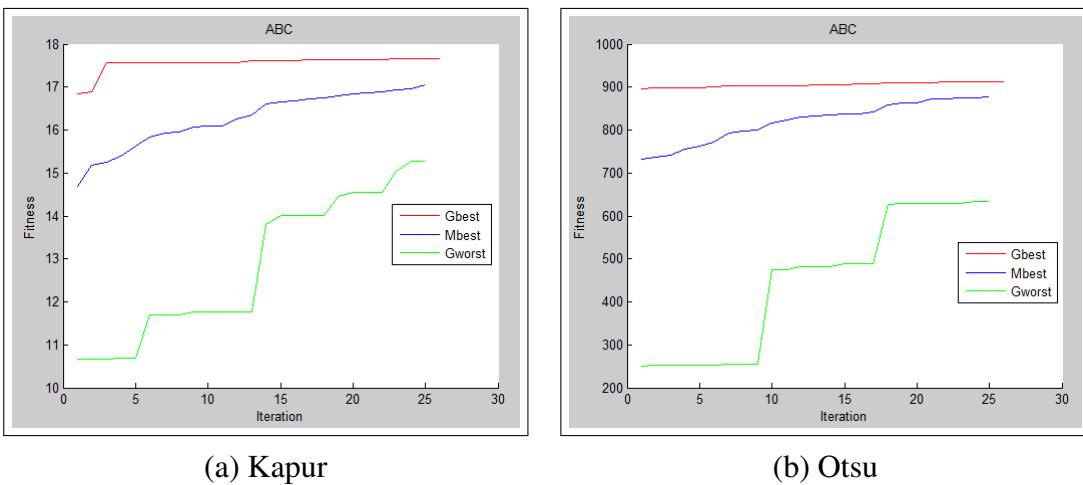


FIGURE 5.4 – Évolution de la fitness dans l'algorithme ABC

La figure 5.5 présente l'évolution de la fitness pour l'approche GABC. Dans le graphe de la fonction Kapur on remarque que la meilleure fitness évolue petit à petit aux cours des itérations. Dans le graphe de la fonction Otsu on voit que la meilleure fitness évolue mais stagne dans beaucoup d'endroits. La moyenne des fitness et la mauvaise fitness sont aussi guidées par le meilleur global.

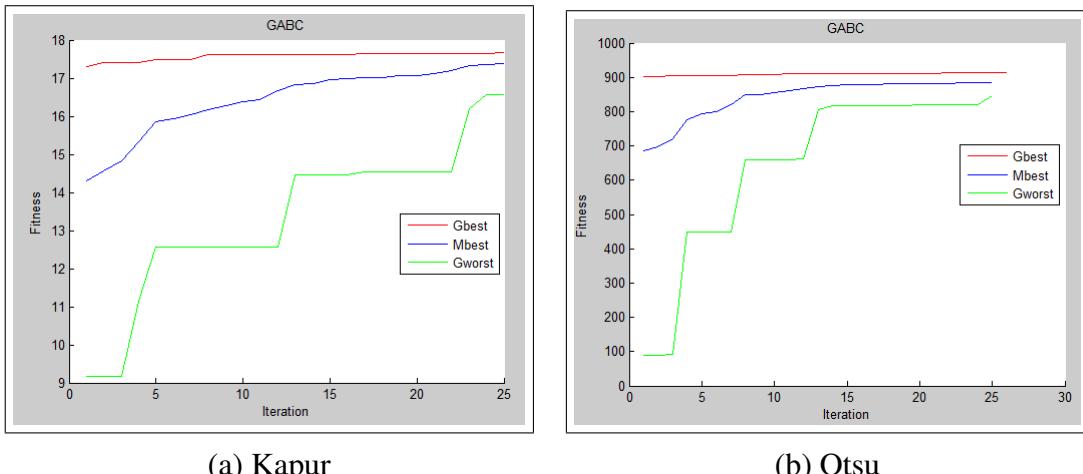


FIGURE 5.5 – Évolution de la fitness dans l'algorithme GABC

La figure 5.6 présente l'évolution de la fitness pour l'approche QPSO. Dans le graphe de la fonction Kapur, l'évolution de la fitness se fait petit à petit. Dans la fonction Otsu on voit que l'algorithme QPSO reste stagné c'est à dire qu'il est tombé dans des optima locaux.

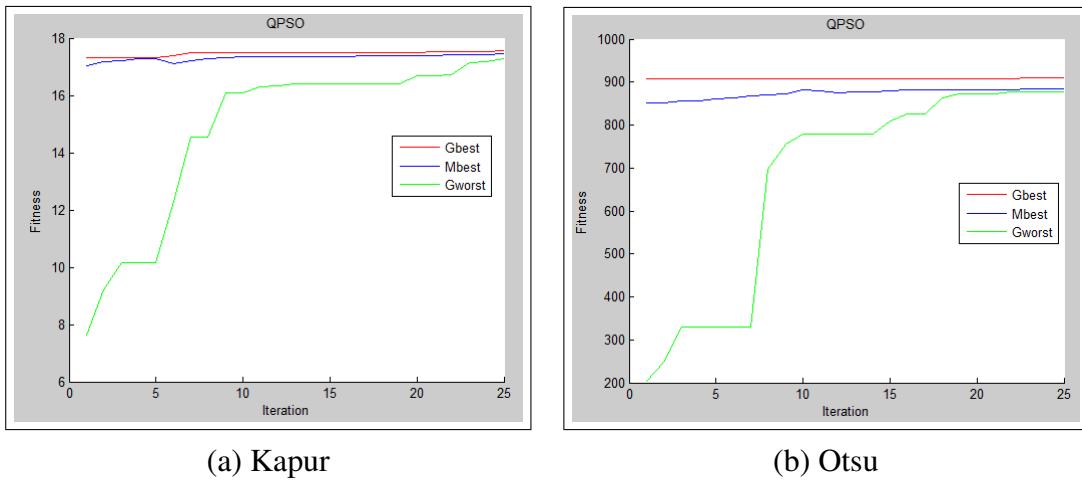


FIGURE 5.6 – Évolution de la fitness dans l'algorithme QPSO

La figure 5.7 présente l'évolution de la fitness pour l'approche OQPSO. Dans le graphe de la fonction Kapur on voit que l'évolution de la fitness se fait doucement aux cours des itérations. Pour la fonction Otsu on voit que l'algorithme reste stagné dans les itérations 1 à 5. après l'algorithme OQPSO commence à évoluer.

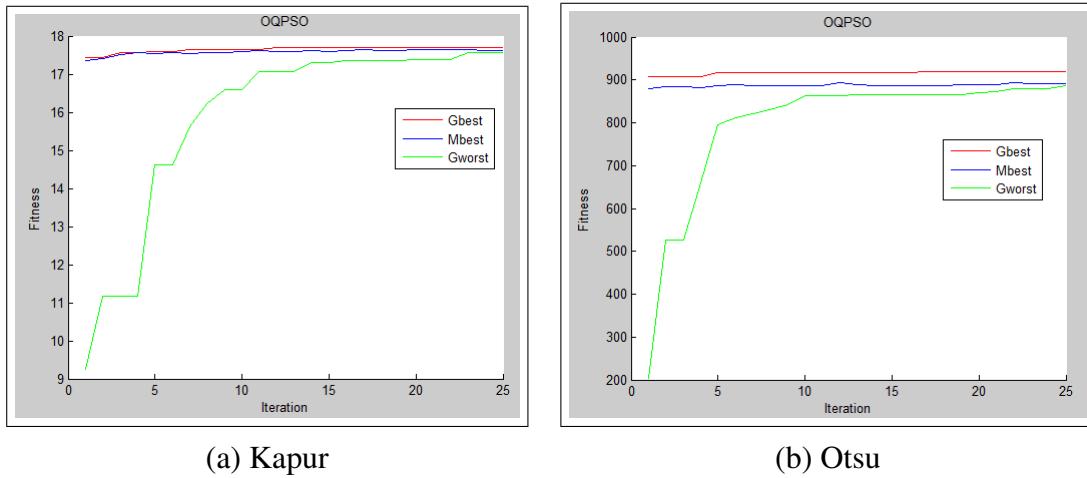


FIGURE 5.7 – Évolution de la fitness dans l'algorithme OQPSO

La figure 5.8 présente l'évolution de la meilleure fitness en utilisant la fonction Kapur des 4 approches qui segmente *l'image 1* en 5 classes. On voit que l'évolution du OQPSO est meilleure que l'algorithme QPSO de base.

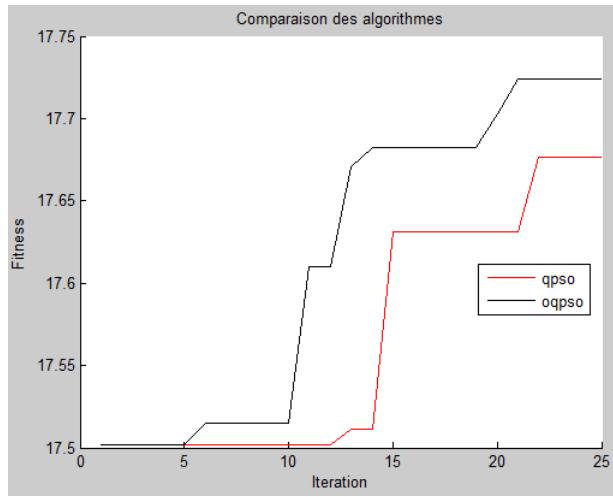


FIGURE 5.8 – Comparaison de l'algorithme QPSO, OQPSO

La figure 5.9 représente l'évolution de la meilleure fitness en utilisant la fonction Otsu des 4 approches qui segmente *l'image 1* en 5 classes. On peut dire que l'algorithme OQPSO est le plus performant entre les 4 approches. On voit aussi qu'il a réglé le problème de convergence prématuée du QPSO classique.

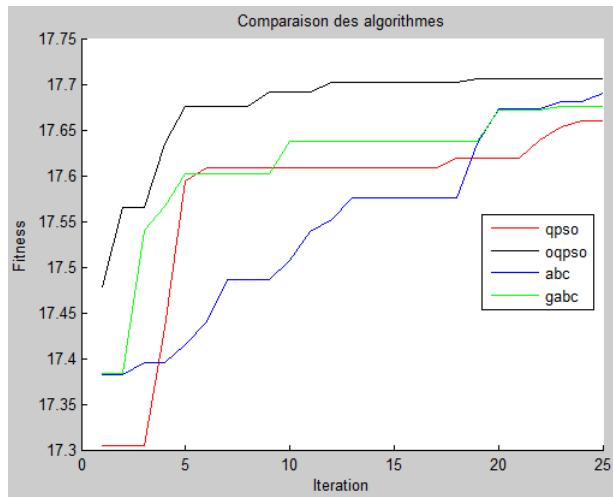


FIGURE 5.9 – Comparaison des 4 approches

A partir des résultats numériques et graphiques des quartes approches on peut dire que l'algorithme OQPSO est le plus performant entre les 4 approches car il se montre stable et performant avec les deux fonctions objectif quelque soit le nombre de seuils. On peut dire que l'apprentissage par complément a permis d'accélérer la vitesse de convergence.

Les algorithmes ABC et GABC sont instables. Des fois l'algorithme ABC dépasse l'algorithme GABC et des fois l'algorithme GABC dépasse l'algorithme ABC. Comme l'algorithme GABC est guidé par le meilleur global, il doit être meilleur que l'algorithme ABC. On peut dire donc que

l'algorithme GABC a perdu sa performance dans le domaine discret.

L'algorithme QPSO est performant mais devant les approches ABC et GABC qui sont des approches très puissantes il se montre faible. Son principal problème est la convergence prématuée. L'introduction de l'apprentissage par complément dans le QPSO a pu à pallier à cette limite.

5.5 Conclusion

Dans ce chapitre, nous avons exposé les résultats expérimentaux obtenus de l'implémentation des algorithmes QPSO, OQPSO, ABC et GABC pour la résolution du problème de la segmentation d'images médicales par seuillage. Les résultats obtenus ont prouvé que l'algorithme OQPSO est meilleur que les algorithmes QPSO, ABC et GABC.

En conclusion on peut dire que l'approche OQPSO a pu pallier à la limite du QPSO qui est la convergence prématuée. L'algorithme OQPSO se montre plus stable et plus performant pas rapport aux algorithmes QPSO, ABC et GABC.

Appendices

Annexe A

Résultats des images segmentées

la figure A.1 présente la base d'images médicales , la figure A.2 présente d'autre type d'images utilisées.

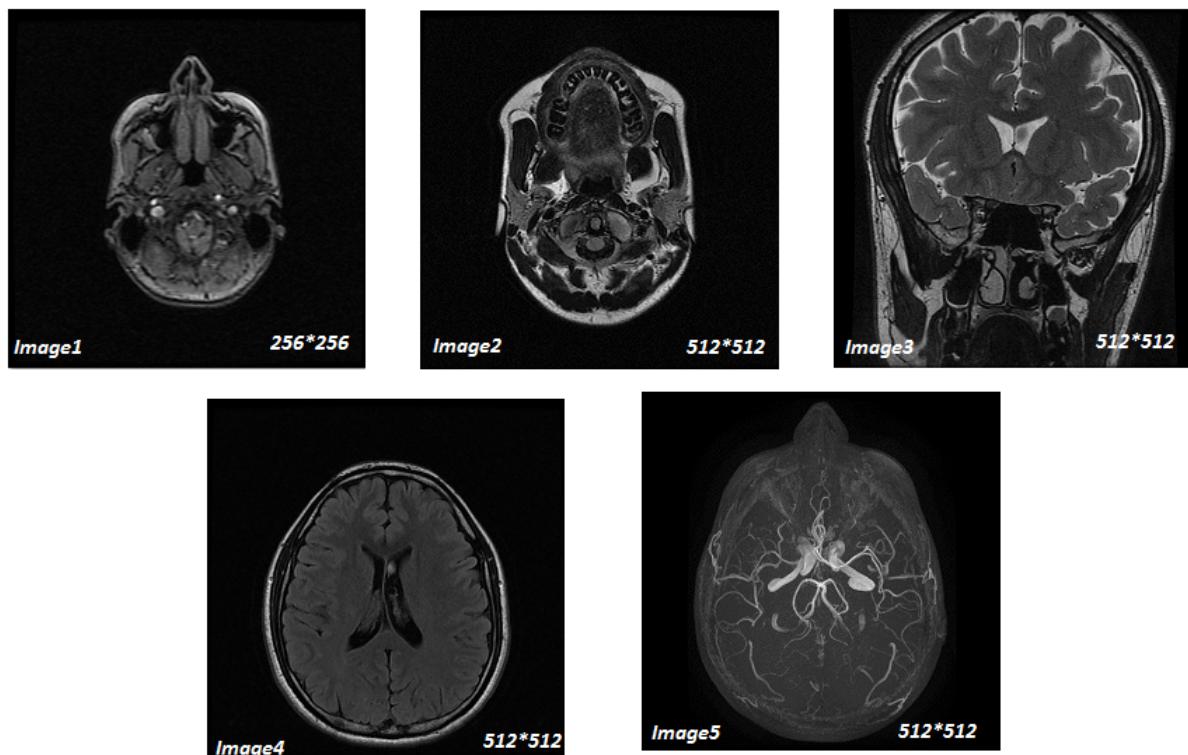


FIGURE A.1 – Images médicales utilisées pour les tests



FIGURE A.2 – Autre type d'images utilisées pour les tests

L'image *Peppers* a été converti en niveaux de gris par une commande matlab, puis segmentée par les 4 approches comme les autre images de tests.

TABLE A.1 – Image1 segmentée par les 4 approches avec la fonction objectif **Kapur**

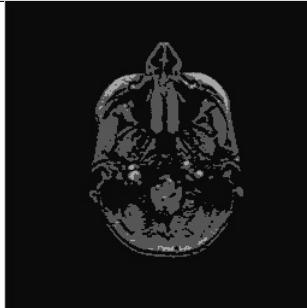
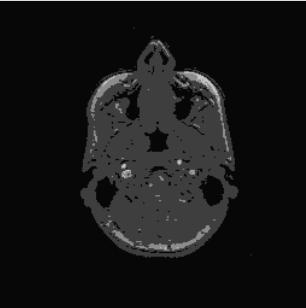
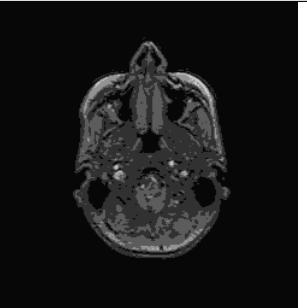
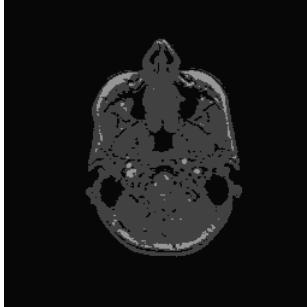
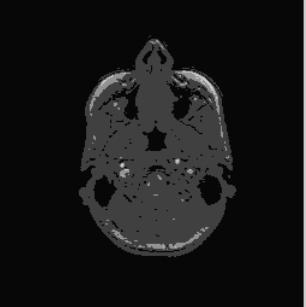
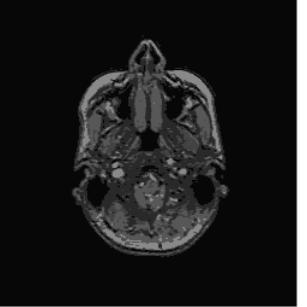
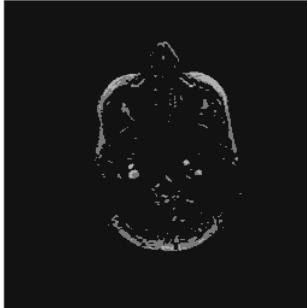
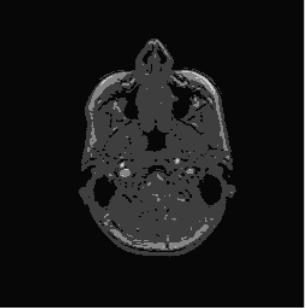
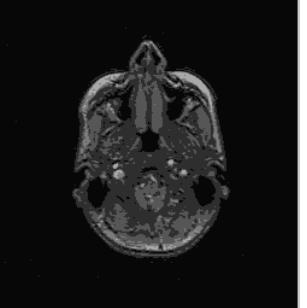
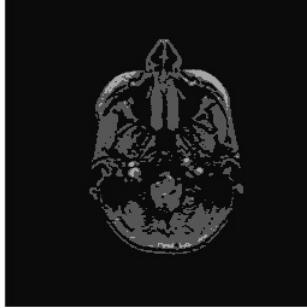
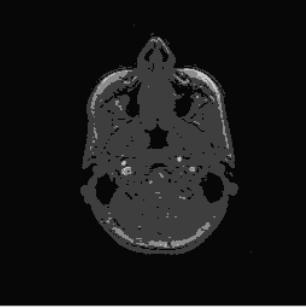
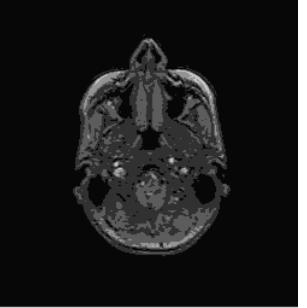
Approches	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[62 142]	Seuil :[19 118 176]	Seuil :[21 75 128 178]
	Fitness=11.2167	Fitness=14.6066	Fitness=17.7041
OQPSO			
	Seuil :[26 122]	Seuil :[20 126 181]	Seuil :[20 60 74 108]
	Fitness=11.2388	Fitness=14.6123	Fitness=17.6604
ABC			
	Seuil :[102 154]	Seuil :[24 110 182]	Seuil :[17 71 110 146]
	Fitness=11.2388	Fitness=14.6088	Fitness=17.7052
GABC			
	Seuil :[62 142]	Seuil :[19 118 176]	Seuil :[21 75 128 178]
	Fitness=11.2167	Fitness=14.6066	Fitness=17.7041

TABLE A.2 – Image2 segmentée par les 4 approches avec la fonction objectif **Kapur**

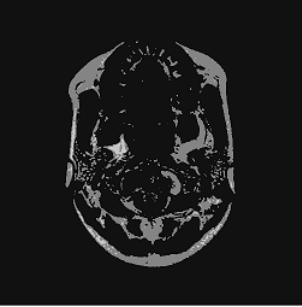
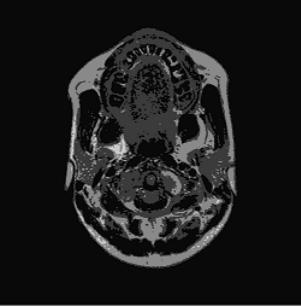
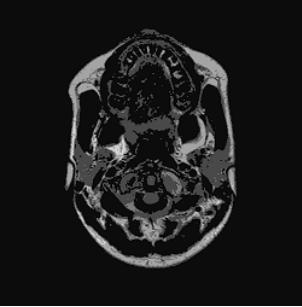
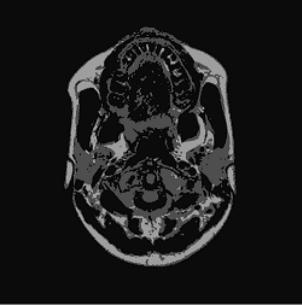
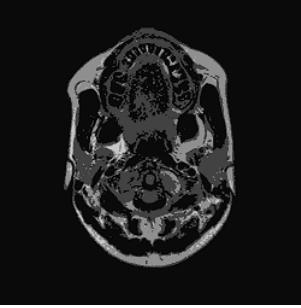
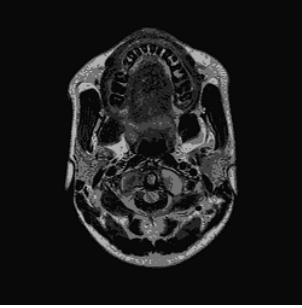
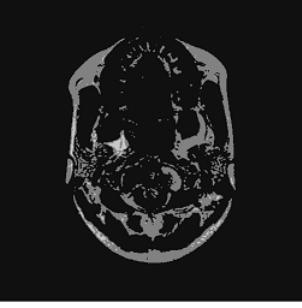
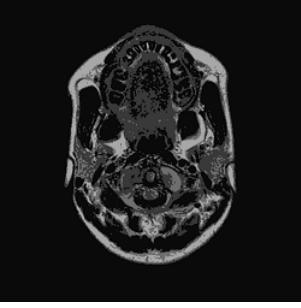
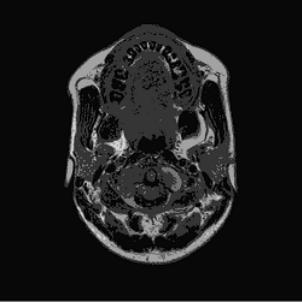
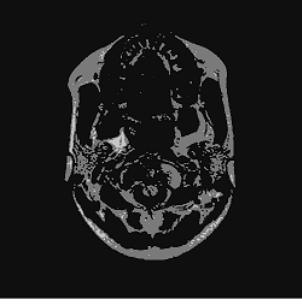
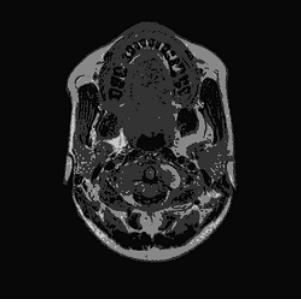
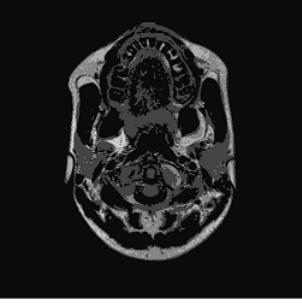
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[90 183]	Seuil :[33 96 190]	Seuil :[51 103 146 194]
	Fitness=11.5517	Fitness=14.9880	18.0314
OQPSO			
	Seuil :[49 124]	Seuil :[39 105 183]	Seuil :[28 52 82 160]
	Fitness=11.5490	Fitness=14.9876	Fitness=18.0333
ABC			
	Seuil :[86 184]	Seuil :[36 86 144]	Seuil :[26 95 140 196]
	Fitness=11.5517	Fitness=14.9890	Fitness=18.0317
GABC			
	Seuil :[79 181]	Seuil :[24 94 184]	Seuil :[43 104 162 195]
	Fitness=11.5516	Fitness=14.9885	Fitness=18.0379

TABLE A.3 – Image3 segmentée par les 4 approches avec la fonction objectif **Kapur**

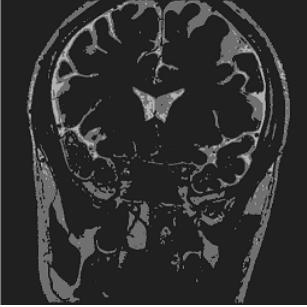
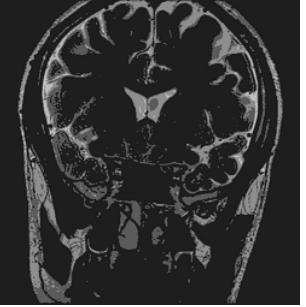
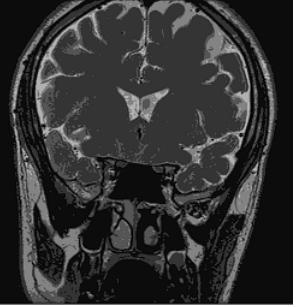
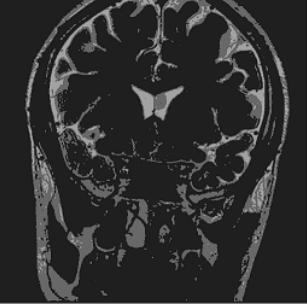
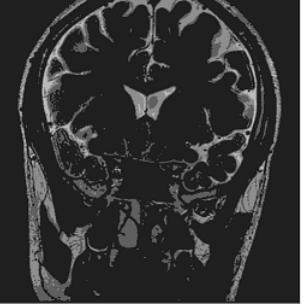
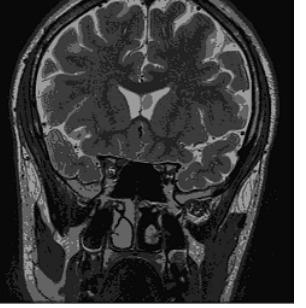
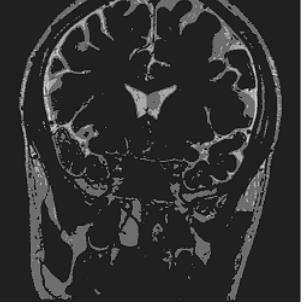
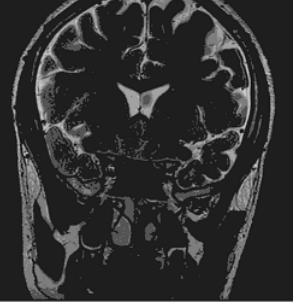
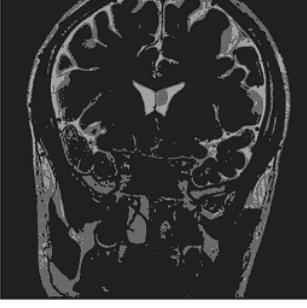
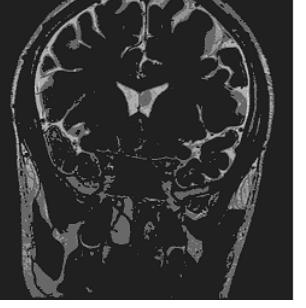
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[79 161]	Seuil :[71 121 177]	Seuil :[30 70 108 162]
	Fitness=12.2065	15.3401	Fitness=18.0954
OQPSO			
	Seuil :[75 144]	Seuil :[74 122 172]	Seuil :[20 51 74 133]
	Fitness=12.2068	Fitness=15.3442	Fitness=18.0967
ABC			
	Seuil :[80 168]	Seuil :[77 154 197]	Seuil :[70 107 148 188]
	Fitness=12.2068	Fitness=15.3408	Fitness=18.1311
GABC			
	Seuil :[76 144]	Seuil :[18 85 172]	Seuil :[77 139 159 209]
	Fitness= 12.2068	Fitness=15.3391	Fitness=18.1197

TABLE A.4 – Image4 segmentée par les 4 approches avec la fonction objectif **Kapur**

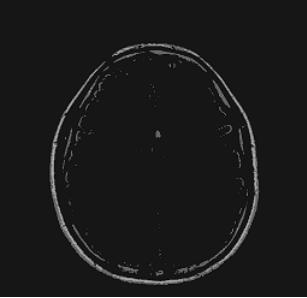
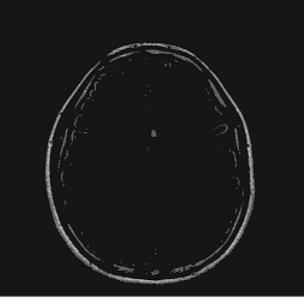
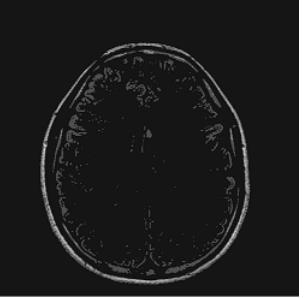
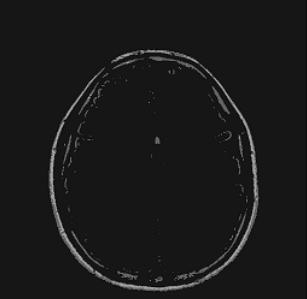
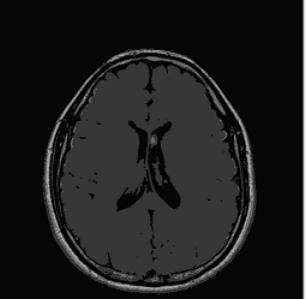
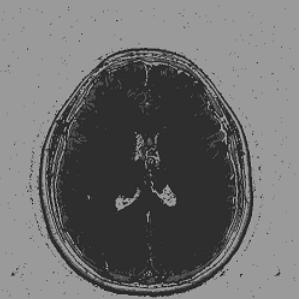
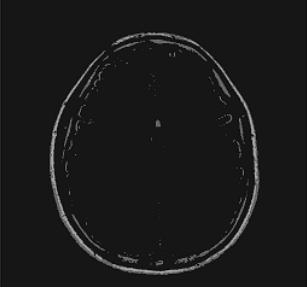
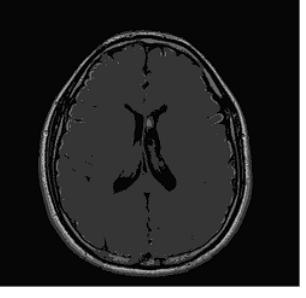
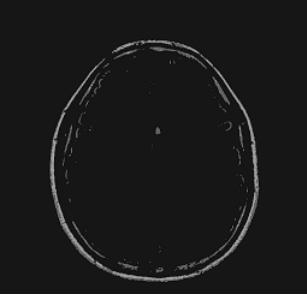
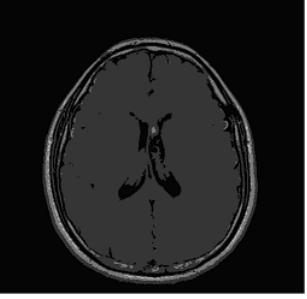
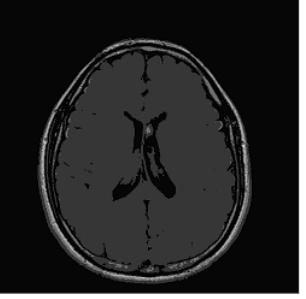
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[76 140]	Seuil :[76 130 174]	Seuil :[67 114 162 196]
	Fitness=11.5018	Fitness=14.4949	Fitness=17.3248
OQPSO			
	Seuil :[76 136]	Seuil :[32 82 140]	Seuil :[9 69 107 128]
	Fitness=11.5027	Fitness=14.4765	Fitness=17.2548
ABC			
	Seuil :[76 140]	Seuil :[85 130 201]	Seuil :[26 75 143 221]
	Fitness=11.5027	Fitness=14.4877	Fitness=17.2211
GABC			
	Seuil :[78 129]	Seuil :[20 84 175]	Seuil :[28 84 147 210]
	Fitness=11.5027	Fitness=14.4897	Fitness=17.2248

TABLE A.5 – Image5 segmentée par les 4 approches avec la fonction objectif **Kapur**

Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[83 143]	Seuil :[115 154 215]	Seuil :[69 117 164 199]
	Fitness=11.4159	Fitness=14.6089	Fitness=17.5382
OQPSO			
	Seuil :[80 142]	Seuil :[81 131 195]	Seuil :[73 131 201 223]
	Fitness=11.4159	Fitness=14.6182	Fitness=17.4917
ABC			
	Seuil :[87 153]	Seuil :[34 84 139]	Seuil :[62 79 128 200]
	Fitness=11.4159	Fitness=14.5909	Fitness=17.5174
GABC			
	Seuil :[54 136]	Seuil :[85 155 216]	Seuil :[76 122 167 230]
	Fitness=11.4144	Fitness=14.6088	Fitness=17.5341

TABLE A.6 – Lena segmentée par les 4 approches avec la fonction objectif **Kapur**

Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[166 178]	Seuil :[86 133 175]	Seuil :[79 132 177 208]
	Fitness=12.35	Fitness=15.3275	Fitness=17.9710
OQPSO			
	Seuil :[104 167]	Seuil :[85 148 184]	Seuil :[88 150 184 219]
	Fitness=12.3529	Fitness=15.3202	Fitness=17.9713
ABC			
	Seuil :[113 186]	Seuil :[79 114 190]	Seuil :[64 97 138 81]
	Fitness=12.3535	Fitness=15.3218	Fitness=17.9802
GABC			
	Seuil :[95 165]	Seuil :[62 111 166]	Seuil :[105 149 183 205]
	Fitness=12.3535	Fitness=15.3192	Fitness=18.0089

TABLE A.7 – Peppers segmentée par les 4 approches avec la fonction objectif **Kapur**

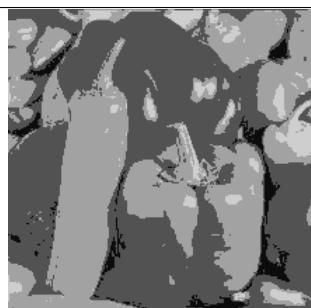
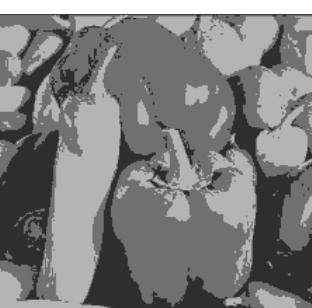
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[75 143]	Seuil :[60 120 177]	Seuil :[54 105 151 195]
	Fitness=12.6114	Fitness=15.6623	Fitness=18.5677
OQPSO			
	Seuil :[76 147]	Seuil :[62 114 162]	Seuil :[50 89 134 177]
	Fitness=12.6114	Fitness=15.6625	Fitness=18.5293
ABC			
	Seuil :[76 149]	Seuil :[75 148 191]	Seuil :[18 129 195 236]
	Fitness=12.6114	Fitness=15.6579	Fitness=18.5478
GABC			
	Seuil :[80 155]	Seuil :[75 146 223]	Seuil :[27 42 75 143]
	Fitness=12.6113	Fitness=15.6599	Fitness=18.4633

TABLE A.8 – Image1 segmentée par les 4 approches avec la fonction objectif **Otsu**

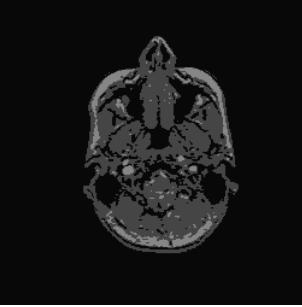
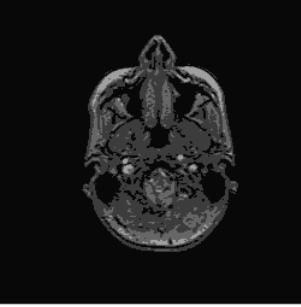
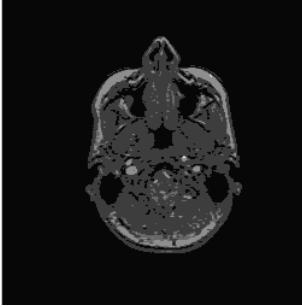
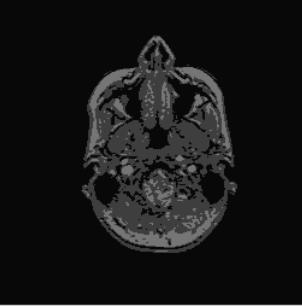
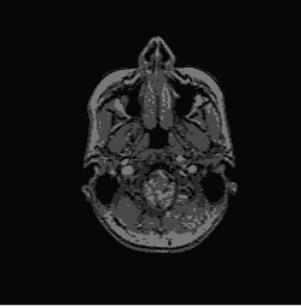
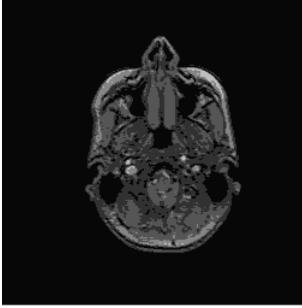
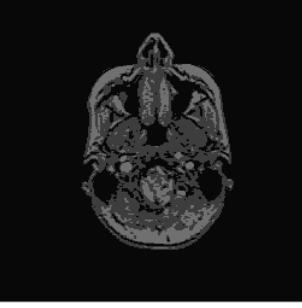
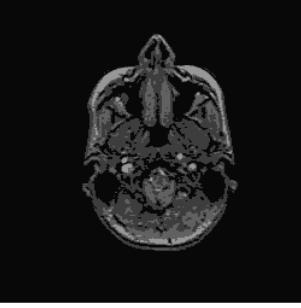
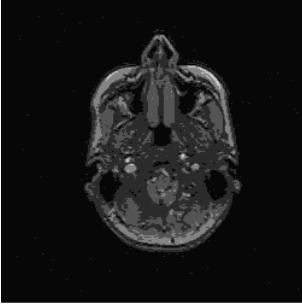
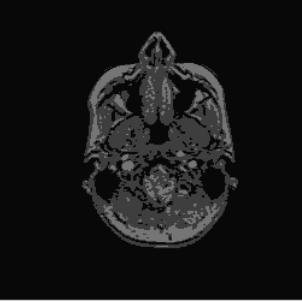
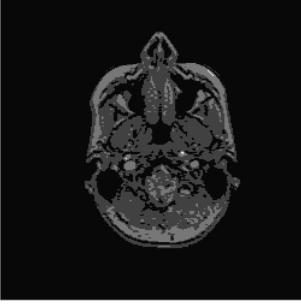
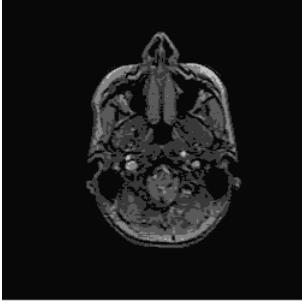
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[40 105]	Seuil :[35 86 135]	Seuil :[28 96 114 239]
	Fitness=847.8315	Fitness=888.9337	Fitness=900.9201
OQPSO			
	Seuil :[35 91]	Seuil :[27 53 93]	Seuil :[28 68 111 171]
	Fitness=848.9707	Fitness=892.5224	Fitness=917.6742
ABC			
	Seuil :[37 86]	Seuil :[40 83 123]	Seuil :[15 68 106 182]
	Fitness=848.9707	Fitness=891.2401	Fitness=927.6336
GABC			
	Seuil :[37 91]	Seuil :[39 93 235]	Seuil :[38 75 110 172]
	Fitness=848.9571	Fitness=892.2373	Fitness=914.1670

TABLE A.9 – Image2 segmentée par les 4 approches avec la fonction objectif **Otsu**

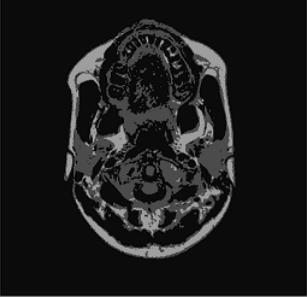
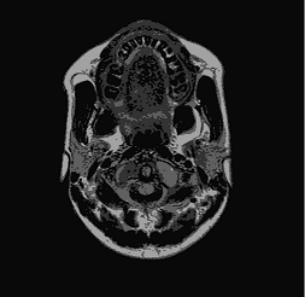
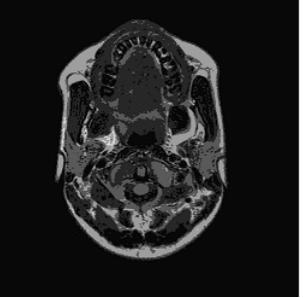
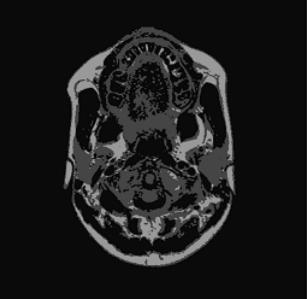
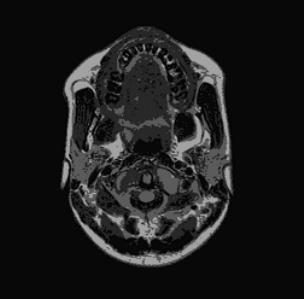
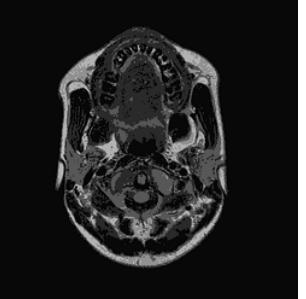
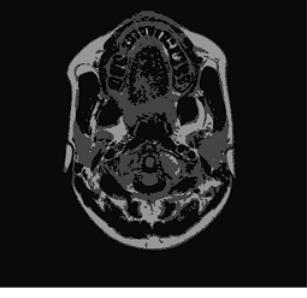
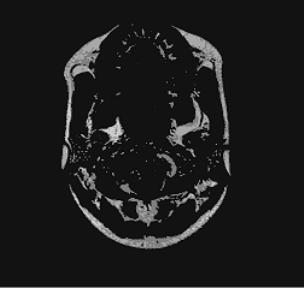
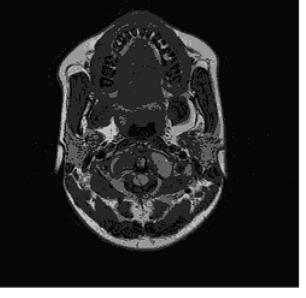
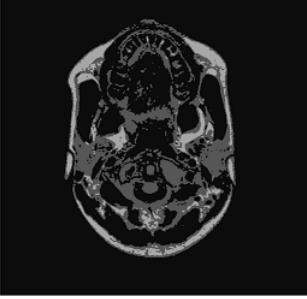
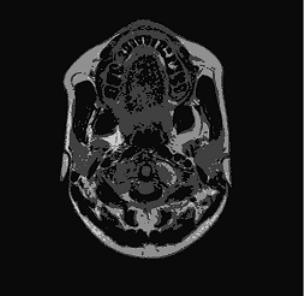
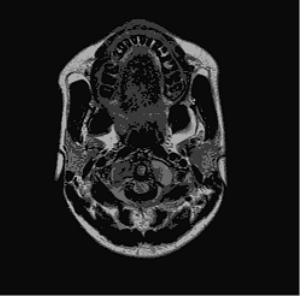
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[46 123]	Seuil :[34 73 132]	Seuil :[21 65 126 210]
	Fitness=1.4118e+003	Fitness=1.4779e+003	Fitness=1.5114e+003
OQPSO			
	Seuil :[40 115]	Seuil :[23 65 133]	Seuil :[26 65 125 162]
	Fitness=1.4126e+003	Fitness=1.4787e+003	Fitness=1.5208e+003
ABC			
	Seuil :[40 110]	Seuil :[99 156 191]	Seuil :[16 74 130 173]
	Fitness=1.4126e+003	Fitness=1.4775e+003	Fitness=1.5114e+003
GABC			
	Seuil :[53 143]	Seuil :[37 105 186]	Seuil :[38 83 137 156]
	Fitness=1.4126e+003	Fitness=1.4771e+003	Fitness=1.5211e+003

TABLE A.10 – Image3 segmentée par les 4 approches avec la fonction objectif **Otsu**

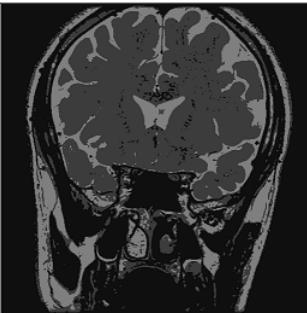
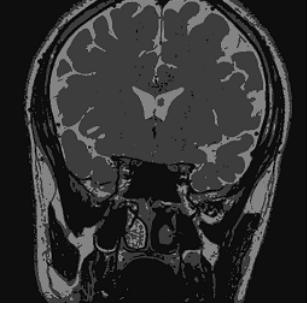
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[41 89]	Seuil :[36 92 147]	Seuil :[35 76 125 172]
	Fitness=1.5024e+003	Fitness=1.7181e+003	Fitness=1.8189e+003
OQPSO			
	Seuil :[37 97]	Seuil :[35 83 147]	Seuil :[34 66 110 191]
	Fitness=1.5024e+003	Fitness= 1.7174e+003	Fitness=1.7997e+003
ABC			
	Seuil :[38 99]	Seuil :[44 82 128]	Seuil :[34 87 146 156]
	Fitness=1.5024e+003	Fitness=1.7150e.003	Fitness=1.8864e+003
GABC			
	Seuil :[52 103]	Seuil :[42 114 169]	Seuil :[31 81 129 192]
	Fitness=1.5024e+003	Fitness=1.7209e+003	Fitness=1.7914e+003

TABLE A.11 – Image4 segmentée par les 4 approches avec la fonction objectif **Otsu**

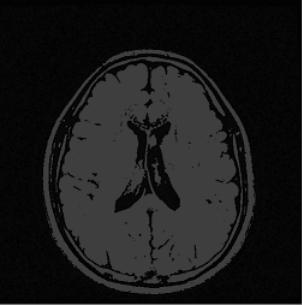
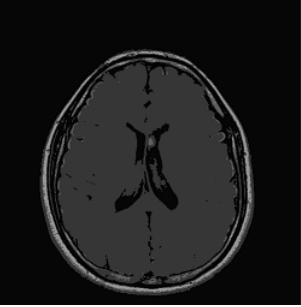
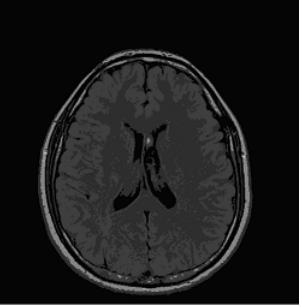
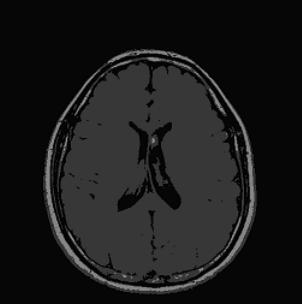
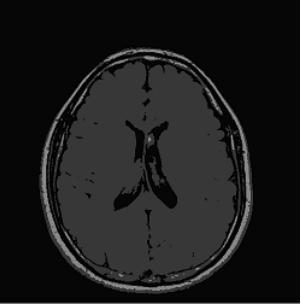
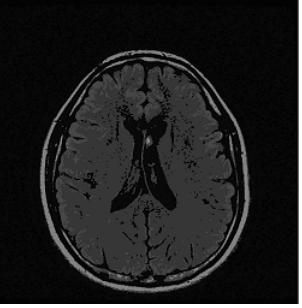
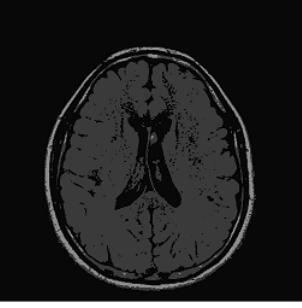
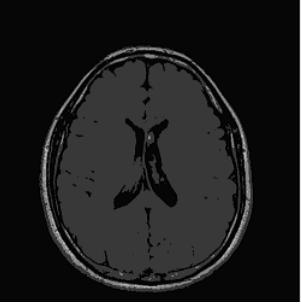
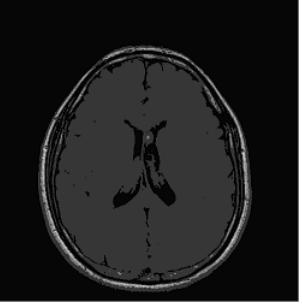
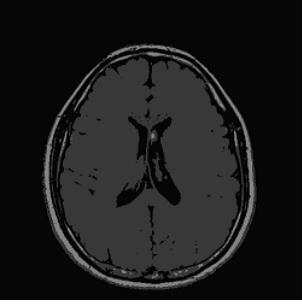
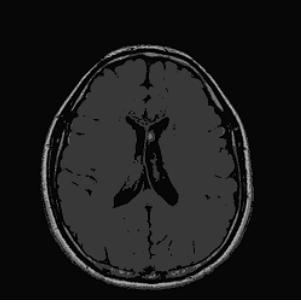
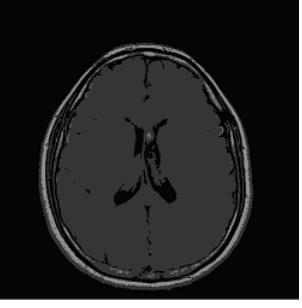
Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[4 40]	Seuil :[27 78 121]	Seuil :[21 55 96 205]
	Fitness=844.6715	Fitness=876.7372	Fitness=934.0564
OQPSO			
	Seuil :[31 94]	Seuil :[0 30 98]	Seuil :[4 45 64 91]
	Fitness=844.7658	Fitness=915.7507	Fitness=958.3122
ABC			
	Seuil :[45 106]	Seuil :[32 102 177]	Seuil :[23 101 150 189]
	Fitness=844.7658	Fitness=894.1268	Fitness=953.7460
GABC			
	Seuil :[34 92]	Seuil :[38 89 139]	Seuil :[20 83 108 253]
	Fitness=844.7658	Fitness=917.6960	Fitness=938.9686

TABLE A.12 – Image5 segmentée par les 4 approches avec la fonction objectif **Otsu**

Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[19 96]	Seuil :[22 73 125]	Seuil :[23 64 119 249]
	Fitness=1.1876e+003	Fitness=1.4879e+003	Fitness=1.4869e+003
OQPSO			
	Seuil :[15 93]	Seuil :[12 74 131]	Seuil :[31 67 125 202]
	Fitness=1.1854e+003	Fitness=1.4867e+003	Fitness=1.7057e+003
ABC			
	Seuil :[29 94]	Seuil :[26 60 100]	Seuil :[0 25 71 140]
	Fitness=1.1876e+003	Fitness=1.4888e+003	Fitness=1.6949e+003
GABC			
	Seuil :[31 95]	Seuil :[44 90 149]	Seuil :[0 29 68 144]
	Fitness=1.1868e+003	Fitness=1.2468e+003	Fitness=1.4647e+003

TABLE A.13 – Lena segmenté par les 4 approches avec la fonction objectif **Otsu**

Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[109 152]	Seuil :[91 147 190]	Seuil :[53 94 131 170]
	Fitness=1.9734e+003	Fitness=2.1437e+003	Fitness=2.2234e+003
OQPSO			
	Seuil :[106 167]	Seuil :[86 138 185]	Seuil :[83 120 162 181]
	Fitness=1.9720e+003	Fitness=2.1511e+003	Fitness=2.2234e+003
ABC			
	Seuil :[91 146]	Seuil :[4 92 152]	Seuil :[95 154 192 201]
	Fitness=1.9739e+003	Fitness=2.1491e+003	Fitness=2.2225e+003
GABC			
	Seuil :[78 144]	Seuil :[76 123 172]	Seuil :[51 77 128 191]
	Fitness=1.9739e+003	Fitness=2.1503e+003	Fitness=2.2234e+003

TABLE A.14 – Peppers segmenté par les 4 approches avec la fonction objectif **Otsu**

Approche	2Seuils	3Seuils	4Seuils
QPSO			
	Seuil :[68 133]	Seuil :[65 102 154]	Seuil :[51 92 131 171]
	Fitness=2.4608e+003	Fitness=2.6414e+003	Fitness=2.7297e+003
OQPSO			
	Seuil :[68 135]	Seuil :[57 117 173]	Seuil :[42 84 134 147]
	Fitness=2.4608e+003	Fitness=2.6465e+003	Fitness=2.7262e+003
ABC			
	Seuil :[72 129]	Seuil :[59 120 169]	Seuil :[67 128 174 188]
	Fitness=2.4607e+003	Fitness=2.6466e+003	Fitness=2.7178e+003
GABC			
	Seuil :[109 163]	Seuil :[51 121 161]	Seuil :[60 113 155 223]
	Fitness=2.5497e+003	Fitness=2.6493e+003	Fitness=2.7245e+003

Conclusion général

Dans ce travail, nous avons abordé le problème de la segmentation d'images médicales par seuillage multi-niveaux au moyen des métaheuristiques. Celles-ci ont révélé leur grande efficacité pour fournir des solutions approchées de bonne qualité. Parmi une large panoplie de méthodes de segmentation d'images par seuillage, on a choisi les deux méthodes les plus utilisées en ce domaine, la première consiste à segmenter les images médicales en se basant sur l'entropie de Kapur et la deuxième se base sur la variance inter-classes d'Otsu.

L'algorithme d'optimisation par essaim de particules PSO est une métaheuristique performante. Cependant, elle souffre d'un problème majeur qui est le problème de la convergence prématuée. Une bonne balance entre l'exploration et l'exploitation est primordiale pour une convergence vers la solution optimale. Pour cela, on a proposé comme première contribution une variante du PSO pour la segmentation d'images médicales par seuillage, qui est le PSO quantique (QPSO). Cet algorithme est plus performant que le PSO classique mais soufre toujours du problème de la convergence prématuée. Afin de pallier à cette limite, on a proposé comme deuxième contribution, qui est totalement la notre, une variante du PSO quantique qui introduit le concept d'apprentissage par complément. Cette approche est plus performante que l'algorithme QPSO de base. Elle a pu régler le problème de la convergence prématuée. Les algorithmes QPSO et OQPSO ont été comparés avec d'autres approches qui sont L'ABC et le GABC, qu'on a implémenté nous même pour but de comparaison. Ces approches sont parmi les métaheuristiques les plus performantes. Notant que l'approche GABC n'a jamais été utilisée pour la segmentation d'images médicales par seuillage multi-niveaux et cela est notre troisième contribution.

Les résultats expérimentaux qu'on a obtenu de l'application des ces 4 approches QPSO, OQPSO, ABC et GABC à différentes instances d'images médicales avec les deux fonctions objectif Kapur et Otsu. Ces résultats ont démontré la supériorité de notre approche qui est l'apprentissage par complément dans l'optimisation par essaim de particules quantiques OQPSO par rapport à l'algorithme QPSO de base ainsi que les algorithmes ABC et GABC qui sont parmi les métaheuristiques les plus performantes.

Ce travail peut se poursuivre dans plusieurs directions surtout dans cette époque d'or du multimédia. On va proposer de tester la performance de nos approches sur d'autres types de problèmes

réels ou académiques. De plus, on peut utiliser le concept d'apprentissage par complément pour accélérer la vitesse de convergence d'autres métaheuristiques dans le but de rester toujours dans l'optimisation.

Bibliographie

- ABDELLI, O.** (2011). Segmentation d'images par seuillage d'histogrammes bidimensionnels. Mémoire de D.E.A., Faculté de génie electronique et d'Informatique Departement Automatique Université Mouloud Mammeri de Tizi-Ouzou.
- ANDERSON, P.** (1999). Perspective : Complexity theory and organization science. *Organization Science*.
- AZERRADJ, A. et KESSOUM, A.** (2007). Application des contours actifs géodésiques pour la segmentation de la vidéo. *Mémoire de fin d'études*.
- BACHELET., V.** (1999). *Métaheuristiques parallèles hybrides : Application au QAP*. Thèse de doctorat, USTL LIFL France.
- BACK, T. et SCHWEFEL, H.-P.** (1993). An overview of evolutionary algorithms for parameter optimization evolutionay computation. *On the state of evolutionary computation. Proc.*, pages 1–24.
- BEAUMONT, P. et BRADSHAW, P.** (1995). A distributed parallel genetic algorithm for solving optimal growth models, computational economics. <http://www.sc-eco.univ-nantes.fr/~tvallee/recherche/murat/agpresf42.pdf>.
- BELKACEM, S.** (2006). *Optimisation topologique de structures par algorithmes génétiques*. Thèse de doctorat, Ecole Doctorale Sciences pour l'Ingénieur det Microtechniques Université de Technologie de Belfort-Montbéliard.
- BENDIAB, E.** (2010). *Traitemet d'image :Vision assistée par ordinateur (VAO)*. Université Mentouri Constantine.
- BENDIAB, E.** (2011). Traitement d'image. *Université Mentouri Constantine*.
- BERRICHI, F. et BENYETTOU, M.** (2009). Interprétation des images médicales cérébrales : Segmentation par l'approche split et merge ,conférence internationale sur l'informatique et ses applications. *Conférence Internationale sur l'informatique et ses Applications,Saida, Algeria*.
- BEVERIDGE, J., RIFFITH, J., KOHLER, R., HANSON, A. et RISEMAN, E.** (1989). Segmenting images using localized histograms and region merging ijc.

- BIHAN, D. L.** (2008). Comprendre le cerveau par l'image. *Membre de l'Institut Institut d'imagerie biomédicale NeuroSpin Direction des sciences du vivant CEA Centre de Saclay ,RMN, magnétisme et santé.*
- BIRATTARI, M, S.** (2002). Adaptation, adaptive capacity and vulnerability. *Morgan Kaufmann, San Francis.*
- BONNIOL, V.** (2009). Les techniques d'imagerie médicale : les examens radiologiques. *generation plus.*
- BOUCHER et GARBAY** (1998). Des agents spécialisés pour la compréhension de séquences d'images.
- BROWN, L.** (1992). A survey of image registration technique. *ACM computing surveys*, 24:325–376.
- CANNY, J.** (1986). A computational approach to edge detection, *ieee trans. on pattern analysis and machine intelligence.*
- CASTAN, S., ZHAO, J. et SHEN, J.** (1989). Une famille de détecteurs de contours basée sur filtre exponentiel.optimal. *In AFCET-RFIA.*
- CHANG, F., YEN, J. et S.CHANG** (1995). A new criterion for automatic multilevel thresholding. *IEEE trans. Image process.*
- CHEHDI, K. et COQUIN, D.** (1991). Binarisation d'images par seuillage local optimal maximisant un critère d'homogénéité. *Troisième colloque GRETSI-Juan-les-pins.*
- CHILALI, O.** (2006). Classification automatique de données utilisant les modéle deformable. *Thèse de magister, université mouloud Mammeri, Tizi Ouzou, Algerie.*
- CHO, Z., JONES, J. et SINGH, M.** (1993). Foundations of medical medical imaging wiley inter-science.
- COBB, J.** (2011). A definition of learning. <http://www.missiontolearn.com/2009/05/definition-of-learning/>.
- COQUEREZ, J.** (1995). Analyse d'image, filtrage et segmentation. *Masson 1995, Paris.*
- CORNUÉJOLS, A. et MICLET, L.** (Cornuejols2002). *L'apprentissage artificiel. Concepts et algorithmes.* Eyrolles.
- CUEVAS, E.** (2009). A novel multi threshold segmentation approach based on artificial immune system optimization advances in computational intell.

- DEKHICI, L. et BELKADI, K.** (2012). Métaheuristique des lucioles discrète pour les flow shop hybrides. *Laboratoire LAMOSI Département d'informatique Université U.S.T.O.M.B. 31000 Oran ALGERIE.*
- DERICHE, R.** (1987). Using canny's criteria to derive a recursively implemented optimal edge detector. *International Journal of Computer Vision.*
- DERICHE, R.** (1990). Fast algorithms for low level vision. *IEEE Trans. Pattern Analysis and Machine Intelligence.*
- DRAA, A.** (2011). *Modeles pour les systemes complexes adaptatifs pour la resolution de problemes : Automates cellulaires apprenants quantiques et evolution differentielle quantique.* Thèse de doctorat, Universite Mentouri de Constantine Faculte des Sciences de l'ingenieur Department d'informatique.
- DREO, J.** (2003). *Adaptation de la méthode des colonies de fourmis pour l'optimisation en variables continues.* Thèse de doctorat, Application en génie biomédical.
- EDMONDS, B.** (2000). *Syntactic Measures of Complexity.* Thèse de doctorat, University of Manchester.
- ELECTROPIEDIA** (2004). Définition de l'échantillonnage. *Commission Internationale électrotechnique.*
- FARZI, S., SHAVAZI, A. R. et PANDARI, A. R.** (2010). Using quantum-behaved particle swarm optimization for portfolio selection problem. *Faculty of Computer Engineering, Islamic Azad University – Branch of Kermanshah, Kermanshah, Iran.*
- FEIBEN, A. et SCHIPPERS, C.** (1998). On evolutionary exploration and exploitation. *Fundamenta Informatica.*
- FENG, D., WENKANG, S., LIANGZHOU, C., YONG, D. et ZHENFU, Z.** (2005). Infrared image segmentation with 2d maximum entropy method based on particle swarm optimization (pso). *Pattern Recognition Letters*, 26:597–603.
- FRASER, A.** (1957). *Simulation of genetic systems by automatic digital computers.* Thèse de doctorat, Journal of Biological Science.
- FROMM, J.** (2005). Types and forms of emergence. <http://arxiv.org/ftp/nlin/papers/0506/0506028.pdf>.
- GONZALEZ, R. et WOODS, R. E.** (1992). Digital image processing. *Addison Wesley, Reading, MA.*
- GONZALEZ, W.** (2008). Intensity transformations and spatial filtering.

- HAFSIA, R.** (2012). Une approche basée essaim d'abeilles artificielles pour la segmentation d'images. Mémoire de D.E.A., Laboratoire MISC, Université Mentourie Constantine Algerie.
- HAMMOUCHE, K., DIAF, M. et SIARRY, P.** (2010). A comparative study of various meta-heuristic techniques applied to the multilevel thresholding problem. *journal home page*.
- HAMMOUCHE, K., K., D. et M., S.** (2008). A multilevel automatic thresholding method based on a genetic algorithm for a fast image segmentation. *Computer Vision Image*.
- HASHEMI, A. et MEYBODI** (2011). Anote on the learning automata based algorithms for adaptive parameter selection in pso. Rapport technique, Applied Soft Computing.
- HASSANZADEH, T., VOJODI, H. et MAHMOUDI, F.** (2011). Non-linear grayscale image enhancement based on firefly algorithm. *Faculty of IT and Computer Engineering Qazvin Azad University, Qazvin, Iran*.
- HASSAS, S.** (2003). *Systèmes complexes à base de multi-agents situés*. Habilitation à diriger des recherches, Université Claude Bernard-Lyon 1.
- HENON, S. et WEISBUCH, G.** (2003). Action concertée : "systèmes complexes en shs". Rapport technique, CNRS, PARIS.
- HOLLAND, J. H.** (1996). *Hidden Order : How Adaptation Builds Complexity*. Addison Wesley Longman Publishing Co., Inc. New York.
- HORNG, M.-H.** (2011). Multilevel thresholding selection based on the artificial bee colony algorithm for image segmentation. *Department of Computer Science and Information Engineering, National PingTung Institute of Commerce, No. 51 Min-Shien E. Road, Pingtung City 900, Taiwan*, 38:13785–13791.
- HOROWITZ, S. et PAVLIDIS, T.** (1976). Picture segmentation by a tree traversal algorithm. *journal of the association for computing machinery*. 23(2):368–388.
- IANIK, M.** (1995). *Les implications épistémologiques des théories du chaos pour l'hypothèse des anticipations rationnelles*. Thèse de doctorat, Université du Québec.
- ILACHINSKI, A.** (2004). *Artificial War : Multi-Agent Based Simulation of Combat*. World Scientific.
- JAIN, A., MURTY, M. et FLYNN, P.** (1999). Data clustering : a review. *acm computing surveys*.
- JONG, K. D. et SPEARS, W.** (1993). On the state of evolutionary computation. *Proc Of International Conference on Genetic Algorithms (ICGA 93)*, pages 618—623.
- JOURDAN, L.** (2003). *Métaheuristiques pour l'extraction de connaissances : Application à la génomique*. Thèse de doctorat, Université des sciences et technologies de Lille France.

- KAPUR, J., SAHOO, P. et WONG, A.** (1985). A new method for gray-level picture thresholding using the entropy of the histogram. *computer vision, graphics and image processing*.
- KARABOGA, D.** (2007). A powerful and efficient algorithm for numeral function optimization :artificial bee colony(abc)algorithm. *The Dept. of Computer Engineering Turk Université erciyes,Melikgazi, Kayseri, 38039.*
- KARABOGA, D. et AKAY, B. B.** (2007). Artificial bee colony algorithm on training artificial neural networks. *Signal Processing and Communications Applications*.
- KASS, M., WIKIN, A. et D, T.** (1988). Snakes : Active contour models computer vision. *graphics and image processing*.
- KENNEDY, J. et EBERHART, C.** (1995). Particle swarm optimization. *on Neuronal networks, Piscataway (Japan) IEEE Int. Conf*, 4:1942–1948.
- KIRSCH, R.** (1971). Computer determination of the constituent structures of biomedical images. *Computer and Biomedical Research. USA.*
- LANGTON, C. G.** (1990). Computation at the edge of chaos : Phase transition and emergent computation. *Physica*, 42:12–37.
- LAURENCE, G.** (1999). *Trois principes de coopération pour la segmentation en imagerie de résonnance magnétique cérébrale*. Thèse de doctorat, Imag, Université Joseph Fourier Grenoble I. TIMC.
- LIU, H. W. Y., ZENG, S. Y., LI, H. et LI, C. H.** (2007). Opposition-based particle swarm algorithm with cauchymutation. *Proceedings of the Conference on EvolutionaryComputation*.
- MONTAGNE, E. et HEITZ, F.** (2009). *Imagerie médicale tome 1*. Radiologie conventionnelle standard ,3ème édition.
- MORIN, E.** (2008). *On Complexity*. Advances in Systems Theory, Complexity, and the Human Sciences. Hampton Press.
- NAKIB, A.** (2007). *Conception de métahéuristiques d'optimisation pour la segmentation d'images. Application à des images biomédicales*. Thèse de doctorat.
- NEGGAZ, N. et BENYETTOU, A.** (2009). Recalage des images médicales par les algorithmes évolutionnaires. *Laboratoire Signal Image Parole (SIMPA) Algérie, Université des Sciences et de la Technologie d'Oran.*
- OHLANDER, PRICE, K. et REDDY, D. R.** (1979). Picture segmentation using recursive region splitting method. *computer graphics and image processing*.

- OTSU, N.** (1979). A threshold selection method for grey level histograms. *IEEE Transactions on System, Man and Cybernetics*.
- PARROTT, L.** (2002). Complexity and the limits of ecological engineering. *Transactions of the ASAE American Society of Agricultural Engineers*.
- PAVLIDIS et LIOW, Y.-T.** (1990). Integrating region growing and edge detection. *IEEE Trans Pattern analysis and machine intelligence*.
- PREWITT, J.** (1970). Object enhancement and extraction.
- PRICE, K. et STORN, R.** (1997). Differential evolution a simple and efficient heuristic for global optimization over continuous spaces report tr95 -012. *Journal of Global Optimization, International Computer Science Institute, Berkeley, California*.
- RAFAEL, G. et WOODS, R. E.** (2008). *Digital Image Processing*. Pearson Prentice Hall.
- RAHNAMAYAN, S., TIZHOOSH, H. R. et SALAMA, M. M. A.** (2008). Opposition-based differential evolution. *IEEE Transaction on Evolutionary Computation*.
- RASHEDI, E. et NEZAMABADI, H.** (2009). Gsa : A gravitational search algorithm. *Shahid Bahonar University of Kerman, Department of Electrical Engineering*.
- ROBERTS, L.** (1965). Machine perception of 3-d solids.
- RÉPTER** (2000). Définition du répertoire terminologique 2000 [archive] de la commission générale de terminologie et de néologie.
- SCHOENAUER, M. et MICHALEWICZ, Z.** (1997). Evolutionary computation : an control and cybernetics.
- SHEN, J. et CASTAN, S.** (1986). An optimal linear operator for edge detection. *In Proc.IEEE Computer Society Conference on Computer Vision and Pattern Recognition*.
- SHEN, J. et CASTAN, S.** (1992). An optimal linear operator for step edge detection. *CVGIP. Graphics Models and Image Processing*.
- SHI-YANG, X.** (2009). Firefly algorithms for multimodal optimization, stochastic algorithms science. *Foundations and Applications”, SAGA 2009, Lecture Notes in Computer Springer-Verlag, Berlin*.
- SMIT, B. et WANDEL, J.** (2006). Adaptation, adaptive capacity and vulnerability. *Global Environmental Change Elsevier*.
- SOBEL, I.** (1978). Neighbourhood coding of binary images for fast contour following and general array binary processing.computer graphics and image processing.

- STRASTERS, K. et GERBRANDS, J.** (1991). Three-dimensional image segmentation using a split, merge and group approach.
- SUN, J.** (2004). Particle swarm optimization with particles having quantum behavior , a global search strategy of quantum behaved particle swarm optimization. *Proc.of Congress on Evolutionary Computation, Proc. IEEE Conference on Cybernetics and Intelligent Systems*.
- TALBI, H.** (2009). *Algorithme evolutionnaire quantique pour le recalage et la segmentation d'images multiobjectif*. Thèse de doctorat, Université Mentourie Constantine.
- TAO, W. et TIAN, J. W.** (2003). Jian liuimage segmentation by three level thresholding based on maximum fuzzy entropy and genetic algorithm pattern recognition letters.
- TIZHOOSH, H. et MALISIA, A. R.** (2007). "applying opposition-based ideas to the ant colony system". *Proceedings of IEEE Swarm Intelligence Symposium*.
- TROUDI, F.** (2006). Résolution du problème de l'emploi du temps : Proposition d'un algorithme évolutionnaire multi objectif. Mémoire de D.E.A., Laboratoire MISC, Université Mentourie Constantine Algerie.
- Van den BERGH, F.** (2001). An analysis of particle swarm optimizers. *University of Pretoria*.
- van der MERWE, D. et ENGELHRECHT, A.** (2003). Data clustering using particle swarm optimization. *Department of Computer Science University of Pretoria*.
- YANG, K., MAGINU, K. et NOMURA, H.** (2009). Parameters identification of chaotic systems by quantum-behaved particle swarm optimization. *Department of Artificial Intelligence, Kyushu Institute of Technology, Iizuka Japan*.
- YANG, Z.-H.** (2003). Relative entropy multilevel thresholding method based on genetic algorithm,, *in : IEEE International Conference on Neural Networks and Signal Processing Nanjing, China*.
- YU, H.-Y. et FAN, J.-L.** (2008). Three level image segmentation based on maximum fuzzy partition entropy of 2-d histogram and quantum genetic algorithm. *Département of information and control Xi an institute of post and telecommunication*.
- ZHU, G. et KWONG, S.** (2010). Gbest guided artificial bee colony algorithm for numerical function optimization. *Shenzhen Institues of Advanced Technology,Chinese Academy of Sciences, Shenzhen Chinz*, pages 3167–3173.
- ZUCKER, S.** (1976). Region growing childhood and adolescence. computer graphics and image dans processing. *Signal Processing*, 5.